Números enteros

Cada palabra, cualquiera que sea su longitud, almacena un número, aunque en ciertas circunstancias se usan varias palabras para contener un número. Por ejemplo, considérese una palabra de 16 bits para almacenar números enteros. De los 16 bits, el primero representa el signo del número; un cero es un signo más y un uno es un signo menos. Los 15 bits restantes pueden usarse para guardar números binarios desde 000000000000000 hasta 111111111111111 (véase figura 1.6). Al convertir este número en decimal se obtiene:

$$(1 \times 2^{14}) + (1 \times 2^{13}) + (1 \times 2^{12}) + \ldots + (1 \times 2^{1}) + (1 \times 2^{0})$$

que es igual a $2^{15} - 1 = 327671$. Por lo tanto, cada palabra de 16 bits puede contener un número cualquiera del intervalo −32768 a + 32767 (véase el problema 1.10).

Números reales (punto flotante)

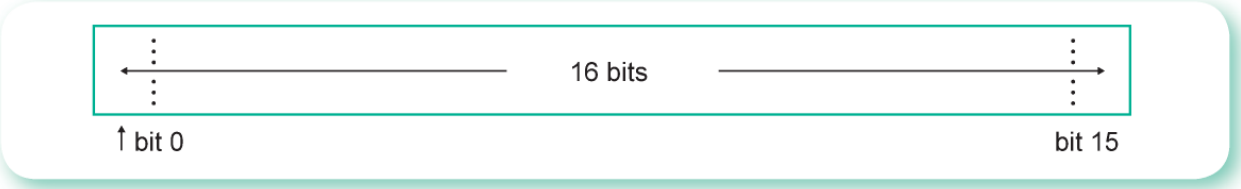

Figura 1.6 Esquema de una palabra de 16 bits para un número entero.

Ejemplo 1.8

Represente el número 525_{10} en una palabra de 16 bits.

Solución

$525_{10} = 1015_8 = 1000001101_2$, y su almacenamiento quedaría de la siguiente forma:

0	0	0	0	0	0	1	0	0	0	0	0	1	1	0	1

Ejemplo 1.9

Represente el número −26 en una palabra de 16 bits.

Solución

$-26_{10} = -\ 11010_2$ y su almacenamiento en una palabra de 16 bits quedaría así:

1	0	0	0	0	0	0	0	0	0	0	1	1	0	1	0

Copyright © 2015. Grupo Editorial Patria. All rights reserved

Nieves Hurtado, A. (2015). Métodos numéricos: aplicados a la ingeniería: (ed.). Grupo Editorial Patria. https://elibro.net/es/ereader/unachecuador/39455?page=31

Cuando se desea almacenar un número real, se emplea en su representación binaria, llamada de punto flotante, la notación

$$0.d_1d_2d_3d_4d_5d_6d_7d_8 \times 2^{d'_1 d'_2 d'_3 d'_4 d'_5 d'_6 d'_7}$$

donde $d_1 = 1$ y d_i y d'_j con $i = 2, \ldots, 8$ y $j = 1,2,\ldots, 7$ pueden ser ceros o unos y se guarda en una palabra, como se muestra en la figura 1.7.

Igual que antes, el bit cero se usa para guardar el signo del número. En los bits del uno al siete se almacena el exponente de la base 2 y en los ocho restantes la fracción.* Según el lenguaje de los logaritmos,

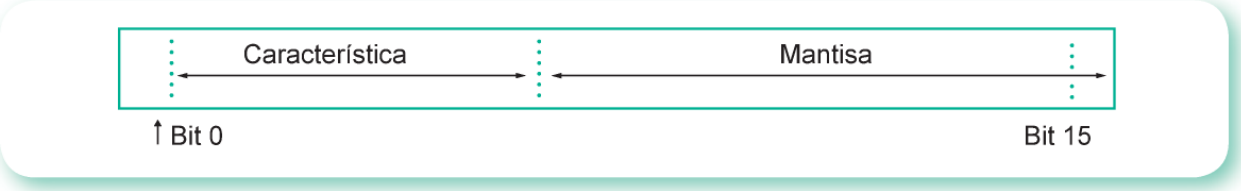

Figura 1.7 Esquema de una palabra de 16 bits para un número de punto flotante.

la fracción es llamada **mantisa** y el exponente **característica**. El número mayor que puede guardarse en una palabra de 16 bits, usando la notación de punto flotante, es

	Exponente positivo	
0	0111111	11111111
más	2^{63}	Equivalente a 0.99 en decimal

y los números que se pueden guardar en punto flotante binario van de alrededor de 2^{-64} (si la característica es negativa) a cerca de 2^{63}; en decimal, de 10^{-19} a cerca de 10^{18} en magnitud (incluyendo números positivos, negativos y el cero).
Nótese que primero se normaliza el número, después se almacenan los primeros ocho bits y se truncan los restantes.

Ejemplo 1.10

El número decimal −125.32 que en binario es

$$-1111101.010100011110101,$$

Solución
Normalizado queda así:

$$-.\underbrace{11111010100011110101}_{\text{bits truncados en el almacenamiento}} \times 2^{+111}$$

* El exponente es un número binario de seis dígitos, ya que el bit uno se emplea para su signo. En algunas computadoras el exponente se almacena en base ocho (octal) o base 16 (hexadecimal), en lugar de base 2.

Copyright © 2015. Grupo Editorial Patria. All rights reserved

Nieves Hurtado, A. (2015). Métodos numéricos: aplicados a la ingeniería: (ed.). Grupo Editorial Patria. https://elibro.net/es/ereader/unachecuador/39455?page=31

y la palabra de memoria de 16 bits donde se almacena este valor quedaría como

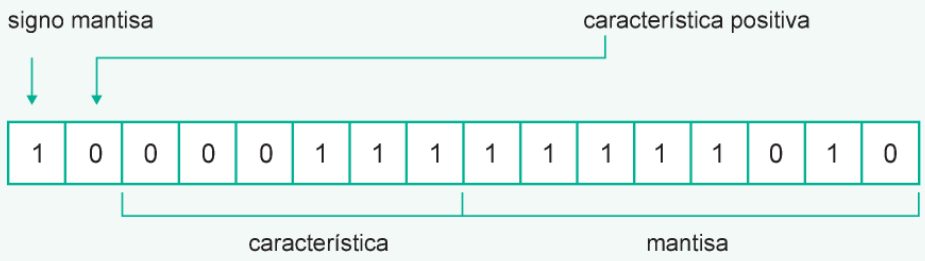

El número decimal + 0.2, que en binario es

$$0.0011001100110011...$$

y que normalizado queda

$$.1100110011001100... \times 2^{-10}$$

bits truncados

se almacena así:

0	1	0	0	0	0	1	0	1	1	0	0	1	1	0	0

Doble precisión

La doble precisión es un esfuerzo para aumentar la exactitud de los cálculos adicionando más bits a la mantisa. Esto se hace utilizando dos palabras, la primera en la forma expuesta con anterioridad y los bits de la segunda para aumentar la mantisa de la primera. Entonces, con una palabra de 16 bits puede usarse en doble precisión una mantisa de 8 + 16 = 24 bits, los cuales permiten expresar alrededor de 7 dígitos de exactitud en un número decimal, en lugar de 3 de la precisión sencilla.

La desventaja del uso de la doble precisión es que se emplean más palabras, con lo que aumenta el uso de memoria por un programa.

Error de redondeo

Para finalizar esta sección, se analizarán brevemente algunas consecuencias de utilizar el sistema binario y una longitud de palabra finita.

Como no es posible guardar un número binario de longitud infinita o un número de más dígitos de los que posee la mantisa de la computadora que se está empleando, se almacena sólo un número finito de estos dígitos; la consecuencia es que comete automáticamente un pequeño error, conocido como error de redondeo, que al repetirse muchas veces puede llegar a ser considerable. Por ejemplo, si se desea guardar la fracción decimal 0.0001, que en binario es la fracción infinita

$$0.0000000000000110100011011011100010111010110 00...$$

Copyright © 2015. Grupo Editorial Patria. All rights reserved

Nieves Hurtado, A. (2015). Métodos numéricos: aplicados a la ingeniería: (ed.). Grupo Editorial Patria. https://elibro.net/es/ereader/unachecuador/39455?page=31

quedaría, después de normalizarse, almacenada en una palabra de 16 bits como

$$.11010001 \times 2^{-1101}$$

Si se desea sumar el número 0.0001 con él mismo diez mil veces, usando una computadora, naturalmente que no se esperará obtener 1 como resultado, ya que los números que se adicionen no serían realmente 0.0001, sino valores aproximados a él (véase el problema 1.16).

1.3 Errores

Error absoluto, error relativo y error en por ciento

Si p^* es una aproximación a p, el error se define como

$$E = p^* - p$$

Sin embargo, para facilitar el manejo y el análisis se emplea el error absoluto definido como

$$EA = | p^* - p |$$

y el error relativo como

$$ER = \frac{| p^* - p |}{p}, \text{ si } p \neq 0$$

y como por ciento de error a

$$ERP = ER \times 100$$

En otros libros, las definiciones pueden ser diferentes; por ejemplo, algunos autores definen el error E como $p - p^*$; por tanto, sugerimos que al consultar distintas bibliografías se busquen las definiciones de error dadas.

Ejemplo 1.11

Suponga que el valor para un cálculo debiera ser

$$p = 0.10 \times 10^2, \text{ pero se obtuvo el resultado } p^* = 0.08 \times 10^2, \text{ entonces}$$

$$EA = | 0.08 \times 10^2 - 0.10 \times 10^2 | = 0.2 \times 10^1$$

$$ER = \frac{| 0.08 \times 10^2 - 0.10 \times 10^2 |}{0.10 \times 10^2} = 0.2 \times 10^0$$

$$ERP = ER \times 100 = 20\%$$

Por lo general, interesa el error absoluto y no el error relativo; pero, cuando el valor exacto de una cantidad es "muy pequeño" o "muy grande", los errores relativos son más significativos.

Por ejemplo, si

$$p = 0.24 \times 10^{-4} \quad \text{y} \quad p^* = 0.12 \times 10^{-4},$$

Copyright © 2015. Grupo Editorial Patria. All rights reserved

Nieves Hurtado, A. (2015). Métodos numéricos: aplicados a la ingeniería: (ed.). Grupo Editorial Patria. https://elibro.net/es/ereader/unachecuador/39455?page=31