UNIDAD 1

# Fundamentos de Machine Learning.

TEMA 1:

## Introducción y fundamentos.

**Descripción**:

La asignatura Machine Learning 1 ofrece al estudiante una primera aproximación al fascinante mundo del aprendizaje automático, integrando teoría y práctica para resolver problemas reales con datos.

A lo largo del curso, se explorarán los fundamentos matemáticos y computacionales que sustentan los algoritmos modernos, junto con ejemplos aplicados en ciencia e ingeniería.

El estudiante aprenderá a diseñar, entrenar y evaluar modelos, comprendiendo tanto sus alcances como sus limitaciones.

Esta experiencia no solo fortalece competencias técnicas, sino también el pensamiento crítico, preparando a los futuros profesionales para enfrentar los desafíos de la era digital con creatividad e innovación.

Machine Learning 1

PERIODO ACADÉMICO 2026-1S

TABLA DE CONTENIDO

Tema 1. Introducción y fundamentos..... 2
1.1. Concepto y tipos de aprendizaje automático. ..... 2
1.2. Aplicaciones y desafíos en ciencia e ingeniería. ..... 4
1.3. Fundamentos matemáticos: álgebra lineal, probabilidad y estadística..... 6
1.4. Herramientas computacionales..... 8
Bibliografía ..... 9

# Tema 1. Introducción y fundamentos.

El aprendizaje automático (Machine Learning, ML) se ha consolidado como un campo fundamental dentro de la inteligencia artificial (IA) y la ciencia de datos. Su relevancia radica en la capacidad de los algoritmos para identificar patrones en grandes volúmenes de datos y realizar predicciones sin necesidad de instrucciones explícitas. En las últimas dos décadas, este paradigma ha revolucionado la investigación científica, la ingeniería y los sectores productivos, al punto de convertirse en una herramienta transversal a múltiples disciplinas.

El propósito de este tema es ofrecer una visión estructurada de los principios esenciales del ML. En primer lugar, se revisan los conceptos y tipos de aprendizaje automático, diferenciando sus enfoques y aplicaciones. Posteriormente, se destacan ejemplos recientes de aplicación en ciencia e ingeniería, así como los desafíos actuales en términos de calidad de datos, interpretabilidad y eficiencia computacional. Luego, se abordan los fundamentos matemáticos que constituyen la base teórica de los algoritmos, incluyendo álgebra lineal, probabilidad y estadística. Finalmente, se analizan las herramientas computacionales que permiten la implementación práctica de los modelos, con énfasis en el ecosistema Python.

**1.1. Concepto y tipos de aprendizaje automático.**

El aprendizaje automático se define como la disciplina que desarrolla algoritmos capaces de mejorar su desempeño en tareas específicas a partir de datos, sin ser programados explícitamente para cada caso (ISO, 2023).

Desde un punto de vista práctico, el ML implica generalizar a partir de ejemplos, es decir, aprender patrones y regularidades para predecir resultados en situaciones inéditas. La clasificación más aceptada de los tipos de ML incluye cinco enfoques principales que se describen en la Figura 1 y se detallan a continuación:

1. **Aprendizaje supervisado**: utiliza conjuntos de datos con etiquetas conocidas. Es el más utilizado en la industria y se aplica en clasificación de imágenes, predicción de valores numéricos y diagnóstico médico (IBM, 2023).
2. **Aprendizaje no supervisado**: trabaja con datos sin etiquetas, identificando estructuras ocultas como agrupamientos o componentes principales. Ejemplos recientes incluyen segmentación de clientes y análisis de redes sociales (Yazici et al., 2023).
3. **Aprendizaje semi-supervisado**: combina un pequeño conjunto de datos etiquetados con un gran volumen de datos no etiquetados, útil en contextos donde el etiquetado manual resulta costoso, como en la genómica (Symeonidis et al., 2022).
4. **Aprendizaje por refuerzo**: entrena agentes mediante la interacción con un entorno, recibiendo recompensas o penalizaciones. Ha alcanzado notoriedad por su éxito en robótica y videojuegos complejos (Hao et al., 2022).
5. **Aprendizaje auto-supervisado**: emergente en la última década, crea etiquetas artificiales a partir de los propios datos. Es fundamental en los grandes modelos de lenguaje y visión (IBM, 2023).

**Figura 1.** Tipos de Aprendizaje Automático

**Fuente:** Elaboración propia

La coexistencia de estos enfoques ha derivado en sistemas híbridos que combinan lo mejor de cada paradigma, dando origen a arquitecturas más robustas y versátiles.

## 1.2. Aplicaciones y desafíos en ciencia e ingeniería.

El ML se encuentra presente en una amplia gama de aplicaciones científicas y tecnológicas (ver Figura 2):

- **Salud y biomedicina**: diagnóstico asistido por imágenes médicas, predicción de riesgos cardiovasculares y descubrimiento de fármacos mediante simulaciones moleculares.

- **Ingeniería civil y ambiental**: detección de fallas estructurales, predicción de deslizamientos de tierra y modelado de inundaciones a partir de datos satelitales.
- **Telecomunicaciones**: detección de fraudes, predicción de congestión de red y optimización de asignación de recursos.

- **Educación personalizada**: sistemas que adaptan contenidos en función del desempeño de los estudiantes, promoviendo itinerarios de aprendizaje flexibles (Yazici et al., 2023).

**Figura 2.** Espectro de aplicaciones de Inteligencia Artificial desde la asistencia humana hasta la automatización completa.

**Fuente:** Elaboración propia

Sin embargo, estas aplicaciones enfrentan desafíos que condicionan su impacto y se visualizan en la Figura 3 y son los siguientes:

**1. Sesgos y equidad**: los algoritmos tienden a reproducir sesgos de los datos, lo que plantea retos éticos y sociales (Mersha et al., 2024).

**2. Complejidad computacional**: los modelos profundos requieren arquitecturas de hardware especializadas (GPU y TPU) y un consumo energético significativo (Hao et al., 2022).

**3. Calidad de los datos**: la presencia de ruido, valores faltantes o distribuciones no representativas compromete la validez de los modelos (Dritsas et al., 2025).

**4. Interpretabilidad**: se ha enfatizado la necesidad de modelos explicables, especialmente en áreas críticas como la medicina o las finanzas (Mersha et al., 2024).

Estos retos han impulsado el desarrollo de subcampos como la IA explicable (*Explainable AI, XAI*) y el aprendizaje automático informado por principios físicos (*Physics-Informed Machine Learning*), que buscan un balance entre precisión, transparencia y confiabilidad.

**Figura 3.** Desafíos de la Inteligencia Artificial que van más allá de la superficie.

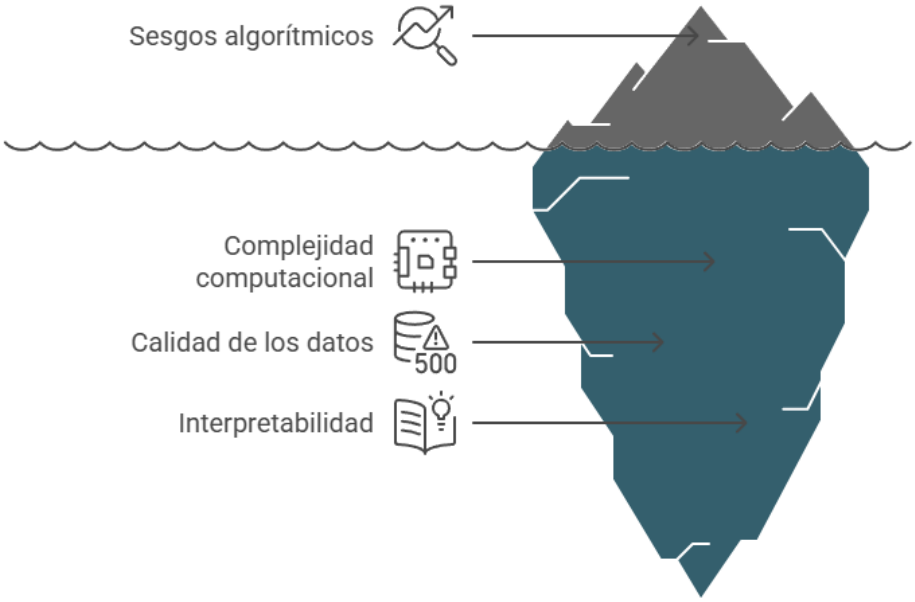


**Fuente:** Elaboración propia

**1.3. Fundamentos matemáticos: álgebra lineal, probabilidad y estadística.**

El éxito de ML se sustenta en un sólido andamiaje matemático.

Tres disciplinas resultan especialmente relevantes, las cuales se ilustran en la Figura 4 y se detallan a continuación:

- **Álgebra lineal**: proporciona las herramientas para representar datos en vectores y matrices, manipular transformaciones lineales y aplicar descomposiciones como la SVD. Recientes avances en álgebra lineal aleatorizada permiten escalar estas operaciones a conjuntos de datos masivos (Dritsas et al., 2025).
- **Probabilidad**: sustenta la modelación de la incertidumbre mediante distribuciones y procesos estocásticos. Conceptos como los modelos de Markov resultan esenciales en aprendizaje por refuerzo.
- **Estadística**: aporta métodos de inferencia, validación y pruebas de hipótesis, necesarios para asegurar que los modelos aprendidos sean generalizables y no reflejen patrones espurios (Symeonidis et al., 2022).

La integración de estas disciplinas permite el diseño de algoritmos robustos, capaces de equilibrar precisión, eficiencia y capacidad de generalización.

**Figura 4.** Fundamentos Matemáticos de la Inteligencia Artificial

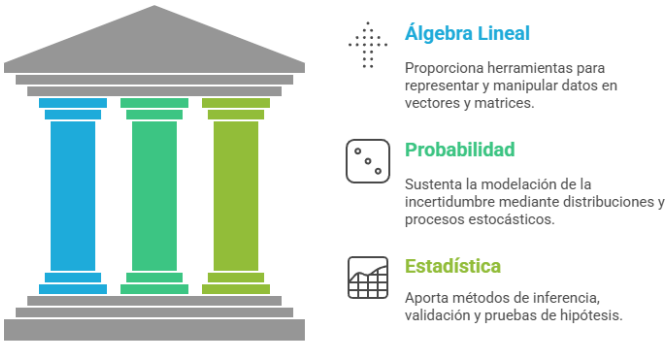


**Fuente:** Elaboración propia

### 1.4. Herramientas computacionales.

El desarrollo práctico de proyectos de ML se apoya en un ecosistema tecnológico que facilita la implementación, evaluación y despliegue de modelos.

Un resumen gráfico se aprecia en la Figura 5.

- **Lenguajes de programación**: Python domina el campo gracias a su simplicidad y extensas bibliotecas.
- **Bibliotecas científicas**: NumPy y pandas para manipulación de datos, matplotlib y seaborn para visualización, y scikit-learn para modelos clásicos.
- **Frameworks de deep learning**: TensorFlow y PyTorch son líderes en la construcción y entrenamiento de redes neuronales profundas.
- **Entornos interactivos**: Jupyter Notebooks y Google Colab permiten documentar procesos de forma reproducible.
- **Prácticas de MLOps**: han emergido como un campo clave que integra ingeniería de software y ciencia de datos para garantizar la reproducibilidad y la escalabilidad de los modelos en entornos de producción (Symeonidis et al., 2022).

**Figura 5.** Principales Herramientas de Ciencia de Datos

**Fuente:** Elaboración propia

# Bibliografía

Barthels, C., Müller, I., Taranov, K., Alonso, G., & Hoefler, T. (2019). Strong

Dritsas, E., Stamelos, I., Tsakalidis, A., & Sotiropoulos, D. N. (2025). Exploring the intersection of machine learning and big data. *Journal of Open Innovation: Technology, Market, and Complexity, 7*(1), 13. MDPI. https://doi.org/10.3390/make7010013

Hao, Z., Liu, S., Zhang, Y., Ying, C., Feng, Y., Su, H., & Zhu, J. (2022). Physics-informed machine learning: A survey on problems, methods and applications. *arXiv preprint*. https://arxiv.org/abs/2211.08064

Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): When to use them or not. *Geoscientific Model Development, 15*, 5481–5487. https://doi.org/10.5194/gmd-15-5481-2022

IBM. (2023). *Five machine learning types to know*. IBM Think. https://www.ibm.com/think/topics/machine-learning-types

ISO. (2023). *Artificial intelligence — Machine learning — Framework for machine learning*. International Organization for Standardization. https://www.iso.org/artificial-intelligence/machine-learning

ISO/IEC. (2022). ISO/IEC 23053:2022 — Framework for Artificial Intelligence (AI) Systems Using Machine Learning (ML). ISO. ScienceDirect

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in ML-based science. *Patterns, 4*(10), 100779. https://doi.org/10.1016/j.patter.2023.100804

McLatchie, Y., et al. (2024). Efficient estimation and correction of selection-induced bias. *Statistics and Computing, 34*, 132. https://doi.org/10.1007/s11222-024-10442-4

Mersha, M., Lam, K., Wood, J., Alshami, A. K., & Kalita, J. (2024). Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction. *Neurocomputing*, *599*, 128111. https://doi.org/10.1016/j.neucom.2024.128111

Mienye, I. D., & Sun, Y. (2022). A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. *IEEE Access, 10*, 99129–99159. https://doi.org/10.1109/ACCESS.2022.3207287

AI, N. (2023). Artificial intelligence risk management framework (AI RMF 1.0). *URL: https://nvlpubs. nist. gov/nistpubs/ai/nist. ai*, 100-1

Owusu-Adjei, M., Ben Hayfron-Acquah, J., Frimpong, T., & Abdul-Salaam, G. (2023). Imbalanced class distribution and performance evaluation metrics. *PLOS Digital Health,* 2(11), e0000290. https://doi.org/10.1371/journal.pdig.0000290

scikit-learn developers. (n. d.). 3.1 Cross-validation: evaluating estimator performance. *Scikit-learn 1.7.2 documentation*. scikit-learn.org

scikit-learn developers. (n. d.). Nested versus non-nested cross-validation (example). *Scikit-learn 1.7.2 documentation*. scikit-learn.org

scikit-learn developers. (n. d.). Calibration tools (brier_score_loss, calibration_curve). *Scikit-learn 1.7.2 documentation*. scikit-learn.org

Symeonidis, G., Nerantzis, E., Kazakis, A., & Papakostas, G. A. (2022, January). Mlops-definitions, tools and challenges. In *2022 IEEE 12th Annual Computing and Communication Workshop and Conference (CCWC)* (pp. 0453-0460). IEEE. https://doi.org/10.1109/CCWC54503.2022.9720902

Yazici, İ., Yıldız, O. T., & Karakaya, M. (2023). A survey of applications of artificial intelligence and machine learning. *ICT Express,* 9(3), 221–233. https://doi.org/10.1016/j.jestch.2023.101455