



Coordinación de  
**Educación Abierta y a Distancia**  
VICERRECTORADO ACADÉMICO



## ASIGNATURA MACHINE LEARNING

### Actividad Autónoma 2

**Nombre de la actividad:** Principios de modelado y validación en Machine Learning

**Unidad 1:** Fundamentos de Machine Learning

**Tema 2:** Principios de modelado y validación



FACULTAD DE  
Ingeniería

Nombre: Lenin Lopez

Fecha:

Carrera: 26042026

Periodo académico: 2026-1S

Semestre: 4to.

## Flujo de modelado

1. Describa con sus propias palabras las etapas principales de un proyecto de aprendizaje automático desde la recopilación de datos hasta la validación final.

**Preparación de datos:** Se recopila la información necesaria, se limpian errores y se transforman los datos para que sean utilizables.

**Análisis y división:** Se exploran los patrones de los datos y se dividen en grupos de entrenamiento, validación y prueba.

**Entrenamiento:** El algoritmo procesa los datos de entrenamiento para aprender a resolver el problema planteado.

**Optimización y validación:** Se ajustan los parámetros y se evalúa el rendimiento del modelo con datos no vistos para mejorar su precisión.

**Prueba final y despliegue:** Se realiza una evaluación definitiva del desempeño y, si es satisfactorio, se pone el modelo en producción.

2. Realice un diagrama de flujo sencillo que muestre dichas etapas.



## Métricas de desempeño

3. Un modelo de clasificación binaria arrojó la siguiente matriz de confusión en un conjunto de 100 observaciones:

|               | Predicho Positivo | Predicho Negativo |
|---------------|-------------------|-------------------|
| Real Positivo | 40                | 10                |
| Real Negativo | 20                | 30                |

a) **Calcule accuracy.**

Datos

VP = 40

FN = 10

FP = 20

VN = 30

$$Accuracy = \frac{VP+VN}{VP+VN+FP+FN}$$

$$Accuracy = \frac{40 + 30}{40+30+20+10} = 0.70$$

b) **Calcule precision.**

$$precision = \frac{VP}{VP + FP} = \frac{40}{40 + 20} = 0.6667$$

c) **Calcule recall.**

$$recall = \frac{VP}{VP + FN} = \frac{40}{40 + 10} = 0.80$$

d) **Calcule F1-score.**

$$F1 = \frac{2 \cdot precision \cdot recall}{precision + recall} = \frac{2 \cdot 0,667 \cdot 0,80}{0,667 \cdot 0,80} = 0.7273$$

e) Interprete los resultados: ¿es un modelo equilibrado?

El modelo tiene un desempeño aceptable, pero no es completamente equilibrado. Detecta bastante bien los casos positivos, porque su recall es alto, pero también comete varios falsos positivos, lo que baja la precision. En otras palabras, el

modelo encuentra la mayoría de los positivos, aunque no siempre acierta cuando predice una clase positiva.

5. Para un modelo de regresión, los valores reales y predichos fueron:

- Reales: [3.0, 2.5, 4.0, 5.0]
- Predichos: [2.8, 2.7, 4.2, 4.5]

a) Calcule el Error cuadrático medio (RMSE).

| Real | Predicho | Error | Error cuadrado |
|------|----------|-------|----------------|
| 3.0  | 2.8      | 0.2   | 0.04           |
| 2.5  | 2.7      | -0.2  | 0.04           |
| 4.0  | 4.2      | -0.2  | 0.04           |
| 5.0  | 4.5      | 0.5   | 0.25           |

$$MSE = \frac{0.04 + 0.04 + 0.04 + 0.25}{4} = \frac{0.37}{4} = 0.0925$$

$$RMSE = \sqrt{0.0925} = 0.3041$$

b) Explique qué significa el resultado respecto al ajuste del modelo.

El valor del RMSE indica que, en promedio, las predicciones del modelo se desvían alrededor de 0.30 unidades respecto a los valores reales. Mientras más pequeño sea este valor, mejor ajuste tiene el modelo.

## Validación de modelos

6. Explique en qué consiste la división *train/validation/test* y su importancia.

**Train:** se usa para que el modelo aprenda.

**Validation:** se usa para ajustar hiperparámetros y comparar versiones del modelo.

**Test:** se reserva para medir el desempeño final sin influir en el entrenamiento.

Esta separación es importante porque evita que el modelo se evalúe con los mismos datos con los que aprendió. Si eso pasara, el resultado sería demasiado optimista.

7. ¿Por qué es necesario estratificar los cortes de los datos en un problema de clasificación con clases desbalanceadas?

La estratificación es un paso fundamental cuando se tiene clases desbalanceadas porque garantiza que la proporción de las clases se mantenga idéntica tanto en el conjunto de entrenamiento como en el de prueba.

8. Describa la diferencia entre *k-fold cross validation* y *stratified k-fold cross validation*.

|                        | K-Fold Estándar                                | Stratified K-Fold                         |
|------------------------|------------------------------------------------|-------------------------------------------|
| Distribución de clases | Aleatoria (puede variar entre folds).          | Preservada (idéntica en todos los folds). |
| Uso ideal              | Datasets grandes y balanceados.                | Datasets pequeños o desbalanceados.       |
| Riesgo de sesgo        | Alto en clases minoritarias.                   | Muy bajo.                                 |
| Varianza del error     | Puede ser mayor debido a folds inconsistentes. | Tiende a ser menor y más estable.         |

9. Ilustre con un ejemplo numérico sencillo (10 datos divididos en 5 particiones) cómo funciona la validación cruzada.

| Iteración | Datos de Entrenamiento (Train) | Datos de Validación (Test) |
|-----------|--------------------------------|----------------------------|
| 1         | {3,4,5,6,7,8,9,10}             | {1,2}                      |
| 2         | {1,2,5,6,7,8,9,10}             | {3,4}                      |
| 3         | {1,2,3,4,7,8,9,10}             | {5,6}                      |
| 4         | {1,2,3,4,5,6,9,10}             | {7,8}                      |
| 5         | {1,2,3,4,5,6,7,8}              | {9,10}                     |

## Herramientas computacionales

10. Explique con sus palabras qué significa que un modelo esté:

a) Sobreajustado (*overfitting*).

Un modelo está sobreajustado cuando aprende demasiado bien los datos de entrenamiento, incluyendo ruido o patrones irrelevantes. En ese caso, funciona muy bien con entrenamiento, pero falla con datos nuevos.

b) Subajustado (*underfitting*)

Un modelo está subajustado cuando es demasiado simple y no logra capturar la relación real entre las variables. Entonces rinde mal tanto en entrenamiento como en prueba.

11. Dibuje un gráfico de curvas de aprendizaje (error vs tamaño de conjunto de entrenamiento) que ilustre ambos casos.

