




Carrera de Ciencia de Datos
e Inteligencia Artificial
FACULTAD DE INGENIERÍA

Principios de modelado y validación de redes neuronales artificiales

Arquitectura Fundamental



El funcionamiento del MLP (multilayer perceptrón) se asemeja a un un grafo no cíclico, donde la información fluye en una sola dirección (hacia adelante).

$$a_j = \sum_{i=0}^D w_{ji}^{(1)} x_i$$

↓

$$y_k(\mathbf{x}, \mathbf{w}) = f \left(\sum_{j=0}^M w_{kj}^{(2)} h \left(\sum_{i=0}^D w_{ji}^{(1)} x_i \right) \right)$$

Capacidad de Generalización


Una red neuronal de dos capas (MLP) es capaz de aproximar cuatro funciones diferentes:

(a) $f(x) = x^2$, **(b)** $f(x) = \sin(x)$, **(c)** $f(x) = |x|$, y **(d)** $f(x) = H(x)$, donde $H(x)$ es la función escalón.

En cada caso, se han muestreado uniformemente N puntos de datos, representados en color azul, en el intervalo $(-1; 1)$. Estos puntos de datos se utilizan para entrenar una red de dos capas con tres nodos ocultos, con funciones de activación tanh y unidades de salida lineales.

Las salidas de los tres nodos ocultos se grafican con las curvas de líneas entrecortadas.

La salida de cada red se muestra mediante la curva roja.



Funciones de activación

Activación no lineal

- **Sigmoide:** Comprime cualquier valor al rango 0, 1. Se usa a la capa de salida, generalmente en problemas de clasificación binaria. Sufre de saturación, cuando los valores son muy altos o bajos, el gradiente es casi cero, deteniendo el aprendizaje.
- **Tanh** (Tangente Hiperbólica): Similar a la sigmoide pero con rango -1, 1. Al estar centrada en cero, suele ayudar a que la convergencia sea más rápida en capas ocultas.
- **Softmax:** Convierte las salidas de la red en una distribución de probabilidad que suma 1. Se utiliza exclusivamente en la capa de salida para clasificación multiclase.

Representación matemática

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$\frac{e^{z_i}}{\sum e^{z_j}}$$

La función de activación es un cálculo matemático aplicado a la salida de una neurona que genera una reacción mayor o menor, con base en la información recibida “criterio que define cómo responder ante la suma de estímulos”.

Funciones de Costo

Regresión

Error Cuadrático Medio (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Penaliza fuertemente los errores grandes debido al cuadrado, lo que obliga al modelo a ajustarse a los valores atípicos.

Clasificación

Entropía Cruzada Binaria (Binary Cross-Entropy)

$$J(\theta) = -\frac{1}{n} \sum [y \ln(\hat{y}) + (1 - y) \ln(1 - \hat{y})]$$

Mide qué tan "cerca" está la distribución de probabilidad predicha de la etiqueta real (0 o 1).C.


Entropía Cruzada Categórica, se usa junto con Softmax para clasificación de múltiples categorías (ej. reconocer si una imagen es un perro, gato o ave).

La función de costo permite comparar el resultado de la predicción /clasificación con la salida esperada.

Entrenamiento y Propagación de errores

Regla de la Cadena y Backpropagation

El entrenamiento es una aplicación iterativa de la regla de la cadena del cálculo multivariado. Calculamos cómo cambia el error respecto a cada peso (w), descomponiendo las derivadas capa por capa desde la salida (output) hacia la entrada (input).



Backpropagation es el algoritmo que asigna culpa a cada neurona por el error final .

¿Cómo funciona la retropropagación?

Consta de dos fases principales:

1. Propagación hacia adelante (Forward Pass):


1. Los datos de entrada se envían a través de las neuronas, capa por capa, hasta obtener una salida final.
2. La salida obtenida se compara con el valor real (etiqueta) y se calcula el error usando una función de pérdida (*loss function*), como el error cuadrático medio o la entropía cruzada.

2. Propagación hacia atrás (Backward Pass):

1. El error se retropropaga desde la salida hacia las capas anteriores.
2. Utilizando el **descenso de gradiente** y la **regla de la cadena**, se calculan las derivadas parciales del error con respecto a cada peso en la red.
3. Los pesos se ajustan para reducir el error, moviéndose en la dirección contraria al gradiente.

Regla de la cadena

Ilustraciones




$$\frac{dz}{dt} = \frac{\partial z}{\partial x} \cdot \frac{dx}{dt} + \frac{\partial z}{\partial y} \cdot \frac{dy}{dt}$$

Notación:

$$\frac{\partial z}{\partial x} = \frac{\partial f}{\partial x}, \quad \frac{\partial z}{\partial y} = \frac{\partial f}{\partial y}$$

Árbol de dependencia



Ejercicio 1

Crear una Red Neuronal artificial convencional, tipo Feedforward.

<https://colab.research.google.com/drive/1d80w2hdgHPN7p5RaDsBYosNKmFiN-b0Z?usp=sharing>

Responder a las siguientes preguntas:

Cual es la estructura de la red, qué valores se han colocado en la entrada?, cómo cambian los pesos?, cuál es el propósito de la estructura creada.

Ejercicio 2

Prueba con **TensorFlow Playground**, herramienta creada por Google para visualizar el comportamiento de una red neuronal artificial.

Tareas a ejecutar y luego comentar los resultados:

- Elegir datos
- Añadir capas ocultas
- Observar cómo la regla de la cadena actualiza los pesos (las líneas se vuelven más gruesas o cambian de color).

<https://playground.tensorflow.org/#activation=tanh&batchSize=10&dataset=circle®Dataset=reg-plane&learningRate=0.03®ularizationRate=0&noise=0&networkShape=4&seed=0.46445&showTestData=false&discretize=false&percTrainData=50&x=true&y=true&xTimesY=false&xSquared=false&ySquared=false&cosX=false&sinX=false&cosY=false&sinY=false&collectStats=false&problem=classification&initZero=false&hideText=false>

Actividade práctica-experimental

Experimentar con TENSORFLOW PLAYGROUND y documentar los resultados obtenidos, con el propósito de explicar lo siguiente:

1. Estructura Feed Forward.
2. Función de los **nodos ocultos**.
3. Resultados de aplicar la **función de activación**.

En cada punto agregar una captura de pantalla y al final incorporar sus conclusiones.

Material basado en la bibliografía
declarada en el sílabo.
