

MACHINE LEARNING

|

APRENDIZAJE DE MÁQUINA

Lida Barba Maggi, Ing. Ph.D.

Antecedentes

1943

1ra. ANN

1949

Regla de
Aprendizaje
Hebbiano

1950-1960

- Perceptrón
- Adaline

1969-1980

- Algoritmo
BP,
- MLP

1990 -> Redes
recurrentes

2006 Deep
Learning

2012
Convolutional
ANN

Antecedentes

En 1943 McCulloch y Pitts proponen la Primera Red Neuronal, la que fue diseñada para usar pesos fijos.

En 1949, Hebb desarrolla la Primera regla de aprendizaje, conocida como Aprendizaje Hebbiano, en la regla se determina que si dos neuronas se activan al mismo tiempo, la fuerza entre ellas incrementa.

En el año 1960 Widrow y Hoff crean ADALINE, una red neuronal artificial cuyas siglas corresponde a ADaptive LINEar Element, la que contenía una sola capa de n neuronas con n valores de salida basada en una función lineal. En el año 1988 Winter y Widrow, desarrollan MADALINE Rule II -MRII, un nuevo algoritmo para redes feedforward multicapa basado en neuronas ADALINE.


Entre los años 1950 y 1960, varios investigadores, entre ellos Block, Minsky, Papert y Rosenblat, crean el Perceptrón, un modelo de red neuronal que converge con los pesos correctos, Weight Adjustment fue el algoritmo de aprendizaje, cuyo objetivo era contar con programas que podían pensar.

Antecedentes (cont.)

En 1969 Minsky y Papert, determinan que el Perceptrón no podía aprender con funciones no lineales. La limitación del Perceptrón, paralizó durante mucho tiempo las investigaciones en el campo de las RNA, Paul Werbos en el año 1974, plantea una solución inicial a este problema, relacionada con un algoritmo que permitiera obtener y actualizar los pesos intermedios del sistema, conocido posteriormente como backpropagation.

Entre los años 1980 y 1986, el grupo PDD integrado por Rumelhart y McClland, publican el libro Parallel Distributed Processing: Explorations in the Microstructure of Cognition, “redescriben” un algoritmo similar al de Werbos, conocido como “retropropagación de errores” o “backpropagation”, en el libro se demuestra que las redes neuronales multicapa y no lineales son mucho más robustas y pueden utilizarse para una amplia gama de funciones.

ANN: Su Inspiración




Las ANN han sido inspiradas en el funcionamiento del sistema nervioso humano.

El sistema nervioso y el sistema endócrino controlan las funciones del organismo, el sistema nervioso está compuesto básicamente de células especializadas cuya función es recibir estímulos sensitivos y transmitirlos a los órganos efectores, sean musculares o glandulares; los estímulos sensitivos que se originan fuera o dentro del organismo se correlacionan dentro del sistema nervioso y los impulsos eferentes son coordinados de modo que los órganos efectores funcionan juntos y en armonía para el bienestar del individuo, en las especies superiores tiene la capacidad de almacenar información, cuando es apropiada, se integra con otros impulsos nerviosos y se canaliza hacia la vía eferente común (Snell, 2006).



Relación entre una neurona biológica y una neurona artificial

La divergencia y la convergencia son funciones de la circuitería neural, cada neurona envía impulsos a muchas otras neuronas (divergencia), y recibe impulsos de muchas neuronas (convergencia).


Las conexiones feedback, a partir de las conexiones sinápticas pueden ser excitatorias o inhibitorias, los circuitos facilitan los sistemas de control, siendo estos feedback positivo o negativo, evidentemente una red neuronal artificial no representa la realidad, debido a la gran complejidad de la neuroanatomía.




Relación entre una neurona biológica y una neurona artificial (cont.)



Relación entre una neurona biológica y una neurona artificial (cont.)



Estructura típica de una ANN



$$y_k = \varphi\left(\sum_{j=1}^m w_{kj}x_j\right)$$

La función de activación es generalmente no lineal. Típicamente se usa una función sigmoideal:

$$\varphi(x) = \frac{1}{1 + e^{-x}}$$

Estructura típica de una ANN (cont.)

Una ANN-MLP típica, está conformada por tres niveles o capas: de entrada, oculta y de salida. Las conexiones entre las capas poseen determinados pesos.

Las entradas (inputs) son denotadas por $x_1, \dots, x_m$.


Los pesos (weights) son denotados por $w_{k1}, \dots, w_{km}$. Ciertos modelos usan además una entrada tipo bias θ cuyo valor es usualmente 1, su uso es arbitrario (en ciertos problemas se ha observado un aceleramiento de la convergencia de la red).

En una ANN con propagación aditiva, la salida (output) es denotada por y_k y se representa por medio de:

$$y_k = \varphi \left(\sum_{j=1}^m w_{kj} x_j \right)$$

Topologías de las redes neuronales artificiales (por dirección del flujo)

Las topologías comunes en una red neuronal son feedforward (FNN) y recurrente (RNN), sin descartar el uso de topologías mixtas. El peso de la conexión de las neuronas es el principal componente directamente determinado por la topología, también la velocidad de los cálculos es afectada por la topología de la red. En términos de intercambio de datos, por ejemplo una interacción recurrente tiende a retrasar la respuesta de la red.



A mostly complete chart of Neural Networks

©2016 Fjodor van Veen - asimovinstitute.org

Backfed Input Cell

Input Cell

Noisy Input Cell

Hidden Cell

Probabilistic Hidden Cell

Spiking Hidden Cell

Output Cell

Match Input Output Cell

Recurrent Cell

Memory Cell

Different Memory Cell

Kernel

Convolution or Pool

Perceptron (P)



Feed Forward (FF)




Radial Basis Network (RBF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)



Gated Recurrent Unit (GRU)




Auto Encoder (AE)



Variational AE (VAE)



Denoising AE (DAE)



Sparse AE (SAE)



Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)



Deep Belief Network (DBN)




Multilayer Perceptron (MLP)

El MLP surge en la década de 1980, como una solución para superar el problema detectado en el Perceptrón Simple, en cuanto a su imposibilidad de aprender clases de funciones no linealmente separables.

El MLP constituye el modelo de ANN más utilizado para la resolución de problemas de ingeniería. Varias investigaciones han demostrado su condición de aproximador universal de funciones.


La red neuronal conocida como Perceptrón Multicapa es un modelo neuronal con “propagación hacia adelante”, feedforward, caracterizada por su organización en capas de celdas disjuntas, de forma que ninguna salida neuronal constituye una entrada para las neuronas de la misma capa o de capas previas, evitándose así las conexiones “hacia atrás” o recurrentes (Flores & Fernández, 2008).

Multilayer Perceptron (cont.)



Aunque una red puede ser construida con un número indeterminado de capas ocultas, varias investigaciones han demostrado que la inclusión de un único nivel de neuronas ocultas resulta suficiente para que la red logre converger (aproximar el valor deseado).

Algoritmos de Aprendizaje



Basados en el
cálculo diferencial

Gradient Descent



Inspirados

Nature: fishes, ants, birds,
bees, genetic, ...

Tipos de aprendizaje

Aprendizaje Supervisado	Aprendizaje sin Supervisión	Aprendizaje Reforzado
- Clasificación - Regresión - Ranking	- Clustering - Segmentación - Reducción de Dimensiones	- Procesos de Decisión - Sistemas de Recompensas - Sistemas de Recomendación

Actividad en clase: ubica en padlet la aplicación con el tipo de aprendizaje

- | | |
|----------------------------------|--|
| 1. Meaningful Compression | 11. Predicción de rendimiento académico |
| 2. Descubrimiento de estructuras | 12. Expectativa de vida |
| 3. Feature elicitation | 13. Sistemas de recompensas |
| 4. Visualización Big Data | 14. Reducción de dimensionalidad |
| 5. Clasificación de imágenes | 15. Segmentación de mercado |
| 6. Retención de clientes | 16. Marketing dirigido |
| 7. Diagnóstico de enfermedades | 17. Sistemas de recomendación de películas |
| 8. Detección de spam | 18. Aprendizaje adaptado |
| 9. Pronóstico del clima | 19. Autos autónomos |
| 10. Estimación de parámetros | 20. Predicción de accidentes de tránsito |
| | 21. IA que juega |
| | 22. Visión en juegos |
| | 23. Recomendación de estrategias de ventas |
| | 24. Traducción de lengua |


Instrucciones:

La aplicación que debes elegir, deberá coincidir con el último dígito de tu día y año de nacimiento, ejemplo

Día 22


Año 2000

Las aplicaciones a ubicar en el padlet son: 2, 12, 22, 10, 20





"Imagen generada mediante IA (Gemini 3 Flash) basada en el prompt del docente autor sobre el ecosistema de Machine Learning para Ingeniería en Ciencia de Datos."


Fundamentos Matemáticos



Geometría de los datos



FUNDAMENTOS MATEMÁTICOS DEL MACHINE LEARNING: GUÍA PARA INGENIERÍA EN CIENCIA DE DATOS



"Imagen generada mediante IA (Gemini 3 Flash) basada en el prompt del docente autor sobre el ecosistema de Machine Learning para Ingeniería en Ciencia de Datos."

Herramientas computacionales

1. Núcleo de Programación: Python / R

2. Librerías /Frameworks

- NumPy: Manejo de **tensores y álgebra lineal computacional** de alto rendimiento.
- Pandas: Manipulación de **estructuras de datos** (dataframes), leer archivos (CSV, Excel, etc.), filtrar, limpiar y analizar datos.
- Scikit-Learn: Herramienta para el **Machine Learning** "clásico" (Regresiones, SVM, Random Forest, Clustering).
- PyTorch: Framework para **Deep Learning**.
- TensorFlow / Keras: Usada en entornos de producción industrial por su escalabilidad y herramientas de despliegue como **TensorFlow Serving**.

3. Entornos de Desarrollo (IDE) y Notebooks: Jupyter Notebook / Lab, Google Colab, VS Code.

4. Visualización de Datos: Matplotlib & Seaborn.

Práctica propuesta

1. Solicita a la IA generativa (Python), el código base para HOLA MUNDO EN MACHINE LEARNING.
2. Probarlo en GOOGLE COLAB.
3. Analizar e identificar el proceso que se realice en las líneas del código.
4. Compartirlo en la clase tutorial.

Recuerda que en la clase tutorial también podrás consultar con la Docente Tutora sobre las dificultades o inquietudes con respecto a los paquetes de aprendizaje, actividades prácticas y autónomas.

Material basado en la bibliografía declarada en el sílabo y en:

Flórez, R. Fernández. (2008). J. Las Redes Neuronales Artificiales. España: Netbiblio, 19-61.

Freeman, J., Skapura, D. (1991). Neural Networks Algorithms, Applications, and Programming Techniques. USA: Addison-Wesley.

Snell, R. (2006). Clinical Neuroanatomy. 6th Edition. USA: Lippincott Williams & Wilkins.

Géron, A. (2023). Aprende machine learning con Scikit-Learn, Keras y TensorFlow: Conceptos, herramientas y técnicas para conseguir sistemas inteligentes (3.^a ed.). Anaya Multimedia.

Python Deep Learning : Introducción práctica con Keras y TensorFlow 2 Jordi Torres