



UNIDAD 2

Modelos avanzados de clasificación y regresión.

TEMA 1:

Modelos lineales y no lineales.

Descripción:

La Unidad 2 profundiza en los modelos supervisados avanzados, fundamentales en el aprendizaje automático moderno.

Se exploran métodos lineales y no lineales, incluyendo regresión polinómica, logística y técnicas de regularización, que amplían la capacidad predictiva y reducen el sobreajuste. Además, se abordan algoritmos potentes como Máquinas de Soporte Vectorial y redes neuronales básicas, que permiten modelar relaciones complejas en los datos.

Finalmente, se estudian árboles de decisión, métricas multiclase y estrategias para interpretar errores, aplicando los conocimientos en datasets reales. Esta unidad fomenta la comprensión crítica y el dominio práctico para enfrentar problemas predictivos actuales.

Machine Learning 1

PERIODO ACADÉMICO 2026-1S

TABLA DE CONTENIDO

Tema 1. Modelos lineales y no lineales.....	2
1.1. Regresión lineal, polinómica y regularizada.	2
1.2. Regresión logística y Softmax.	5
1.3. Máquinas de Soporte Vectorial (SVM).	7
1.4. Redes neuronales básicas.	10
Bibliografía	14

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

Tema 1. Modelos lineales y no lineales.

Los modelos lineales y no lineales constituyen la base del aprendizaje supervisado y permiten abordar una amplia gama de problemas de predicción y clasificación. Los enfoques lineales, como la regresión lineal y sus variantes polinómica y regularizada, ofrecen interpretabilidad y eficiencia al estimar relaciones entre variables, aunque requieren supuestos estadísticos que rara vez se cumplen en la práctica (James et al., 2023; Géron, 2023).

En clasificación, la regresión logística y su extensión multiclase mediante Softmax permiten modelar probabilidades predictivas, siendo fundamentales en ciencias aplicadas y en tareas de referencia como el reconocimiento de patrones (Hosmer et al., 2023; Murphy, 2023). Cuando las fronteras de decisión son más complejas, las Máquinas de Soporte Vectorial (SVM) destacan por su formulación geométrica y el uso de funciones kernel que proyectan los datos a espacios de mayor dimensión para lograr separaciones más robustas. Por otro lado, las redes neuronales artificiales representan un paradigma no lineal flexible y escalable: su capacidad para aprender representaciones jerárquicas les permite resolver problemas intratables con modelos lineales simples (Raschka et al., 2022). En conjunto, estos métodos ilustran el dilema sesgo-varianza y subrayan la importancia de equilibrar interpretabilidad, complejidad y capacidad de generalización en aplicaciones reales.

1.1. Regresión lineal, polinómica y regularizada.

La **regresión lineal** constituye el punto de partida de los modelos supervisados de predicción.

Su propósito es estimar una variable de salida y como combinación lineal de un conjunto de predictores $x_1, x_2, x_3, \dots, x_p$

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

$$\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j$$

Donde β_0 es el intercepto, β_j los coeficientes asociados a cada predictor, y el ajuste se logra minimizando el error cuadrático medio (MSE). La solución matricial clásica es

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

siempre que la matriz X tenga rango completo (James et al., 2023).

La potencia pedagógica de este modelo radica en su interpretabilidad: los coeficientes muestran cómo cambia la variable dependiente por unidad de cambio en cada predictor. No obstante, la regresión lineal supone relaciones estrictamente lineales, independencia de los errores, homocedasticidad y normalidad de residuos, condiciones que rara vez se cumplen en problemas reales.

Cuando la relación entre las variables no es lineal, la **regresión polinómica** amplía la expresividad del modelo introduciendo potencias de los predictores:

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d$$

Esto permite capturar curvaturas y tendencias complejas, aunque al incrementar el grado d puede generar el riesgo de sobreajuste. Desde una perspectiva didáctica, este caso ilustra la tensión entre sesgo y varianza: un polinomio de grado bajo tiene alto sesgo, mientras que uno de grado alto puede memorizar el ruido de los datos (Raschka et al., 2022).

La regularización constituye una estrategia esencial para controlar esta complejidad. **Ridge (L2)** penaliza la suma de los cuadrados de los coeficientes:

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

$$RSS + \lambda \sum_{j=1}^p \beta_j^2$$


mientras que **Lasso (L1)** penaliza la suma de los valores absolutos:

$$RSS + \lambda \sum_{j=1}^p |\beta_j|$$

RSS representa la suma de los residuos al cuadrado: $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$, λ es el parámetro de regularización que controla la intensidad de la penalización.

Ridge encoge los coeficientes y es útil frente a colinealidad, mientras que Lasso puede anular algunos coeficientes, funcionando como un mecanismo de selección de variables (Géron, 2023). El hiperparámetro λ regula la magnitud de la penalización y se ajusta mediante validación cruzada.

Figura 1. Modelos de regresión equilibran la complejidad y la interpretabilidad



Fuente: Elaboración propia

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

1.2. Regresión logística y Softmax.

A diferencia de la regresión lineal, **la regresión logística** está diseñada para resolver problemas de clasificación, no de predicción de valores continuos.

En el caso binario ($y \in \{0,1\}$), la probabilidad de que un ejemplo pertenezca a la clase positiva se modela con la función sigmoide $\sigma(z)$:

$$P(y = 1|x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$$

donde x es un vector de características (inputs o predictores), w es un vector de coeficientes o pesos asociados a cada característica. Indican cuánto aporta cada variable x_j a la predicción, b es el sesgo (bias o intercepto). Ajusta el modelo desplazando la curva sigmoide y $\hat{p}_i$ es la probabilidad estimada de que la observación i pertenezca a la clase positiva.

La función de pérdida asociada es **la entropía cruzada binaria** $L(w)$ se expresa continuación:

$$L(w) = - \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

donde n es el número total de observaciones, y_i es la etiqueta real de la observación i (0 o 1), $\hat{p}_i$ es la probabilidad predicha para la clase positiva. La minimización de $L(w)$ se alcanza mediante optimización iterativa. Los coeficientes se interpretan en términos de **log-odds**, lo que convierte a la

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales


regresión logística es una herramienta muy valorada en ciencias de la salud, economía y marketing (Hosmer et al., 2023).

Cuando el problema incluye más de dos clases, el **modelo Softmax** generaliza la regresión logística. Para K clases, la probabilidad $P(y = k|x)$ representan que una observación pertenezca a la clase k :

$$P(y = k|x) = \frac{e^{-(w_k^T x + b_k)}}{\sum_{j=1}^K e^{-(w_j^T x + b_j)}}$$

donde w_k es un vector pesos asociados a la clase k , b_k es el sesgo correspondiente a la clase k . Cada observación recibe un vector de probabilidades que suma uno, asignándose la clase con mayor valor. Softmax es la capa de salida estándar en redes neuronales y ha demostrado gran eficacia en tareas de clasificación de imágenes y texto (Murphy, 2023).

Figura 2. Comparación entre Regresión Logística Binaria y Softmax



Fuente: Elaboración propia

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

1.3. Máquinas de Soporte Vectorial (SVM).

Imagina que tienes puntos de dos colores en un plano y deseas trazar una línea que los separe. Muchas líneas podrían hacerlo, pero **no todas generalizan igual** cuando aparezcan puntos nuevos.

Las **Máquinas de Soporte Vectorial (SVM)** resuelven este dilema buscando el **hiperplano** que deja el **mayor margen** entre las clases. Ese margen—la distancia a los puntos más cercanos de cada clase, llamados **vectores de soporte**—actúa como “colchón de seguridad”: cuanto mayor, más robusta suele ser la separación frente a ruido y nuevas observaciones.

En su forma más simple, una SVM lineal aprende una función de decisión afín

$$f(x) = w^T x + b$$

donde w es el **vector de pesos** (normal al hiperplano) y b el **sesgo**. La **clase predicha** depende del **signo** de $f(x)$. Para obtener el margen máximo y permitir algunos errores de entrenamiento cuando los datos no son perfectamente separables, el aprendizaje resuelve:

$$\min_{w, b, \{\xi_i\}} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

sujeto a restricciones que garantizan la separación con **holguras** ξ_i , es decir, permitiendo ciertos incumplimientos controlados en la clasificación. El hiperparámetro C regula el compromiso como se aprecia en la Figura 3 y se describe a continuación:

- C grande, penaliza fuertemente los errores de entrenamiento, lo que puede conducir a un posible sobreajuste (margen más estrecho, fronteras muy “rígidas”).

Regresión lineal

Regresión logística


Máquinas de Soporte

Redes neuronales

- C pequeño, tolera más errores de clasificación a cambio de un margen más amplio con riesgo de subajuste si es excesivamente bajo.

Muchos problemas **no** son linealmente separables en el espacio original de características. Las SVM solucionan esto con **funciones kernel** que **proyectan implícitamente** los datos a un espacio de mayor dimensión donde una separación lineal sí puede existir. Gracias al “**truco del kernel**”, nunca calculamos esa proyección de forma explícita: solo evaluamos similitudes. Lo kernels frecuentes son:

Figura 3. Penalización de errores y ajuste del modelo en SVM



Fuente: Elaboración propia

- **Lineal:** cuando una frontera plana es suficiente.
- **Polinomial:** introduce interacciones y curvaturas de orden mayor.
- **RBF (Radial Basis Function):** muy usado; crea fronteras suavemente curvas alrededor de los datos.
- **Sigmoide:** emparentado con neuronas artificiales, hoy menos popular que RBF.

Con **RBF**, aparece el hiperparámetro γ (gamma), que controla el “alcance” de cada muestra en la frontera:

- γ **alto**, tiene influencia localizada y fronteras muy onduladas (**varianza alta**, riesgo de sobreajuste).

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

- γ bajo, posee influencia amplia y fronteras suaves (**sesgo alto**, riesgo de subajuste).

En el uso de las SVM, una regla didáctica fundamental consiste en **ajustar los hiperparámetros C y γ** de manera conjunta, preferentemente mediante **validación cruzada**. Esto se debe a que ambos parámetros interactúan entre sí: C regula el equilibrio entre el margen amplio y los errores en el conjunto de entrenamiento, mientras que γ controla la complejidad de la frontera de decisión cuando se emplea el kernel RBF. No existe un valor universalmente mejor para todos los problemas; su elección depende de la naturaleza de los datos, el nivel de ruido presente y el tamaño del dataset.

Figura 4. Funciones Kernel disponibles para SVM



Fuente: Elaboración propia

Las aplicaciones típicas de las SVM son numerosas y se han consolidado en distintos campos. En **clasificación de texto e imágenes**, se utilizan con representaciones como la bolsa de palabras o descriptores visuales para detectar patrones complejos. En el ámbito del **diagnóstico médico**, permiten apoyar tareas críticas como la detección de tumores a partir de imágenes biomédicas. En **bioinformática**, se emplean para analizar datos de expresión génica o estudios proteómicos, donde la dimensionalidad de los datos es elevada. Asimismo, han mostrado gran eficacia en la **detección de fraude financiero**, donde identifican transacciones con patrones anómalos que podrían indicar actividades ilícitas.

1.4. Redes neuronales básicas.

Las **redes neuronales artificiales (RNA)** se inspiran en la neurona biológica, pero operan con una **formulación matemática controlable y entrenable**. Su fuerza radica en **aprender representaciones no lineales** de los datos componiendo transformaciones simples en **capas**. Así, problemas intratables para modelos lineales (como XOR) se vuelven abordables.

Cada neurona realiza una combinación lineal con sesgo y la pasa por una **función de activación**:

$$z = \sum_{i=1}^p w_i x_i + b, \quad a = \phi(z)$$

Aquí $x = (x_1, \dots, x_p)$ es el vector de entrada, $w = (w_1, \dots, w_p)$ los **pesos**, b el **sesgo**, y a la **activación** resultante. La no linealidad $\phi(\cdot)$ es imprescindible:

- **Sigmoide**, $\sigma(z) = 1/(1 + e^{-z})$, es útil para probabilidades (binaria), pero **se satura**.
- **Tanh**, es centrada en 0, ayuda a la estabilidad.
- **ReLU**, $\max(0, z)$, es estándar en redes modernas por su **eficiencia** y mejor propagación de gradientes.

El estudio de las redes neuronales básicas, en particular el Perceptrón Multicapa (MLP), constituye un pilar esencial para comprender la evolución del aprendizaje automático moderno. Una red típica se organiza en tres niveles: la capa de entrada, que recibe el vector de características x ; una o varias capas ocultas, que generan representaciones intermedias mediante la aplicación de funciones de activación; y la capa de salida, que produce la predicción final $\hat{y}$ como se aprecia en la Figura 5. Cada capa puede describirse matemáticamente como

$$a^{(l)} = \phi(W^{(l)}a^{(l-1)} - b^{(l)})$$

donde $W^{(l)}$ y $b^{(l)}$ representan los parámetros entrenables de la capa l (Géron, 2023).

Regresión lineal

Regresión logística


Máquinas de Soporte

Redes neuronales

El proceso de aprendizaje se lleva a cabo mediante **retropropagación** y optimización iterativa. La retropropagación aplica la regla de la cadena para calcular los gradientes de la función de pérdida (entropía cruzada en clasificación o MSE en regresión) respecto a cada parámetro. Posteriormente, algoritmos como el descenso por gradiente estocástico (SGD) o Adam ajustan los valores de $W^{(l)}$ y $b^{(l)}$, en ciclos denominados **épocas**, hasta lograr una reducción del error (Raschka, Liu & Mirjalili, 2022).

Para garantizar la convergencia, es fundamental escalar las variables de entrada, además de aplicar técnicas de regularización como *early stopping*, *weight decay* o *dropout*.

Figura 5. Procesamiento de datos en Redes Neuronales



Fuente: Elaboración propia

Desde una perspectiva didáctica, la comprensión de la capacidad del modelo y la relación sesgo-varianza es central. Las **redes con pocas neuronas** tienden a **subajustar**, mostrando alto sesgo, mientras que las redes grandes pueden **sobreajustar** si no se regulan, reflejando alta varianza. La calibración de probabilidades predictivas es otro aspecto relevante, pues en aplicaciones sensibles, como diagnóstico médico, la

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

confiabilidad de las predicciones es tan importante como la exactitud (Murphy, 2023).

En cuanto a las aplicaciones, las redes neuronales básicas son versátiles: permiten resolver problemas de **clasificación de imágenes** (ej. MNIST, CIFAR), **procesamiento de texto** (análisis de sentimientos, clasificación de noticias), predicción de series temporales y reconocimiento de voz. Un ejemplo clásico reside en la limitación de un perceptrón simple que no puede separar el problema XOR, pero un MLP con una capa oculta y función ReLU sí lo consigue, lo que ilustra de manera intuitiva el poder de la composición de funciones no lineales (Benítez, Cencerrado, Escudero & Kanaan, 2025).

Al comparar las redes neuronales con las Máquinas de Soporte Vectorial (SVM), emergen diferencias notables. **Las SVM son especialmente útiles en datasets pequeños o medianos**, donde una buena ingeniería de características y un kernel RBF bien ajustado ofrecen resultados robustos y fácilmente interpretables. En contraste, los **MLP brillan cuando existe abundancia de datos y la complejidad de los patrones requiere arquitecturas más profundas y flexibles**. En términos prácticos, las SVM tienden a ser más rápidas de entrenar en escenarios con pocos atributos, mientras que las redes neuronales pueden integrar el preprocesamiento y el modelado de manera conjunta en contextos de mayor escala (scikit-learn developers, 2024).

Finalmente, es importante advertir sobre los errores más comunes. Entre ellos se encuentran no escalar las variables antes de entrenar, seleccionar hiperparámetros utilizando el conjunto de prueba —lo que conduce a una visión optimista del rendimiento—, o confundir el desempeño en entrenamiento con la capacidad de generalizar. Como buenas prácticas, se recomienda siempre usar validación cruzada, interpretar los modelos de acuerdo con sus particularidades (vectores de soporte en SVM, curvas de entrenamiento en MLP) y discutir en el aula el dilema sesgo-varianza como un criterio transversal para elegir modelos.

En conclusión, las redes neuronales básicas y las SVM representan dos enfoques complementarios del aprendizaje supervisado. Mientras que las primeras simbolizan la flexibilidad y el poder de aproximación universal, las segundas ofrecen elegancia geométrica y eficiencia en problemas

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

de menor escala. Entender sus fundamentos, limitaciones y aplicaciones prepara a los estudiantes no solo para usar herramientas, sino para tomar decisiones informadas en proyectos reales de ciencia de datos.

Regresión lineal

Regresión logística

Máquinas de Soporte

Redes neuronales

Bibliografía

Benítez, R., Cencerrado, A., Escudero, G., & Kanaan, S. (2025). *Inteligencia artificial avanzada*. FUOC.

Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.). O'Reilly.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2023). *Applied Logistic Regression* (4th ed.). Wiley.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python* (2nd ed.). Springer.

Müller, A. C., & Guido, S. (2017). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media.

Murphy, K. P. (2023). *Probabilistic Machine Learning: Advanced Topics*. MIT Press.

Raschka, S., Liu, Y., & Mirjalili, V. (2022). *Machine Learning with PyTorch and Scikit-Learn*. Packt.

scikit-learn developers. (2024). *User Guide v1.4–1.5* (Linear models; SVM; Neural networks; Model selection).

scikit-learn developers. (2024). *User Guide v1.4–1.5* (Model evaluation and metrics).