



UNIDAD 2

Modelos avanzados de clasificación y regresión.

TEMA 2:

Árboles de decisión y métricas avanzadas.

Descripción:

La Unidad 2 profundiza en los modelos supervisados avanzados, fundamentales en el aprendizaje automático moderno.

Se exploran métodos lineales y no lineales, incluyendo regresión polinómica, logística y técnicas de regularización, que amplían la capacidad predictiva y reducen el sobreajuste. Además, se abordan algoritmos potentes como Máquinas de Soporte Vectorial y redes neuronales básicas, que permiten modelar relaciones complejas en los datos.

Finalmente, se estudian árboles de decisión, métricas multiclase y estrategias para interpretar errores, aplicando los conocimientos en datasets reales. Esta unidad fomenta la comprensión crítica y el dominio práctico para enfrentar problemas predictivos actuales.

Machine Learning 1

PERIODO ACADÉMICO 2026-1S

TABLA DE CONTENIDO

Tema 2. Árboles de decisión y métricas avanzadas.....	2
2.1. Árboles de decisión: criterios de partición.....	2
2.2. Métricas para multiclase.....	5
2.3. Interpretación y análisis de errores	7
2.4. Aplicaciones prácticas en datasets reales.....	9
Bibliografía	12

Tema 2. Árboles de decisión y métricas avanzadas.

Este tema constituye un puente entre la construcción de modelos predictivos y la evaluación crítica de su desempeño. Los árboles de decisión ofrecen una estructura jerárquica que traduce problemas complejos en secuencias de reglas comprensibles, lo cual facilita tanto la predicción como la interpretación. Su funcionamiento se basa en criterios de partición, como la ganancia de información y el índice de Gini, que buscan dividir los datos en regiones homogéneas y permiten discutir de manera pedagógica conceptos centrales como el sesgo y la varianza. Sin embargo, entrenar un modelo no basta: es fundamental comprender cómo evaluar sus resultados en escenarios reales. En este sentido, las métricas multiclase —precisión, recall, F1-score, ROC-AUC o log-loss— trascienden la simple exactitud, ofreciendo una mirada más equilibrada cuando las clases están desbalanceadas. Además, la interpretación y el análisis de errores revelan no solo las limitaciones del modelo, sino también oportunidades de mejora y sesgos en los datos. Finalmente, trabajar con datasets reales como Kaggle o UCI transforma la teoría en práctica, mostrando que el aprendizaje automático no es solo una técnica matemática, sino también una herramienta para la toma de decisiones en ámbitos como la salud, las finanzas o la seguridad digital.

2.1. Árboles de decisión: criterios de partición.

Los **árboles de decisión** son modelos de aprendizaje supervisado que buscan dividir el espacio de los datos en regiones cada vez más homogéneas con respecto a la variable objetivo.

La idea pedagógica central es que un árbol funciona como un conjunto de **preguntas secuenciales**: en cada nodo se aplica una condición sobre una variable predictora, y de acuerdo con la respuesta, se sigue una rama u otra.

Cada nodo interno del árbol representa una condición de partición sobre una variable x_j , mientras que cada nodo hoja corresponde a una predicción $\hat{y}$. En clasificación, la predicción se da como la clase mayoritaria; en regresión, como el valor promedio de los ejemplos en la hoja. El objetivo del entrenamiento es seleccionar en cada nodo el **mejor criterio de partición**. Dos de los más utilizados son:

- **Ganancia de información (basada en entropía)**: mide la reducción de incertidumbre lograda al aplicar una división.

$$H(S) = - \sum_{k=1}^K p_k \log_2(p_k)$$

donde p_k es la proporción de ejemplos de la clase k .

- **Índice de Gini**: mide la impureza de una partición.

$$G(S) = 1 - \sum_{k=1}^K p_k^2$$

Un valor bajo de Gini indica mayor homogeneidad.

En la práctica, tanto Gini como entropía suelen dar resultados similares, aunque el índice de Gini es más eficiente computacionalmente (Müller & Guido, 2017; Benítez et al., 2025).

Figura 1. Criterios de partición en árboles de decisión



Fuente: Elaboración propia

La capacidad predictiva de un árbol depende directamente de su **profundidad**. Un árbol demasiado profundo puede sobreajustar los datos de entrenamiento, capturando ruido y perdiendo capacidad de generalización; en contraste, un árbol poco profundo puede subajustar al no detectar patrones relevantes. Para equilibrar este dilema, se emplean técnicas como la poda y el ajuste de hiperparámetros, que permiten regular la complejidad del modelo.

Este aspecto convierte a los árboles de decisión en un recurso ideal para discutir el compromiso entre sesgo y varianza, un tema central en el aprendizaje automático contemporáneo.

2.2. Métricas para multiclase

En los problemas de clasificación multiclase, la exactitud o *accuracy* resulta insuficiente para evaluar el desempeño de un modelo, especialmente cuando las clases se encuentran desbalanceadas.

Con frecuencia, un modelo puede mostrar una alta exactitud simplemente por predecir bien las clases mayoritarias, pero fallar de manera sistemática en las minoritarias. Por ello, la evaluación en escenarios multiclase requiere un enfoque más amplio que considere métricas multicriterio y permita un análisis más equilibrado del rendimiento del algoritmo.

Figura 2. Matriz de confusión

		Predicción		
		Clase A	Clase B	Clase C
Valor real	Clase A	5	7	0
	Clase B	2	9	1
	Clase C	1	2	6

Fuente: Elaboración propia

La primera herramienta fundamental es la **matriz de confusión**, que organiza las predicciones en una tabla de dimensión $K \times K$, donde K es el número de clases. Este recurso visualiza los aciertos y errores de clasificación, mostrando en qué categorías se producen mayores confusiones como se aprecia en la Figura.

A partir de esta matriz se derivan métricas clave: la **precisión (precision)**, que mide la proporción de verdaderos positivos sobre todos los predichos como positivos para una clase

$$Precisión_k = \frac{TP_k}{TP_k + FP_k}$$

El **recall o sensibilidad**, que indica la proporción de verdaderos positivos sobre todos los ejemplos realmente positivos.

$$Recall_k = \frac{TP_k}{TP_k + FN_k}$$

El **F1-score**, que corresponde a la media armónica entre precisión y recall.

$$F1 = 2 \cdot \frac{Precisión_k \cdot Recall_k}{Precisión_k + Recall_k}$$

En clasificación multiclase, estas métricas pueden calcularse mediante distintos esquemas de promedio: *macro average*, que trata a todas las clases por igual; *weighted average*, que pondera las métricas según el tamaño de cada clase; y *micro average*, que combina los conteos globales de verdaderos positivos, falsos positivos y falsos negativos (Raschka, Liu & Mirjalili, 2022).

Además, existen métricas complementarias que enriquecen la evaluación. El **ROC-AUC multiclase** se extiende bajo el enfoque “uno contra todos” y permite analizar la discriminación entre clases. El **índice Kappa de Cohen** introduce una corrección para el acuerdo esperado

Árboles


Métricas

Interpretación

Aplicaciones

por azar, resultando útil en contextos donde la distribución de clases está muy sesgada. Finalmente, el **log-loss** se centra en la calidad de las probabilidades predichas, penalizando más severamente las predicciones con alta confianza que resultan erróneas (scikit-learn developers, 2024).

Figura 3. Evaluación de Métricas de Clasificación



Fuente: Elaboración propia

2.3. Interpretación y análisis de errores

Uno de los aspectos más relevantes en el aprendizaje automático no es únicamente entrenar un modelo, sino comprender las razones por las cuales se equivoca.

Árboles

Métricas

Interpretación

Aplicaciones

La interpretación y el análisis de errores constituyen un paso esencial tanto en la práctica profesional como en la enseñanza, ya que permiten ir más allá de las métricas globales para explorar las limitaciones y los sesgos del algoritmo. Entender los errores no solo mejora la calidad de los modelos, sino que también desarrolla en los estudiantes la capacidad crítica para evaluar resultados de manera rigurosa.

Cuando un modelo produce predicciones $\hat{y}_i$ a partir de entradas x_i , el error se define como la diferencia entre la predicción y la etiqueta real y_i . Este concepto se manifiesta de formas distintas dependiendo del tipo de tarea. En **problemas de clasificación**, los errores más relevantes son los falsos positivos (FP) y los falsos negativos (FN). Un falso positivo ocurre cuando el modelo predice “1” (positivo) siendo en realidad “0”, mientras que un falso negativo corresponde al caso opuesto. La matriz de confusión organiza de manera sistemática estas situaciones, mostrando en qué categorías se concentran los fallos.


Por otro lado, en **problemas de regresión**, los errores suelen evaluarse mediante métricas como el error cuadrático medio (MSE) o el error absoluto medio (MAE), complementándose con el análisis visual de los residuos. Este enfoque gráfico permite identificar patrones sistemáticos, como la tendencia de un modelo a subestimar los valores más altos de la variable respuesta.

Resulta importante comprender que los errores contienen información valiosa sobre el sesgo, la varianza y la calidad de los datos. Por ejemplo, si un modelo comete **errores sistemáticos**, ello puede revelar un sesgo en los datos o una falta de complejidad en la hipótesis del modelo. En contraste, si los **errores son aleatorios** pero elevados, esto puede reflejar una varianza alta y un problema de sobreajuste. Asimismo, en **contextos desbalanceados**, como la detección de fraudes, una alta exactitud puede ser engañosa: un modelo que predice siempre la clase mayoritaria puede parecer “preciso” en términos de accuracy, pero carecer de utilidad práctica (Müller & Guido, 2023; Benítez, Cencerrado, Escudero & Kanaan, 2025).

La interpretación de los errores es tan importante como entrenar el modelo mismo. Esta práctica fomenta una visión crítica en los estudiantes,

ayudándoles a reconocer que los algoritmos no son perfectos y que cada error puede convertirse en una oportunidad de mejora.

Figura 4. Errores en Aprendizaje Automático



Fuente: Elaboración propia

2.4. Aplicaciones prácticas en datasets reales

El análisis de errores adquiere un papel crucial cuando se traslada del entorno teórico a la práctica con datasets reales, pues en estos datos aparecen imperfecciones inherentes al mundo profesional, como ruido, valores faltantes o desbalance de clases.

Árboles

Métricas

Interpretación

Aplicaciones

Este ejercicio no solo permite evaluar la capacidad predictiva de los algoritmos, sino que también brinda a los estudiantes una comprensión más profunda sobre la relevancia de interpretar los resultados más allá de una métrica única como la exactitud. En el ámbito de la **detección de spam**, por ejemplo, el uso de colecciones como SpamAssassin o SMS Spam Collection en Kaggle invita a reflexionar sobre los desafíos del **desbalance de clases**, así como sobre la interpretación de métricas multicriterio como el ROC-AUC. En este escenario, identificar qué palabras o patrones lingüísticos conducen a errores se convierte en una oportunidad para relacionar el aprendizaje automático con problemas de seguridad digital (Raschka, Liu, & Mirjalili, 2022).

En el campo de la **salud**, datasets como *Heart Disease* (UCI/Kaggle) ofrecen un espacio pedagógico privilegiado, ya que el análisis de falsos positivos y falsos negativos tiene consecuencias directas: un falso negativo puede implicar la ausencia de un diagnóstico en un paciente con enfermedad cardíaca, lo que resalta la importancia de priorizar métricas como el recall. Esto evidencia que el aprendizaje automático no solo se evalúa por su desempeño global, sino por la manera en que responde a las necesidades de un dominio específico (Murphy, 2023).

De manera similar, los **conjuntos de imágenes** como MNIST o Fashion-MNIST permiten conectar teoría y percepción visual. Observar ejemplos mal clasificados —como la confusión entre un “5” y un “8”— motiva a discutir sobre la calidad de las representaciones aprendidas y la dificultad inherente a ciertas categorías. La práctica, en este sentido, fomenta un aprendizaje crítico al mostrar que los errores no son meros fallos, sino pistas para mejorar modelos y algoritmos (Géron, 2023).

Por otro lado, en **problemas de regresión**, como la predicción de precios de vivienda en el famoso dataset *House Prices – Advanced Regression Techniques* de Kaggle, los gráficos de residuos adquieren un rol protagónico. Estos permiten identificar si el modelo subestima sistemáticamente los precios de viviendas costosas, revelando un sesgo hacia el promedio. Tal análisis fortalece la capacidad de los estudiantes para evaluar las limitaciones del modelo y discutir estrategias de mejora, como la regularización o la selección de atributos (Benítez, Cencerrado, Escudero, & Kanaan, 2025).

Árboles

Métricas

Interpretación

Aplicaciones

En conclusión, la utilización de datasets reales refuerza tanto el dominio técnico como la comprensión crítica de los modelos, conectando la teoría con problemáticas concretas en salud, economía o seguridad digital. Este enfoque pedagógico convierte el error en una ventana hacia la mejora y en una oportunidad para vincular el aprendizaje automático con la toma de decisiones en contextos reales.

Figura 5. Proyectos de Aprendizaje Automático



Detección de Spam

Clasificar mensajes como spam o ham, experimentar con el desbalance de clases.



Predicción de Enfermedades Cardíacas

Predicir la presencia de enfermedad a partir de variables clínicas, interpretar falsos positivos y negativos.



Clasificación de Imágenes Manuscritas

Reconocer dígitos o prendas de vestir, visualizar ejemplos mal clasificados para entender la confusión.



Predicción de Precios de Viviendas

Estimar precios a partir de características estructurales y demográficas, analizar gráficos de residuos para sesgo.

Fuente: Elaboración propia

Árboles

Métricas

Interpretación

Aplicaciones

Bibliografía

Benítez, R., Cencerrado, A., Escudero, G., & Kanaan, S. (2025). *Inteligencia artificial avanzada*. FUOC.

Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.). O'Reilly.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2023). *Applied Logistic Regression* (4th ed.). Wiley.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python* (2nd ed.). Springer.

Müller, A. C., & Guido, S. (2017). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media.

Murphy, K. P. (2023). *Probabilistic Machine Learning: Advanced Topics*. MIT Press.

Raschka, S., Liu, Y., & Mirjalili, V. (2022). *Machine Learning with PyTorch and Scikit-Learn*. Packt.

scikit-learn developers. (2024). *User Guide v1.4–1.5* (Linear models; SVM; Neural networks; Model selection).

scikit-learn developers. (2024). *User Guide v1.4–1.5* (Model evaluation and metrics).