



Carrera de Ciencia de Datos  
e Inteligencia Artificial  
FACULTAD DE INGENIERÍA

**MACHINE  
LEARNING I**

# Arboles de Decisión (Decision Tree)




## Qué son

Modelos de clasificación (de aprendizaje supervisado).

| ID | Home Owner | Marital Status | Annual Income | Defaulted Borrower |
|----|------------|----------------|---------------|--------------------|
|    |            |                |               |                    |
| 1  | Yes        | Single         | 125K          | No                 |
| 2  | No         | Married        | 100K          | No                 |
| 3  | No         | Single         | 70K           | No                 |
| 4  | Yes        | Married        | 120K          | No                 |
| 5  | No         | Divorced       | 95K           | Yes                |
| 6  | No         | Married        | 60K           | No                 |
| 7  | Yes        | Divorced       | 220K          | No                 |
| 8  | No         | Single         | 85K           | Yes                |
| 9  | No         | Married        | 75K           | No                 |
| 10 | No         | Single         | 90K           | Yes                |

Training Data



Model: Decision Tree



## Cómo se construyen los árboles

En cada nodo del árbol, el algoritmo elige una prueba de atributo que *divide mejor* los datos en subconjuntos más pequeños y homogéneos. La clave para construir un árbol reside en decidir cómo dividir los datos en cada nodo

**Algoritmo de Hunt:** Un algoritmo voraz fundamental. Divide los datos de forma recursiva en cada nodo. Finaliza prematuramente (deja de dividir) si todos los datos de un nodo pertenecen a la misma clase.

### **Algoritmos comunes:**

- ID3 y C4.5: Utilizan la entropía y la ganancia de información.
- CART, SLIQ y SPRINT: Utilizan el índice de Gini.



## **Tipos de atributos**

El tipo de atributo determina las posibles divisiones:

Nominal: (por ejemplo: soltero, casado, divorciado) puede dividirse en múltiples ramas (división múltiple) o agruparse en una división binaria (soltero frente a casado, o frente a divorciado).

Ordinal: (por ejemplo, pequeño, mediano, grande), o también puede ser una división múltiple o binaria.

Continuo: (p. ej., 10.5, 22.1) se puede manejar de dos maneras:

- Discretizado para crear un atributo ordinal (p. ej., bajo, medio, alto), o por división binaria (<edad o >edad)

Para encontrar de forma eficiente la mejor división para valores continuos, primero se ordenan los datos. A continuación, el algoritmo recorre la lista, acumulando recuentos para calcular la impureza de cada posible punto de división.



## Cómo elegir la mejor división?

El enfoque voraz consiste en seleccionar la división que minimice la impureza o maximice la ganancia de información.

### Minimizar las impurezas

La impureza mide el grado de mezcla de clases en un nodo. Un nodo perfectamente puro (de una sola clase) tiene impureza cero. El objetivo es elegir una división que dé como resultado los nodos hijos más "puros" posibles, calculados como un promedio ponderado.

### Medidas de impureza


| Entropía                   | Índice de Gini      | Error de clasificación |
|----------------------------|---------------------|------------------------|
| $-\sum p_i(t) \log p_i(t)$ | $1 - \sum p_i(t)^2$ | $1 - \max[p_i(t)]$     |

*\* $p_i(t)$  es la frecuencia de la clase  $i$  en el nodo  $t$*





## Comparación de métricas de impureza



Este gráfico compara tres medidas de impureza utilizadas en algoritmos de árboles de decisión para un problema de dos clases.

Cada curva representa la proporción de puntos de datos que pertenecen a una de las dos clases. Por ejemplo,  $p = 0,1$  significa que el 10 % pertenece a la clase 1 y el 90 % a la clase 2. El eje  $y$  mide la impureza calculada.

Las tres métricas alcanzan su máximo en  $p = 0,5$ , lo que indica que una división 50/50 es el estado más impuro o "mixto", y si todas son cero en  $p = 0$  y  $p = 1$  representa un nodo "puro" que contiene solo una clase.

Las formas curvas de las funciones de entropía y Gini las hacen más sensibles a los cambios en las probabilidades de clase cerca de los nodos puros, razón por la cual generalmente se prefieren al error de clasificación errónea lineal más simple para encontrar las divisiones más efectivas.



## Maximizar la ganancia de información (utilizado en ID3)

Esta métrica calcula la reducción de entropía lograda por una división. Elegimos la división que proporciona la mayor ganancia.

$$\text{Gain}_{\text{split}} = \text{Entropy}(p) - \sum_i \frac{n_i}{n} \text{Entropy}(i)$$

donde **Entropy**( $p$ ) es la entropía del nodo padre y  $n_i/n$  es la fracción de datos que van al  $i$ -ésimo nodo hijo.

## Maximizar la relación de ganancia (utilizado en C4.5)

La ganancia de información tiene un defecto: favorece naturalmente los atributos con un gran número de divisiones (por ejemplo, dividir por una columna de ID única daría una "pureza" perfecta, pero es inútil).

El índice de ganancia corrige esto penalizando las divisiones que crean muchas particiones pequeñas.

$$\text{Gain Ratio} = \frac{\text{Gain}_{\text{split}}}{\text{Split Info}}$$

Relación de ganancia

$$\text{Split Info} = - \sum_i \frac{n_i}{n} \log_2 \frac{n_i}{n}$$

Split Info mide la "entropía" de la división en sí.



**Para valores categóricos y continuos, existen muchas opciones posibles para la división. Para valores continuos, el número de opciones es igual al número de valores distintos. Para calcular eficientemente el índice de Gini para cada opción de división, podemos primero ordenar los valores, luego recorrer la lista, acumular recuentos y calcular el índice de Gini. Esto requiere una complejidad de  $O(n)$ .**






## Ventajas y desventajas de minimizar impurezas

### Ventajas

- Rápido: Relativamente rápido de construir y usar para predicciones.
- Interpretable: Los árboles pequeños son fáciles de entender y visualizar.
- Robusto: Tiende a manejar bien el ruido, los atributos redundantes y los atributos irrelevantes.

### Desventajas

- Naturaleza codiciosa: El enfoque codicioso puede pasar por alto atributos interactivos (atributos que solo son predictivos cuando se combinan, pero no individualmente).
- Límite de decisión: El modelo solo puede crear límites de decisión basados en un único atributo a la vez (por ejemplo, líneas horizontales o verticales en un espacio 2D).



Both **positive (+)** and **negative (o)** classes generated from **skewed Gaussians** with centers at (8,8) and (12,12) respectively.

La imagen muestra una limitación clave de los árboles de decisión estándar, que se basan en divisiones alineadas con un solo atributo y ejes. El diagrama de dispersión muestra dos clases, positiva y negativa, generadas a partir de distribuciones gaussianas asimétricas.

Si bien las dos clases presentan una separación diagonal clara y sencilla, el árbol de decisión no puede crear una línea diagonal. En su lugar, se ve obligado a aproximar este límite creando un patrón complejo en forma de "escalera", compuesto por numerosas divisiones pequeñas horizontales y verticales, lo que resulta en un modelo mucho más complejo de lo necesario para este conjunto de datos.



## Índice de Gini para medir la impureza de un nodo

Un nodo es puro si todos los registros que contiene pertenecen a la misma clase. Un nodo es impuro si contiene una mezcla de diferentes clases.

Ejemplo:

**Seleccionar atributos que maximicen la pureza promedio después de la división.**

Índice de Gini

Gini = 0: Pureza perfecta (todos los registros de la misma clase)

Gini = 0,5: Impureza máxima (división 50-50 para clasificación binaria)

| ID | Home Owner | Marital Status | Annual Income | Defaulted Borrower |
|----|------------|----------------|---------------|--------------------|
| 1  | Yes        | Single         | 125K          | No                 |
| 2  | No         | Married        | 100K          | No                 |
| 3  | No         | Single         | 70K           | No                 |
| 4  | Yes        | Married        | 120K          | No                 |
| 5  | No         | Divorced       | 95K           | Yes                |
| 6  | No         | Married        | 60K           | No                 |
| 7  | Yes        | Divorced       | 220K          | No                 |
| 8  | No         | Single         | 85K           | Yes                |
| 9  | No         | Married        | 75K           | No                 |
| 10 | No         | Single         | 90K           | Yes                |

*\*Predicción de impago de préstamos. Un prestatario moroso (defaulted borrower) es una persona (o una organización) que no ha pagado un préstamo según los términos acordados.*



### Proceso

Paso 1: Calcular el coeficiente de Gini del nodo raíz

En la raíz, tenemos un total de 10 registros: 7 No, 3 Sí

$$\text{Gini(raíz)} = 1 - [(7/10)^2 + (3/10)^2] = 1 - [0,49 + 0,09] = 1 - 0,58 = 0,42$$

Paso 2: Evaluar cada atributo

#### **Atributo 1: Propietario de la vivienda (Sí/No)**

División en el propietario de la vivienda = Sí:

Registros: 1, 4, 7 → Todos son “No” (sin valor predeterminado)

Recuento: 3 registros (3 No, 0 Sí), según Defaulted Borrower.

$$\text{Gini(Propietario de la vivienda = Sí)} = 1 - [(3/3)^2 + (0/3)^2] = 1 - 1 = 0,0 \text{ (¡Puro!)}$$

División en el propietario de la vivienda = No: Records: 2, 3, 5, 6, 8, 9, 10.

Recuento: 7 registros [4 No (ID: 2, 3, 6, y 9), 3 Sí (ID: 5, 8, y 10)]

$$\text{Gini(Propietario de vivienda = No)} = 1 - [(4/7)^2 + (3/7)^2] = 1 - [0,327 + 0,184] = 1 - 0,511 = 0,489$$

$$\text{Coeficiente de Gini ponderado para el propietario de la vivienda: } \text{Gini\_split(Home Owner)} = (3/10) \times 0,0 + (7/10) \times 0,489 = 0 + 0,342 = 0,342$$

$$\text{Ganancia de Gini (Propietario de vivienda): } \text{Ganancia\_Gini} = \text{Gini(raíz)} - \text{Gini\_división} = 0,42 - 0,342 = \mathbf{0,078}$$



Información de la división (propietario de la vivienda):

Propietario de la vivienda = Sí: 3/10 registros

Propietario de la vivienda = No: 7/10 registros

$$\text{Split\_Info} = -[(3/10) \times \log_2(3/10) + (7/10) \times \log_2(7/10)] = -[0.3 \times (-1.737) + 0.7 \times (-0.515)] = -[-0.521 + -0.361] = -[-0.882] = 0.882$$

Coeficiente de ganancia (propietario de vivienda):  $\text{Coeficiente\_de\_ganancia} = \text{Ganancia\_de\_Gini} /$

$$\text{Información\_de\_división} = 0,078 / 0,882 = 0,088$$

### **Atributo 2: Estado civil (Soltero/Casado/Divorciado)**

División por estado civil = Soltero/a:

Récords: 1, 3, 8, 10

Recuento: 4 registros (2 No, 2 Sí)

$$\text{Gini (individual)} = 1 - [(2/4)^2 + (2/4)^2] = 1 - [0,25 + 0,25] = 0,5$$

División por estado civil = Casado:

Récords: 2, 4, 6, 9

Recuento: 4 registros (4 No, 0 Sí)

$$\text{Gini (Casado)} = 1 - [(4/4)^2 + (0/4)^2] = 0.0 \text{ (¡Puro!)}$$

Separación por estado civil = Divorciados:

Récords: 5, 7

Recuento: 2 registros (1 No, 1 Sí)

$$\text{Coeficiente de Gini (divorciados)} = 1 - [(1/2)^2 + (1/2)^2] = 1 - 0,5 = 0,5$$





Coeficiente de Gini ponderado para el estado civil:  $\text{Gini\_split}(\text{Marital}) = (4/10) \times 0,5 + (4/10) \times 0,0 + (2/10) \times 0,5 = 0,2 + 0 + 0,1 = \mathbf{0,3}$

Ganancia de Gini (Estado civil):  $\text{Ganancia\_Gini} = \text{Gini}(\text{raíz}) - \text{Gini\_división} = 0,42 - 0,3 = \mathbf{0,12}$

### **Atributo 3: Ingresos anuales (continuos)**

Para atributos continuos, necesitamos encontrar el mejor punto de división. Ordenemos por ingresos y probemos las divisiones:

Ordenados por ingresos: 60.000, 70.000, 75.000, 85.000, 90.000, 95.000, 100.000, 120.000, 125.000, 220.000

Probar dividiendo en 80K:

Ingresos  $\leq$  80.000:

Registros: 3, 6, 9  $\rightarrow$  (2 No, 1 Sí)

$\text{Gini} = 1 - [(2/3)^2 + (1/3)^2] = 1 - [0,444 + 0,111] = 0,444$

Ingresos  $>$  80.000:

Registros: 1, 2, 4, 5, 7, 8, 10  $\rightarrow$  (5 No, 2 Sí)

$\text{Gini} = 1 - [(5/7)^2 + (2/7)^2] = 1 - [0,510 + 0,082] = 0,408$





$$\text{Gini\_split}(\text{Ingresos a 80K}) = (3/10) \times 0,444 + (7/10) \times 0,408 = 0,419$$

$$\text{Ganancia de Gini (Ingresos a 80.000): Ganancia\_Gini} = 0,42 - 0,419 = \mathbf{0,001}$$

Probar dividiendo en 95K: Se necesitarían cálculos similares para otros posibles puntos de división.

### **Paso 3: Seleccionar el mejor atributo**


| Attribute             | Gini_split | Gini_Gain   | Selection     |
|-----------------------|------------|-------------|---------------|
| Home Owner            | 0.342      | 0.078       |               |
| <b>Marital Status</b> | <b>0.3</b> | <b>0.12</b> | <b>✓ BEST</b> |
| Income (80K)          | 0.419      | 0.001       |               |

**División según el estado civil (mayor ganancia de Gini = 0,12)**

Paso 4: Construir el árbol.





## Construcción del árbol de decisión



Los 4 registros son “No” → Nodo puro →  
Etiqueta: Sin valor predeterminado


Esto significa: Si el solicitante está casado →  
Se prevé que no habrá impago (se concede el préstamo).







## Arbol final



### Conclusiones para el conjunto de datos de préstamos

Solicitantes casados → Es poco probable que incumplan con el pago (se concede el préstamo)

Solicitantes solteros → Se requiere un análisis más detallado (verificar ingresos, propiedad de vivienda)

Solicitantes divorciados → Requieren análisis adicionales

*El árbol de decisiones proporciona un modelo interpretable para las decisiones de aprobación de préstamos basado en patrones de datos históricos.*





### Reglas de decisión final

Del árbol de decisiones completo, podemos extraer estas reglas para la aprobación del préstamo:

1. SI Estado civil = Casado
  - ENTONCES Predicción: NO Incumplimiento → OTORGAR PRÉSTAMO ✓
2. SI Estado civil = Soltero Y Propietario de vivienda = Sí
  - ENTONCES Predicción: NO Incumplimiento → OTORGAR PRÉSTAMO ✓
3. SI Estado civil = Soltero Y Propietario de vivienda = No Y Ingresos  $\leq 77.500$  - ENTONCES Predicción: NO Incumplimiento → OTORGAR PRÉSTAMO ✓
4. SI Estado civil = Soltero Y Propietario de vivienda = No Y Ingresos  $> 77.500$ 
  - ENTONCES Predicción: SÍ Incumplimiento → DENEGAR PRÉSTAMO ✗
5. SI Estado civil = Divorciado Y Propietario de vivienda = Sí
  - ENTONCES Predicción: NO Incumplimiento → OTORGAR PRÉSTAMO ✓
6. SI Estado civil = Divorciado Y Propietario de vivienda = No
  - ENTONCES Predicción: SÍ Incumplimiento → DENEGAR PRÉSTAMO ✗



Carrera de Ciencia de Datos  
e Inteligencia Artificial  
FACULTAD DE INGENIERÍA

**MACHINE  
LEARNING I**

## **PRÁCTICA DE APLICACIÓN- EXPERIMENTACIÓN**

**Desarrollar el proceso anterior con apoyo Python, trabajo de grupo (3-5 personas)**