



Coordinación de
Educación Abierta y a Distancia
VICERRECTORADO ACADÉMICO



ASIGNATURA MACHINE LEARNING

Actividad Autónoma 4

Nombre de la actividad: Árboles de decisión y métricas avanzadas

Unidad 2: Modelos avanzados de clasificación y regresión

Tema 2: Árboles de decisión y métricas avanzadas



FACULTAD DE
Ingeniería

Nombres:

Fecha:

Carrera:

Periodo académico:

Semestre:

Objetivo de la actividad: Construir, evaluar e interpretar modelos de árboles de decisión aplicando criterios de partición y métricas multiclase, comprendiendo las limitaciones de cada enfoque y analizando errores en datasets reales mediante Google Colab.

Recursos o temas que debe haber estudiado antes de hacer la actividad:

- Conceptos de árboles de decisión y criterios de partición (entropía y Gini).
- Métricas de evaluación en clasificación multiclase: precisión, recall, F1-score, ROC-AUC, log-loss.
- Conceptos de falsos positivos, falsos negativos, sesgo y varianza.
- Interpretación de errores y análisis crítico de resultados.
- Uso de datasets reales (Kaggle, UCI).

Formato de entrega: PDF

Instrucciones:

- Cree un cuaderno en **Google Colab** llamado: AA2_ML_Nombre_Apellido_Grupo_X.ipynb.
- Copie y ejecute los códigos base provistos en cada sección.
- En **cada celda de código**:
 - Ejecute el programa.
 - Añada comentarios (#) explicando qué hace cada instrucción.
 - Interprete los resultados obtenidos (árboles, métricas, matrices de confusión, errores).
- Añada **gráficos adicionales** cuando sea posible (ejemplo: fronteras de decisión, histogramas de errores).
- Responda en texto las preguntas de análisis planteadas.
- Exporte su cuaderno en formato **PDF** y súbalo al aula virtual.

Contenido

1. Árboles de decisión: criterios de partición

- Ejecute el siguiente código:

```
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt

# Cargar el dataset Iris
iris = load_iris()
X, y = iris.data, iris.target

# Entrenar árbol de decisión con criterio Gini y profundidad máxima de 3
clf = DecisionTreeClassifier(criterion="gini", max_depth=3,
random_state=0)
clf.fit(X, y)

# Visualizar el árbol entrenado
plt.figure(figsize=(12,8))
plot_tree(clf, filled=True, feature_names=iris.feature_names,
class_names=iris.target_names)
plt.show()
```

- Observar qué variable aparece en la raíz del árbol.
- Explicar por qué se eligió esa variable como la primera división (mayor ganancia de información o menor índice Gini).
- Modificar el parámetro `max_depth` (ej. 1 y 5) y comparar la diferencia en los árboles obtenidos: ¿Cuál de los dos modelos se ajusta mejor a los datos?
 - a. ¿Qué ocurre con un árbol poco profundo?
 - b. ¿Qué ocurre con un árbol muy profundo?

2. Métricas multiclase

- Ejecute el siguiente código:

```
from sklearn.metrics import classification_report,  
confusion_matrix, ConfusionMatrixDisplay  
  
# Predicciones del modelo  
y_pred = clf.predict(X)  
  
# Matriz de confusión  
cm = confusion_matrix(y, y_pred)  
ConfusionMatrixDisplay(cm,  
display_labels=iris.target_names).plot(cmap="Blues")  
  
# Reporte de métricas  
print(classification_report(y, y_pred,  
target_names=iris.target_names))
```

- Observar la matriz de confusión: ¿qué clases fueron más confundidas?
- Reportar los valores de precisión, recall y F1-score de cada clase.
- Calcular los promedios macro y weighted.
- Explicar:
 - a) ¿Cuál modelo conserva más variables en el ajuste?
 - b) ¿Por qué Lasso puede considerarse un método de selección de variables?
 - c) ¿En qué tipo de problemas conviene usar Ridge y en cuáles Lasso?

3. Interpretación y análisis de errores

- Explique con sus propias palabras qué significan los falsos positivos (FP) y falsos negativos (FN) en un contexto médico (ejemplo: diagnóstico de enfermedad cardíaca).
- Indique qué métrica sería más relevante en ese escenario (precisión o recall) y justifique su respuesta.

4. Aplicaciones prácticas en dataset real

- Seleccione un dataset de Kaggle o UCI (ejemplo: Heart Disease, MNIST o House Prices).
- Ejecute el siguiente código adaptándolo al dataset elegido.

```
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import classification_report,
confusion_matrix

# División de datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.3, random_state=0)

# Entrenar árbol de decisión
clf = DecisionTreeClassifier(max_depth=5, random_state=0)
clf.fit(X_train, y_train)

# Evaluación
y_pred = clf.predict(X_test)
print("Matriz de confusión:\n", confusion_matrix(y_test,
y_pred))
print("\nReporte de métricas:\n", classification_report(y_test,
y_pred))
```

- Identificar qué clases o categorías concentran más errores en la matriz de confusión.
- Comparar los valores de precisión, recall y F1-score.
- Proponer al menos dos estrategias para mejorar el modelo, por ejemplo:
 - a) Ajuste de hiperparámetros (max_depth, min_samples_split).
 - b) Uso de poda del árbol.
 - c) Probar con conjuntos de datos balanceados.



Bibliografía:

- Benítez, R., Cencerrado, A., Escudero, G., & Kanaan, S. (2025). Inteligencia artificial avanzada. FUOC.
- Géron, A. (2023). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (3rd ed.). O'Reilly.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python (2nd ed.). Springer.
- Müller, A. C., & Guido, S. (2017). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media.
- Raschka, S., Liu, Y., & Mirjalili, V. (2022). Machine Learning with PyTorch and Scikit-Learn. Packt.
- scikit-learn developers. (2024). User Guide v1.4–1.5 (Decision Trees; Metrics and Model Evaluation).



Rúbrica de evaluación

Componente de aprendizaje:	Autónomo	X	Contacto con el Docente	
Nombre de la Unidad:	Unidad 2: Modelos avanzados de clasificación y regresión			
Resultado(s) de aprendizaje:	El estudiante analizará resultados con métricas multicriterio.			
Nombre de la Actividad:	Árboles de decisión y métricas avanzadas			

Criterios de Evaluación	Escala de Valoración						
	Excelente (10 - 9,1)	Bueno (9 - 8,1)	Satisfactorio (8 - 7)	Necesita mejorar (6,9 - 0,1)	No entrega (0)	Puntaje	Comentarios (SIGEA)
1. Árboles de decisión: criterios de partición	Entrena el árbol sin errores, explica claramente la variable raíz y analiza con ejemplos cómo afecta la profundidad al modelo.	Entrena el árbol y explica la variable raíz con comentarios generales.	Entrena el árbol parcialmente; explica de manera básica la variable raíz o la profundidad.	Entrena con errores o no interpreta resultados.	No entrega		
2. Métricas multiclase	Calcula y reporta correctamente precisión, recall y F1-score (macro y weighted); interpreta la matriz de confusión identificando clases difíciles de clasificar.	Calcula métricas y comenta diferencias generales entre clases.	Presenta resultados parciales o con explicación superficial.	Resultados incorrectos o sin interpretación crítica.	No entrega		
3. Interpretación y análisis de errores	Explica con claridad falsos positivos y negativos en contexto real (ej. medicina); justifica la métrica prioritaria con ejemplos bien fundamentados.	Explica FP y FN y menciona la métrica más importante con justificación general.	Explicación parcial de FP y FN; justificación poco clara de la métrica prioritaria.	Respuestas vagas o incorrectas sin relación con el contexto.	No entrega		
4. Aplicaciones prácticas en dataset real	Selecciona dataset adecuado, entrena árbol correctamente, reporta métricas y analiza errores con propuestas de mejora bien fundamentadas.	Selecciona dataset y entrena árbol; reporta métricas con análisis general.	Usa dataset pero presenta resultados parciales o con análisis limitado.	Resultados incompletos o sin propuestas de mejora.	No entrega		
5. Presentación, autonomía y reflexión crítica	Documento claro, ordenado y sin plagio; refleja autonomía, innovación y reflexión crítica; alineado a ejes formativos (ética, comunicación, tecnologías).	Documento ordenado y comprensible; autonomía básica.	Documento aceptable pero con poca reflexión crítica.	Documento desordenado, sin reflexión ni autonomía.	No entrega		

Puntaje
total

