



ESCUELA DE NEGOCIOS

MAESTRÍA EN INTELIGENCIA DE NEGOCIOS Y CIENCIA DE DATOS

**DETERMINACIÓN DE UN MODELO DE DETECCIÓN DE FRAUDE EN
TRANSACCIONES FINANCIERAS PARA UNA ENTIDAD BANCARIA**

**Profesor
Andrés David Navas Perrone**

**Autores
Sandy Gabriela Alcivar Zamora
José Luis Condolo Quiroz**

2024

RESUMEN

El fraude dentro de las instituciones financieras representa una amenaza latente de alto valor que involucra a individuos, empresas o entidades dedicadas a engañar a usuarios del comercio electrónico y del sector financiero en general. Con la presente investigación buscamos diseñar y desarrollar un modelo que detecte el fraude financiero utilizando tecnología de la cuarta revolución industrial como Big Data y aprendizaje automático. El modelo a implementar se centra en identificar con alta precisión, patrones anómalos en transacciones bancarias de retiros de dinero, minimizando falsos positivos y falsos negativos, fortaleciendo de esta manera la seguridad financiera.

La metodología de análisis que se va aplicar incluye un análisis exploratorio de las variables y la implementación de algoritmos tales como: Regresión Logística, Árboles de Decisión, y Random Forest. En cada modelo se va a evaluar las métricas de rendimiento como: precisión, recall y curva ROC para poder elegir el modelo que mejor pueda predecir el fraude financiero en el contexto de retiros de dinero dentro de la institución bancaria que se va a estudiar.

Los resultados esperados incluyen la disminución de falsos positivos y un aumento en la precisión predictiva del fraude. El modelo busca fortalecer los controles internos de las instituciones financieras en la lucha contra el fraude.

Con esta investigación se espera contribuir al desarrollo de soluciones tecnológicas que permitan a las instituciones financieras anticiparse a las amenazas asociadas al fraude.

ABSTRACT

Financial fraud is a significant challenge that affects the economic stability of institutions and customer trust. This study aims to develop a financial fraud detection model using advanced data analysis and machine learning techniques. The methodology includes exploratory data analysis, data mining, and the implementation of supervised algorithms such as Random Forest, complemented by neural networks to identify complex patterns.

The expected results emphasize improved accuracy and efficiency in fraud detection, reducing false positives and optimizing response times. These enhancements will strengthen the internal controls of financial institutions, enabling them to anticipate threats and minimize losses associated with fraud.

This work contributes to the development of innovative technological solutions that leverage the power of fourth industrial revolution technologies, positioning financial institutions strategically to address current and future challenges in fraud prevention.

Keywords: Financial fraud, fraud detection, machine learning, data mining, Industry 4.0 technologies

ÍNDICE DEL CONTENIDO

1. RESUMEN	2
2. ABSTRACT	3
3. ÍNDICE DEL CONTENIDO	4
4. ÍNDICE DE TABLAS	6
5. ÍNDICE DE FIGURAS	7
6. INTRODUCCIÓN	1
7. REVISIÓN DE LITERATURA.....	2
8. IDENTIFICACIÓN DEL OBJETO DE ESTUDIO.....	7
9. PLANTEAMIENTO DEL PROBLEMA.....	8
10. OBJETIVO GENERAL	9
11. OBJETIVOS ESPECÍFICOS	9
12. JUSTIFICACIÓN Y APLICACIÓN DE LA METODOLOGÍA	10
9.1. Recolección de datos.....	10
9.2. Tratamiento de los datos.....	12
9.3. Identificación y descripción de las variables	12
9.4. Justificación de las Variables y selección de modelos.....	15
13. RESULTADOS	17
10.1. Análisis Exploratorio	17
10.2. Aplicación de modelos estadísticos.....	23
10.2.1. Random Forest	23
10.2.2. Árbol de Decisión.....	27
10.2.3. Regresión Logística	32
14. DISCUSIÓN DE LOS RESULTADOS Y PROPUESTA DE SOLUCIÓN	36
11.1. Rendimiento de los modelos.....	36

11.2. Falsos Positivos y Negativos de los modelos.....	36
11.3. Aplicabilidad en fraudes financieros	37
11.4. Elección del mejor modelo	37
11.5. Estrategia de implementación.....	38
11.6. Beneficios empresariales asociados a la implementación.....	40
11.7. Nuevas estrategias impulsadas por la detección de fraude.....	41
11.8. Relación con la innovación empresarial.....	42
15. CONCLUSIONES Y RECOMENDACIONES.....	43
16. Referencias	44
17. ANEXOS	47
18. ANEXO 1: Matriz de Revisión Literaria	47
19. ANEXO 2: Código del proyecto.....	50

ÍNDICE DE TABLAS

Tabla 1 Matriz de descripción de variables	13
Tabla 2 Matriz de descripción de las categorías de variable “tipo_transaccion”	13
Tabla 3 Resumen estadístico de las variables de estudio.....	17
Tabla 4 Fraude detectado por tipo de transacción	20
Tabla 5 Nro transacciones fraudulentas detectadas según tipo de transacción	20
Tabla 6 Transacciones legítimas y fraudulentas en Retiro de dinero	21
Tabla 7 Resultados de la evaluación del modelo Random Forest.....	24
Tabla 8 Reporte de Clasificación – Modelo Random Forest	26
Tabla 9 Importancia de las Características – Modelo Random Forest.....	26
Tabla 10 Resultados de la evaluación del modelo árbol de Decisión.....	28
Tabla 11 Reporte de Clasificación – Modelo Árbol de Decisión.....	30
Tabla 12 Importancia de las Características – Modelo Árbol de Decisión.....	31
Tabla 13 Resultados de Evaluación del modelo de Regresión Logística	32
Tabla 14 Reporte de Clasificación – Modelo Regresión Logística	34

ÍNDICE DE FIGURAS

Figure 1 Monto transaccionado de personas por tipo de canal en millones de USD.....	2
Figure 2 Matriz de Correlación de las variables de estudio.....	14
Figure 3 Distribución porcentual por tipo de transacción.....	17
Figure 4 Transaccionalidad según hora del día.....	18
Figure 5 Montos en Transacciones legítimas y fraudulentas	18
Figure 6 Promedio de montos por registros según transacciones legítimas y fraudulentas.....	19
Figure 7 Distribución de fraudes.....	19
Figure 8 Matriz de Correlación para el subconjunto de datos Retiro de Dinero	21
Figure 9 Boxplot de Variables numéricas	22
Figure 10 Matriz de Confusión con Datos de Entrenamiento – Modelo Random Forest	24
Figure 11 Matriz de Confusión con Datos de Prueba – Modelo Random Forest	25
Figure 12 Sobreajuste Modelo Random Forest.....	25
Figure 13 Curva Roc – Modelo Random Forest.....	27
Figure 14 Matriz de Confusión con Datos de Entrenamiento – Modelo Árbol de Decisión	29
Figure 15 Matriz de confusión con Datos de Prueba – Modelo Árbol de Decisión	29
Figure 16 Sobreajuste modelo Árbol de Decisión	30
Figure 17 Curva Roc – Modelo Árbol de Decisión.....	31
Figure 18 Matriz de Confusión para Datos de Prueba – Modelo Regresión Logística.....	34
Figure 19 Sobreajuste modelo Regresión Logística.....	34
Figure 20 Curva Roc – Modelo de Regresión Logística	35

INTRODUCCIÓN

Con el pasar de los años, el fraude financiero se ha convertido en una de las principales amenazas económicas y operativas de las instituciones financieras del país y del mundo. En Ecuador, el auge del comercio electrónico y la adopción de nuevas tecnologías, han impulsado el desarrollo de nuevos negocios e industrias dando un importante dinamismo a la economía del país, esta realidad también ha permitido el incremento de actividades fraudulentas en el sector financiero especialmente en las operaciones transaccionales de valores, lo que exige respuestas inmediatas y efectivas por parte de las organizaciones. Esta perspectiva recalca la necesidad de soluciones robustas que permitan detectar y prevenir acciones fraudulentas de manera oportuna.

La presente investigación tiene como objetivo principal desarrollar un modelo que permita detectar transacciones fraudulentas utilizando herramientas de machine learning, adaptado a la realidad ecuatoriana. Estas técnicas permiten mediante el procesamiento de grandes volúmenes de datos, identificar patrones fraudulentos que podrían pasar desapercibidos en los métodos tradicionales.


La metodología de análisis utilizada para el desarrollo del modelo abarca el análisis exploratorio de datos y la implementación de algoritmos de aprendizaje supervisados. Asimismo, se emplearán técnicas de minería de datos que permitan extraer información clave dentro de los conjuntos de datos masivos.

La relevancia de esta investigación es contribuir al desarrollo de soluciones tecnológicas robustas para la detección del fraude dentro del país. Este documento se estructura en varios capítulos que contienen desde la revisión de la literatura existente hasta la implementación y evaluación del modelo propuesto, ofreciendo una perspectiva integral de esta problemática aplicada al contexto ecuatoriano.

REVISIÓN DE LITERATURA

Según las cifras de la ASO BANCA el monto transaccionado en retiros de dinero muestra un decremento de 13.832 millones de dólares en 2020, este valor disminuyó por la pandemia debido a que las transacciones se realizaban mediante canales electrónicos, en los años siguientes se observa una tendencia incremental que marca la recuperación para este tipo de transacción, en menor medida para los medios remotos. Aun cuando los medios digitales siguen ganando preferencia especialmente por el usuario joven, nos es menos importante los valores transaccionados en los medios físicos y remotos ya que en 2022 movieron mas de 100.000 millones de dólares.

Figure 1 Monto transaccionado de personas por tipo de canal en millones de USD



Fuente y elaboración: ASOBANCA. Canales bancarios: ¿Qué prefieren los ecuatorianos?

Estas cifras son atractivas para los ciberdelincuentes que constantemente buscan infiltrarse en la seguridad de las entidades financieras para cometer algún tipo de fraude, una modalidad de delito en constante evolución.

Los métodos tradicionales de detección de fraude ya no tienen la capacidad requerida para identificar patrones complejos, es por ello que se recurre a soluciones basadas en machine learning, que ofrecen soluciones efectivas y escalables, capaces de detectar y predecir actividades fraudulentas con un nivel

alto de precisión. Mediante la combinación y aplicación de algoritmos como bosques aleatorios y modelos de aprendizaje profundo, las instituciones financieras se han podido adaptar para dar frente a esta problemática.

Carmona Mora y Londoño Morales (2021) resaltan que los modelos de machine learning superan a los métodos tradicionales al identificar comportamientos anómalos que no son evidentes a simple vista. Algoritmos como los árboles de decisión y las redes neuronales pueden procesar grandes volúmenes de datos en tiempo real, permitiendo una respuesta rápida frente a posibles amenazas de fraude. Sin embargo, resaltan el desafío que presenta tener un desbalanceo de datos (transacciones legítimas significativamente más frecuentes que las fraudulentas), indican que esto puede limitar la precisión de los modelos. Este problema puede mitigarse mediante técnicas como el sobremuestreo y el ajuste de pesos en los algoritmos.

Bajo el mismo concepto, el trabajo de Kazeem (2023) y Afriyie et al. (2023), evidencian que los algoritmos supervisados como Random Forest y Support Vector Machines (SVM), ofrecen resultados eficaces en la detección de fraudes. Estas técnicas analizan datos multidimensionales y generan predicciones basadas en patrones históricos. Además, la investigación enfatiza que seleccionar las características más relevantes mejora el rendimiento del modelo como por ejemplo la ubicación geográfica y la frecuencia de uso de las tarjetas. Los autores también destacan la importancia de aplicar sistemas de detección de fraude en tiempo real permitiendo una respuesta inmediata frente a transacciones sospechosas.

Con un enfoque más tradicional, Oza (2018) expone la simplicidad y efectividad de métodos clásicos como Naive Bayes para la detección de fraudes bancarios. Estos modelos son útiles cuando se trabaja con datos homogéneos y bien etiquetados. Aunque pueden en términos de precisión pueden ser superados por técnicas más avanzadas, los métodos básicos siguen siendo valiosos debido a su bajo costo computacional y facilidad de implementación.

Por su parte, Quintero Acuña (2020) propone combinar los sistemas tradicionales de detección de fraude con técnicas analíticas avanzadas de machine learning, y destaca que la actualización continua de estos modelos, mejora su adaptabilidad a nuevos esquemas de fraude. Los resultados muestran que los modelos supervisados alcanzan su rendimiento óptimo cuando utilizan conjuntos de datos recientes, teniendo mayor capacidad predictiva.

Sin embargo, la adopción de estas soluciones no está exentas de desafíos. La calidad de los datos, la interpretación de los resultados y la necesidad de transparencia en los modelos son factores críticos para su éxito. Ali et al. (2021), el autor pone énfasis en que para que exista una implementación efectiva de machine learning se requiere un balance entre los métodos de análisis (técnica) y la interpretación de los resultados. En este sentido, los algoritmos explicativos como árboles de decisión poseen una ventaja ya que permiten comprender los criterios utilizados en la detección del fraude.

El fraude en tarjetas de crédito y comercio electrónico también son objeto de múltiples estudios. Por ejemplo, Santos y Costa (2021) han constatado que al utilizar grandes volúmenes de datos históricos en modelos de Machine Learning, la capacidad para detectar patrones de fraude en tarjetas de crédito puede llegar al 95% de precisión. De manera similar, Artola Moreno (2020) subraya que algoritmos como el Gradient Boosting identifican comportamientos atípicos en las transacciones de los usuarios, optimizando la capacidad de prevención en tiempo real. Estos modelos son fundamentales, dado que el fraude en tarjetas representa pérdidas anuales de miles de millones de dólares a nivel global.

Lee y Wang (2020) por su lado, presentan una perspectiva interesante al aplicar técnicas de aprendizaje profundo para detectar fraudes en plataformas de comercio electrónico. Las redes neuronales convolucionales (CNN) y los modelos recurrentes (RNN) logran identificar transacciones fraudulentas analizando el comportamiento del usuario con sus patrones de navegación. Esta

metodología es especialmente efectiva en entornos dinámicos donde las estrategias de fraude evolucionan constantemente.

En el contexto ecuatoriano, la investigación de Pérez Tatamués (2019), sobre la aplicación Random Forest en el sistema bancario ecuatoriano, nos muestra que este método tuvo una efectividad del 92% en la detección del fraude, esto debido a su capacidad para analizar múltiples variables de manera simultánea detectando patrones irregulares en transferencias bancarias, La implementación de estas tecnologías ha ayudado a reducir las pérdidas financieras, que en 2018 fueron de más de 30 millones de dólares en el sector financiero ecuatoriano.

De la misma forma, Moya et al. (2023) proponen un modelo de prevención de fraudes basado en machine learning para transacciones digitales en Ecuador. Utilizando algoritmos supervisados como Logistic Regression y Gradient Boosting, pudieron desarrollar un sistema capaz de predecir actividades fraudulentas con alta precisión. Los resultados evidenciaron que la combinación de modelos redujo los falsos positivos, siendo esta medición un desafío importante en la implementación de soluciones automáticas.

El estudio de Mansilla Montero (2020) sobre la detección de fraudes en tiempo real utilizando tecnologías de procesamiento distribuido nos muestra que los sistemas basados en Big Data pueden analizar simultáneamente millones de transacciones, detectando fraudes de forma inmediata

Las soluciones basadas en machine learning se presentan como la principal herramienta para mitigar los impactos económicos y sociales asociados al fraude. Las investigaciones revisadas muestran que algoritmos como Random Forest, Gradient Boosting y las redes neuronales ofrecen una precisión superior, especialmente en transacciones digitales y tarjetas de crédito. Sin embargo, su efectividad depende de la calidad de los datos y de la capacidad de adaptación de los modelos a nuevos patrones de fraude.

La adopción de machine learning es un paso importante para proteger las finanzas de los usuarios, negocios y entidades financieras en Ecuador. Si bien existen desafíos técnicos y organizacionales, las investigaciones coinciden en que estas tecnologías son necesarias para construir un sistema financiero más robusto, seguro y confiable que pueda enfrentar un problema que evoluciona constantemente.

IDENTIFICACIÓN DEL OBJETO DE ESTUDIO

El fraude ha significado una amenaza dentro de las instituciones financieras tanto a nivel global como en Ecuador, donde se han registrado 17 356 denuncias por estafas financieras en lo que va del 2024, las modalidades de estafas van desde créditos fraudulentos hasta ataques cibernéticos en instituciones financieras (LaHora, 2024).

Dentro del Ecuador las instituciones financieras enfrentan crecientes amenazas cibernéticas y una mayor necesidad de proteger los activos de sus clientes, esto se vio afectado en el índice de desconfianza del sistema financiero nacional en dónde el valor fue de 5.68% y representa la tasa más alta desde el 2017 (Ecuavisa, 2024). La idea de este modelo es que sea utilizado como una herramienta estratégica que permita fortalecer la seguridad transaccional y la confianza en el sistema financiero del país.

En Ecuador, este problema no solo refleja pérdidas económicas sino también las organizaciones enfrentan retos para fortalecer sus sistemas de prevención de fraude, debido a la evolución que ha tenido las tácticas como phishing y malware avanzado que logran esquivar medidas de seguridad.

Bajo este contexto es crucial el implementar modelos predictivos basados en Machine Learning que sean más robustos y que puedan garantizar la seguridad transaccional. Con esto, se disminuiría las verificaciones manuales y reglas que han demostrado ser ineficientes frente al fraude financiero que hoy en día es un desafío cada vez más complejo y persistente.

Esta investigación busca desarrollar un modelo predictivo que permita no solo analizar grandes volúmenes de datos sino también detectar con alta precisión anomalías y minimizar el riesgo inherente en los fraudes.

PLANTEAMIENTO DEL PROBLEMA

El fraude financiero representa una amenaza que va creciendo con el pasar del tiempo, día a día las transacciones electrónicas van en aumento y el riesgo de fraude asociado va de la mano. Esto ha ocasionado pérdidas significativas dentro de la banca y además ha dañado la confianza del cliente en el sector financiero.

Según el diario *La Hora* en julio de 2024, "Se han detectado 52 entidades financieras falsas que estafan a los ecuatorianos. Esto representa, en promedio, casi 8 entidades financieras falsas detectadas cada mes". Esto es un problema crítico debido a que impacta directamente en las pérdidas financieras, daño en la reputación de la institución, costos operativos altos y sanciones por parte de los organismos de control.

Al implementar un modelo predictivo con métodos de Machine Learning, la organización puede no solo detectar en tiempo real factores anómalos sino también optar por la toma de decisiones informadas y estratégicas basadas en datos. Por otro lado, este enfoque, ayudará a optimizar recursos, reducir falsos positivos y minimizar pérdidas, así como también la adaptabilidad del modelo frente a nuevas técnicas de fraude lo convierte en una solución sostenible y estratégica para la protección de activos y la confianza del cliente (DiveX, 2024).

OBJETIVO GENERAL

Desarrollar un modelo predictivo mediante algoritmos de Machine Learning que permita detectar transacciones fraudulentas de retiros de dinero en instituciones bancarias.

OBJETIVOS ESPECÍFICOS

- Realizar un análisis exploratorio del comportamiento de las transacciones fraudulentas en la institución bancaria.
- Implementar modelos de Machine Learning, compararlos y evaluarlos mediante métricas de precisión, recall y AUC-ROC.
- Crear una estrategia organizacional basada en los resultados para el clúster bancario.

JUSTIFICACIÓN Y APLICACIÓN DE LA METODOLOGÍA

Ayudar a prevenir el fraude financiero es esencial para el clúster bancario, ya que se puede evitar pérdidas económicas que pueden afectar la reputación de la organización. El uso de técnicas de Machine Learning se ha convertido en una solución eficaz para poder prevenir actividades fraudulentas (Soto, 2024).

Bajo este argumento se propone una metodología que contiene las siguientes etapas:

- **Recolección de datos:** Obtener la información de las transacciones financieras.
- **Tratamiento de datos:** Depurar los datos para poder garantizar la calidad de los mismos.
- **Selección de Características:** Seleccionar cada una de las variables relevantes.
- **Análisis de las Variables:** Análisis descriptivo y gráfico del comportamiento de las variables.
- **Selección de Modelo:** Aplicación de algoritmos, medición y selección del modelo.

En esta metodología estructurada podemos abordar el desafío de la detección de fraudes financieros, basándonos en algoritmos de aprendizaje automático.

9.1. Recolección de datos

Esta etapa es crucial, ya que los datos son la base para el análisis y la interpretación de los resultados (Creswell & Poth, 2018). A su vez la calidad de los datos es primordial para la validez y confiabilidad de la investigación, por lo que es esencial seleccionar las técnicas adecuadas de recolección de datos que garanticen la precisión en la recopilación de la información. (Maxwell, 2013)

Sin embargo, para el desarrollo del presente proyecto, no se pudo obtener una base de datos real de alguna institución financiera, debido principalmente a la criticidad de la información, es por eso que el data set utilizado para la evaluación de los modelos predictivos se obtuvo de la plataforma Kaggle. Esta base contiene un conjunto de datos sintéticos generados por un simulador de dinero móvil denominado PaySim que se generó a partir de datos privados reales y que asemeja el funcionamiento normal de transacciones bancarias, adicional introduce un comportamiento malicioso, creando un ambiente propicio para evaluar los métodos de detección de fraudes.

Como lo explica (EA Lopez-Rojas, A. Elmir y S. Axelsson, 2016) “PaySim simula transacciones de dinero móvil basándose en una muestra de transacciones reales extraídas de un mes de registros financieros implementado en un país africano. Los registros originales fueron proporcionados por la empresa multinacional Ericsson (ericsson.com), que es el proveedor del servicio financiero móvil que actualmente se encuentra en funcionamiento en más de 14 países de todo el mundo.”

Con la ayuda de análisis estadístico, PaySim pudo desarrollar un conjunto de datos sintéticos realistas similares al conjunto de datos original, modelando no solo el comportamiento de los clientes, sino también el comportamiento fraudulento mediante agentes maliciosos que siguen patrones delictivos conocidos.

Este conjunto de datos sintéticos se reduce a 1/4 del conjunto de datos original y esta creado exclusivamente para Kaggle. El dataset contiene 6 362 620 registros con 11 columnas, no existen datos nulos y tampoco duplicados. Las variables que tiene el dataset son numéricas y categóricas.

9.2. Tratamiento de los datos

El procesamiento de datos se realizó con el objetivo de garantizar resultados significativos, los pasos que se realizaron fueron los siguientes:

- Se seleccionó únicamente la categoría “RETIRO” que son los retiros de dinero en la variable “tipo_transacción”. Esta decisión se tomó debido a la experiencia en la materia considerando que esta variable es muy frecuente dentro del ámbito financiero y presenta patrones que facilitan el análisis. De la misma manera en la revisión de la literatura se puede detectar que para el análisis de otros tipos de transacciones es necesario más información.
- Se procedió también, con la eliminación de los registros que no presentan dinero en la cuenta del emisor antes de la transacción y al no estar clasificadas como fraude en la variable “es_fraude” donde se indica si la transacción es o no fraudulenta, se consideró que no aportan valor al análisis.

Estas decisiones se tomaron basadas en la revisión literaria y en la experiencia en la detección de fraudes con el objetivo de reducir el ruido de datos y garantizar que el modelo esté alineado con el enfoque de la investigación.

9.3. Identificación y descripción de las variables

Este proceso es esencial ya que permite visualizar la naturaleza de las variables, además, ayuda a la edificación de instrumentos de recolección de datos permitiendo identificar de manera clara las variables de estudio.

Tabla 1 Matriz de descripción de variables

Variable	Fuente	Tipo de variable	Descripción
tiempo	Kaggle	Númerica	Representa una unidad de tiempo, para este caso 1 paso equivale a 1 hora de tiempo. El total de pasos es 744 (simulación de 30 días).
tipo_transaccion	Kaggle	Categórica	Tipo de transacción: DEPOSITO, RETIRO, DEBITO, PAGO, TRANSFERENCIA
monto	Kaggle	Númerica	Importe o monto de la transacción en moneda local
nombre_cliente_titular	Kaggle	Categórica	Nombre del cliente que realizó la transacción
saldo_antes_titular	Kaggle	Númerica	Saldo inicial antes de la transacción del cliente
saldo_despues_titular	Kaggle	Númerica	Nuevo saldo después de la transacción del cliente
nombre_cliente_beneficiario	Kaggle	Categórica	Nombre del destinatario de la transacción
saldo_antes_beneficiario	Kaggle	Númerica	Saldo inicial del destinatario antes de la transacción.
saldo_despues_beneficiario	Kaggle	Númerica	Nuevo saldo del destinatario después de la transacción
es_fraude	Kaggle	Binaria	Variable respuesta: 0 = No Fraude ; 1 = Fraude
fraude2	Kaggle	Binaria	Marca posible Fraude de acuerdo a un parámetro de monto: 0 = Marcado como posible No Fraude ; 1 = Marcado como posible Fraude

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes


Tabla 2 Matriz de descripción de las categorías de variable “tipo_transaccion”

Descripción de las categorías de la variable tipo_transaccion	
DEPOSITO	Es el proceso de aumentar el saldo de la cuenta mediante un depósito en efectivo
RETIRO	Es el proceso disminuir el saldo de la cuenta mediante un retiro en efectivo
DEBITO	Es un proceso que implica una disminución en la cuenta bancaria por pagos automáticos según acuerdos con negocios o débito con tarjeta
PAGO	Es el proceso de pagar bienes o servicios a comercios, lo que disminuye el saldo de la cuenta y aumenta el saldo del receptor
TRANSFERENCIA	Es el proceso de enviar dinero a otro usuario del servicio a través de una plataforma de transacciones digitales

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Figure 2 Matriz de Correlación de las variables de estudio



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

9.4. Justificación de las Variables y selección de modelos

Las variables fueron seleccionadas considerando la literatura revisada y la relevancia que tiene cada una de estas. Se tomó en cuenta las siguientes variables para esta investigación:

- “tiempo”. Representa el momento en una unidad de tiempo hora en que se realizó la transacción
- “monto”. Representa el valor de la transacción, lo que permite detectar cantidades inusuales por cada transacción.
- “saldo_antes_titular” y “saldo_despues_titular”. Permite analizar el saldo antes y después de la transacción, esto ayuda a entender el flujo de dinero e identificar actividades fraudulentas.
- “tipo_transaccion” representa el tipo de transacción que se realiza, y esta característica es un factor determinante dentro del análisis que vamos a realizar.

La variable respuesta o variable que se quiere predecir es **“es_fraude”**

Se va a considerar 3 modelos para esta investigación los cuales respaldan su eficiencia comprobada en problemas de clasificación binaria y su capacidad para manejar conjuntos desbalanceados. Los modelos seleccionados son los siguientes:

- Regresión logística se eligió este modelo debido a que es muy efectivo en problemas binarios.
- Árboles de decisión se eligió este modelo ya que ofrece interpretabilidad en las reglas de clasificación, de hecho, en la revisión de la literatura lo utilizan mucho para la detección de fraudes.

- Random Forest se eligió este modelo debido a que es muy común en el ámbito de detección de fraudes, además, ayuda con los datos desequilibrados.

También se tomaron en cuenta algunos aspectos para garantizar la eficacia del modelo:


- Se utiliza técnicas de balanceo de clases ya que en el dataset las transacciones fraudulentas son menos frecuentes que las genuinas.
- Se selecciona las variables de acuerdo a la disponibilidad, calidad e integridad de las mismas, de esta manera podemos tener información confiable.
- Los modelos seleccionados se tomaron en cuenta en base a la literatura revisada.

RESULTADOS

10.1. Análisis Exploratorio

La visualización del dataset es muy importante ya que permite poder representar el comportamiento de las variables.

Figure 3 Distribución porcentual por tipo de transacción



Elaboración: Autores
Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El 35.2% del dataset corresponde a las transacciones “RETIRO”, lo que indica que son las transacciones más frecuentes, 33.8% en “PAGO”, 22% en “DEPOSITO”, 8.4% en “TRANSFERENCIAS” y en menos porcentaje las transacciones “DEBITO” con 0.7%.

Tabla 3 Resumen estadístico de las variables de estudio


	tiempo	monto	saldo_antes_titular	saldo_despues_titular	saldo_antes_beneficiario	saldo_despues_beneficiario	es_fraude	fraude2
count	6362620.00	6362620.00	6362620.00	6362620.00	6362620.00	6362620.00	6362620.00	6362620.00
mean	243.40	179861.90	833883.10	855113.67	1100701.67	1224996.40	0.00	0.00
std	142.33	603858.23	2888242.67	2924048.50	3399180.11	3674128.94	0.04	0.00
min	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
25%	156.00	13389.57	0.00	0.00	0.00	0.00	0.00	0.00
50%	239.00	74871.94	14208.00	0.00	132705.66	214661.44	0.00	0.00
75%	335.00	208721.48	107315.18	144258.41	943036.71	1111909.25	0.00	0.00
max	743.00	92445516.64	59585040.37	49585040.37	356015889.35	356179278.92	1.00	1.00

Elaboración: Autores
Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El monto promedio por transacción es de 179,861 unidades monetarias, con un rango que va de 0 a 92,445,240. La desviación estándar muestra una alta variabilidad en todas las variables con montos.

El conjunto de datos muestra que, aunque las transacciones son fraudulentas no son tan frecuentes tiene montos de alto valor.

Figure 4 Transaccionalidad según hora del día




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la figura se observa que desde las 18h00 hasta a las 20h00 es el pico más alto de transacciones, mientras que el más bajo se registra de 01h00 a 08h00 am.

Figure 5 Montos en Transacciones legítimas y fraudulentas



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

La figura muestra los montos totales de fraude del dataset 1132.3 B de moneda local, mientras que para los fraudes el monto asciende a 12.1B de moneda local.

Figure 6 Promedio de montos por registros según transacciones legítimas y fraudulentas




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

La figura muestra el promedio por registro de las transacciones del dataset, evidenciando una gran diferencia entre las transacciones de fraude y las de no fraude. Para el caso de las transacciones fraudulentas el monto promedio por transacción es 1.47M de moneda local, mientras que para las transacciones de no fraude el monto promedio por registro es de 0.18M.

Este análisis muestra como el fraude predomina en transacciones con montos más altos en comparación a las transacciones legítimas, se puede notar que es necesario monitorear las transacciones de alto valor ya que presentan un mayor riesgo de actividades fraudulentas.

Figure 7 Distribución de fraudes



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

La figura muestra la distribución porcentual de las transacciones fraudulentas. Del total de transacciones, el 0.13% de los registros fueron fraudes mientras el 99.87% fueron transacciones legítimas. En la figura se puede mostrar que existe un desbalanceo de clases, sin embargo, en la construcción del modelo se corregirá.

Tabla 4 Fraude detectado por tipo de transacción

Es fraude	Tipo_transacción	Nro. Fraudes
0	CASH_OUT	4116
1	TRANSFER	4097

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la tabla se muestra un resumen descriptivo de los tipos de transacciones según la variable Fraude. Se puede observar que los fraudes se concentran en las transacciones Cash_out y Transfer, con montos promedios de 1.45M y 1.48M respectivamente, para el resto de transacciones no se identifican fraudes.

En las transacciones fidedignas el monto promedio en gran manera desde 130,576 en Payment y 9.06M en Transfer.

El fraude ocurre en las transacciones de Retiro y Transferencias y se encuentran caracterizadas por montos alto, lo que indica que estos tipos de transacciones requieren monitoreo.

Tabla 5 Nro transacciones fraudulentas detectadas según tipo de transacción

Los tipos de transacciones fraudulentas son ['TRANSFER', 'CASH_OUT']
El número de TRANSFER fraudulentas = 4097
El número de CASH_OUTS fraudulentas = 4116

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la tabla se puede observar que existe un total de 4097 registros para la transacción transferencias y 4116 para los retiros.

Tomando en cuenta todo el análisis anterior y la naturaleza de los datos, se decide trabajar únicamente con las transacciones de retiro de dinero. Debido a que para el mundo de las transferencias se requiere muchas más características a analizar según la revisión literaria. No se trabaja con las 2 categorías debido a que no se puede generalizar el modelo de detección de fraudes para 2 tipos de transacciones que tiene diferente entorno.

Tabla 6 Transacciones legítimas y fraudulentas en Retiro de dinero

es_fraude	
0	1207622
1	4116
Name: count, dtype: int64	


Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

De los 6,362,620 de registros se toma únicamente los registros de retiros con 1,207,622 registros de no fraude y 4,116 registros de fraude.

Al analizar la naturaleza de los retiros de dinero, se procede con la eliminación de las variables Saldo del destinatario antes y después de la transacción, porque consideramos que no aportan en el análisis.

Figure 8 Matriz de Correlación para el subconjunto de datos Retiro de Dinero



Elaboración: Autores


Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Nuestra nueva matriz de correlación se muestra en la figura, la variable monto y saldo del titular antes de la transacción tiene correlaciones positivas lo que indica que pueden ser variables relevantes para el modelo.

Las variables de los saldos de titular antes y después de la transacción están fuertemente correlacionadas lo que indica que son variables relevantes para la investigación, de la misma manera la relación entre monto y saldo de titular antes de la transacción también es moderada indicando que es una buena variable para ser considerada dentro del análisis.

En este subconjunto de datos se puede ver que las transacciones de mayor monto están altamente relacionadas con los saldos de las cuentas antes de la transacción por lo que estas variables se van a priorizar para la investigación.

Figure 9 Boxplot de Variables numéricas



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

La figura gráficos de caja para las variables numéricas seleccionas: Monto, saldo del titular antes de la transacción y el saldo después de la transacción. En cada

uno de los gráficos se puede ver las transacciones se concentran en los valores más bajos y de la misma manera para los saldos o montos altos existe un número menor de casos indicando como la distribución se encuentra sesgada.

10.2. Aplicación de modelos estadísticos

10.2.1. Random Forest

El algoritmo de Bosque Aleatorio (Random Forest) es una técnica de aprendizaje supervisado que utiliza un enfoque basado en la agrupación de varios árboles de decisión. Cada árbol es entrenado con un subconjunto aleatorio de las variables del conjunto de datos, y el modelo final se obtiene promediando las predicciones de todos los árboles en el caso de regresión, o seleccionando la clase más frecuente en clasificación. Este método se destaca por su capacidad para manejar grandes volúmenes de datos y su efectividad en situaciones con alta varianza, debido a su resistencia al sobreajuste. (Mentch, L. y Zhou, S., 2020)

Aunque la ecuación matemática exacta para un Bosque Aleatorio puede ser compleja, la idea general es que la predicción final es un promedio ponderado de las predicciones de los árboles individuales.

$$\text{Predicción_final} = (1/N) * \sum(\text{Predicción_árbol}_i)$$

Donde:

- N es el número de árboles en el bosque.
- Predicción_árbol_i es la predicción del i-ésimo árbol.

Este modelo se elige por la siguiente razón:

- Alta precisión: Reduce la varianza mejorando la precisión de las predicciones.
- Robustez: Es resistente a datos atípicos y puede manejar variables de diferentes tipos (numéricas y categóricas).

- Importancia de variables: Permite determinar qué variables son las más importantes para la predicción.

Tabla 7 Resultados de la evaluación del modelo Random Forest

Métricas		Random Forest
Train	Accuracy	100,0%
	Precision	100,0%
	Recall	100,0%
	F1-Score	100,0%
	AUC-ROC	100,0%
Test	Accuracy	99,98%
	Precision	99,95%
	Recall	100,00%
	F1-Score	99,98%
	AUC-ROC	100,00%


Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Analizando los resultados del modelo Random Forest podemos ver lo siguiente:

- Tiene un Recall del 99.98% lo que indica que detecta todos los fraudes del conjunto de datos.
- La precisión es del 99.95% que es alta, lo que es bueno para nuestro análisis.
- El F1-Score es del 99.98% lo que indica un balance casi perfecto.
- La curva de Roc tiene un desempeño excelente en la etapa de entrenamiento y prueba con un valor del 100% en cada una.

Figure 10 Matriz de Confusión con Datos de Entrenamiento – Modelo Random Forest




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la matriz de confusión con los datos de entrenamiento del modelo Random Forest se puede ver que los falsos negativos son casi nulos y no hay falsos positivos, esta matriz indica que el modelo es bastante eficaz para la detección de fraudes sin que haya muchos falsos positivos.

Figure 11 Matriz de Confusión con Datos de Prueba – Modelo Random Forest



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la matriz de confusión con los datos de prueba del modelo Random Forest se puede ver que no hay falsos negativos lo que indica que todas las transacciones de fraude fueron detectadas. Además, tiene muy pocos falsos positivos (165) lo que indica que hubo pocas transacciones que no fueron fraudes y el modelo las detectó como fraude. Esta matriz indica que el modelo es bastante eficaz para la detección de fraudes sin que haya muchos falsos positivos.

Figure 12 Sobreajuste Modelo Random Forest

El modelo Random Forest NO parece estar sobreajustado.
Entrenamiento del modelo Random Forest completado. Tiempo transcurrido: 90 segundos.

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Este modelo no se encuentra sobreajustado, lo que indica que el modelo ha aprendido bastante bien las características del conjunto de datos de entrenamiento.


Tabla 8 Reporte de Clasificación – Modelo Random Forest

Reporte de clasificación (Test):				
	precision	recall	f1-score	support
0	1.00	1.00	1.00	362287
1	1.00	1.00	1.00	362287
accuracy			1.00	724574
macro avg	1.00	1.00	1.00	724574
weighted avg	1.00	1.00	1.00	724574

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En el reporte de clasificación se puede observar que todas las predicciones positivas fueron detectadas por el modelo. El recall de 1 muestra que el modelo identificó correctamente los casos positivos en cada clase. Se puede validar que el modelo tiene un rendimiento ideal, mantiene un buen equilibrio entre precisión y recall.


Tabla 9 Importancia de las Características – Modelo Random Forest

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

La variable saldo del titular antes de la transacción (Feature_2) es la característica más importante dentro del conjunto de datos. Y esto se corrobora ya que al ser retiros de dinero el cliente debe mantener fondos en su cuenta antes de la transacción (Feature_1), caso contrario podría ser un posible fraude. La siguiente característica importante en segundo lugar es el monto de la transacción, que es crucial en el contexto de los retiros en efectivo ya que pueden presentar un patrón de fraude en montos altos o muy bajos.

Figure 13 Curva Roc – Modelo Random Forest



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El resultado de la curva Roc indica que el modelo distingue bien las transacciones de fraude y no fraude, es decir, un modelo casi perfecto. Este modelo muestra ser muy robusto ya que reduce bastante los falsos positivos y mantiene un recall perfecto.

10.2.2. Árbol de Decisión

Un árbol de decisión es un modelo de aprendizaje supervisado que utiliza una estructura jerárquica similar a un árbol para tomar decisiones. Cada nodo interno representa una prueba sobre un atributo (por ejemplo, si una característica supera un valor umbral), cada rama simboliza el resultado de dicha prueba, y cada hoja indica una clase o un valor predictivo. Al recorrer el árbol desde la raíz hasta una hoja, se alcanza una clasificación o predicción. Este modelo es altamente valorado por su capacidad de interpretación intuitiva y su adaptabilidad para manejar tanto variables categóricas como continuas. Además, los árboles de decisión suelen ser utilizados como base para métodos más avanzados, como Random Forest o Gradient Boosting (Mitchell, 1997; Quinlan, 1986).

Aunque no existe una única ecuación matemática que represente un árbol de decisión completo, la decisión de dividir un nodo en un árbol de decisión se basa

en una medida de impureza, como la entropía o el índice de Gini. Por ejemplo, la entropía de un conjunto de datos S se calcula como:

$$\text{Entropía}(S) = - \sum p(i) * \log_2(p(i))$$

Donde:

- $p(i)$ es la proporción de elementos de la clase i en S .
- La idea es encontrar la división que maximice la reducción de la impureza.

Este modelo se elige por la siguiente razón:

- Son fáciles de visualizar y entender, lo que facilita la explicación de los resultados.
- Pueden manejar tanto variables numéricas como categóricas.
- A diferencia de otros algoritmos, no es necesario escalar las características.

Tabla 10 Resultados de la evaluación del modelo árbol de Decisión

Métricas		Árbol Decisión
Train	Accuracy	100,0%
	Precision	100,0%
	Recall	100,0%
	F1-Score	100,0%
	AUC-ROC	100,0%
Test	Accuracy	99,97%
	Precision	99,94%
	Recall	100,00%
	F1-Score	99,97%
	AUC-ROC	99,97%

Elaboración: Autores


Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Analizando los resultados del modelo Árbol de decisión podemos ver lo siguiente:

- Tiene un Recall del 100% lo que indica que detecta todos los fraudes del conjunto de datos.

- La precisión es del 99.94% que es alta, lo que es bueno para nuestro análisis.
- El F1-Score es del 99.97% lo que indica un balance casi perfecto.
- La curva de Roc tiene una excelente discriminación en los datos de fraude y no fraude con 100% y 99% respectivamente.

Figure 14 Matriz de Confusión con Datos de Entrenamiento – Modelo Árbol de Decisión




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la matriz de confusión con los datos de entrenamiento del modelo Árbol de Decisión se puede ver que no hay falsos negativos y tampoco falsos positivos, esta matriz indica que el modelo es bastante eficaz para la detección de fraudes sin que haya muchos falsos positivos.

Figure 15 Matriz de confusión con Datos de Prueba – Modelo Árbol de Decisión



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En la matriz de confusión del modelo árbol de Decisión se puede ver que no hay falsos negativos lo que indica que todas las transacciones de fraude fueron detectadas. Además, tiene muy pocos falsos positivos (230) lo que indica que hubo pocas transacciones que no fueron fraudes y el modelo las detectó como fraude. Esta matriz indica que el modelo es bastante eficaz para la detección de fraudes sin que haya muchos falsos positivos.

Figure 16 Sobreajuste modelo Árbol de Decisión

El modelo Árbol de Decisión NO parece estar sobreajustado.
Entrenamiento del modelo Árbol de Decisión completado. Tiempo transcurrido: 10 segundos.

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Este modelo no se encuentra sobreajustado, lo que indica que el modelo ha aprendido bastante bien las características del conjunto de datos de entrenamiento.

Tabla 11 Reporte de Clasificación – Modelo Árbol de Decisión


Reporte de clasificación (Test):				
	precision	recall	f1-score	support
0	1.00	1.00	1.00	362287
1	1.00	1.00	1.00	362287
accuracy			1.00	724574
macro avg	1.00	1.00	1.00	724574
weighted avg	1.00	1.00	1.00	724574

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En el reporte de clasificación se puede observar que no hubo falsos positivos debido a que todas las predicciones positivas fueron detectadas por el modelo. El recall de 1 muestra que el modelo identificó correctamente los casos positivos en cada clase. Se puede validar que el modelo tiene un rendimiento ideal, mantiene un buen equilibrio entre precisión y recall.

Tabla 12 Importancia de las Características – Modelo Árbol de Decisión




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El saldo del titular antes de la transacción (Feature_2) es la característica más importante dentro del conjunto de datos. Y esto se corrobora ya que al ser retiros de dinero el cliente debe mantener fondos en su cuenta antes de la transacción. La siguiente característica importante y en segundo lugar es el monto de la transacción, esto también es crucial en el contexto de los retiros en efectivo.

Figure 17 Curva Roc – Modelo Árbol de Decisión



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El resultado de la curva Roc indica que el modelo distingue bien las transacciones de fraude y no fraude, es decir, un modelo muy bueno. Este

modelo muestra un desempeño muy bueno, además de tener un buen balance entre precisión y recall.

10.2.3. Regresión Logística

La regresión logística es un modelo estadístico ampliamente utilizado para predecir la probabilidad de que una observación pertenezca a una de dos categorías posibles, siendo un modelo clásico de clasificación binaria. A diferencia de la regresión lineal, que predice valores numéricos continuos, la regresión logística utiliza la función sigmoide para transformar las predicciones en probabilidades, permitiendo modelar la probabilidad de ocurrencia de un evento, como determinar si una transacción es fraudulenta o si un paciente tiene una enfermedad (Hosmer et al., 2013; Menard, 2002). Este modelo se basa en la relación entre las variables independientes y la probabilidad del evento mediante el logit, que es el logaritmo natural de las probabilidades (Menard, 2002).

La regresión logística utiliza una función logística, que transforma una combinación lineal de los predictores en una probabilidad entre 0 y 1. La ecuación general de la regresión logística es:

$$p(y=1|x) = 1 / (1 + \exp(-(\beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_nx_n)))$$

Tabla 13 Resultados de Evaluación del modelo de Regresión Logística

Métricas		Regresión Logística
Train	Accuracy	96,56%
	Precision	94,25%
	Recall	99,18%
	F1-Score	96,65%
	AUC-ROC	99,22%
Test	Accuracy	96,56%
	Precision	94,22%
	Recall	99,20%
	F1-Score	96,65%
	AUC-ROC	99,23%


Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Analizando los resultados del modelo Regresión Logística podemos ver lo siguiente:

- Tiene un Recall del 99.20 % lo que indica que detecta la mayoría de fraudes.
- La precisión es del 94.22% lo que indica que se hay falsos positivos.
- El F1-Score es del 96.65% lo que indica que hay un buen balance entre precisión y recall.
- La curva de Roc tiene una excelente discriminación entre fraudes y no fraudes en los datos de entrenamiento y prueba con 99.2% y 99.23% respectivamente.

Figure 18 Matriz de Confusión para Datos de Entrenamiento – Modelo Regresión Logística




Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

- El modelo tiene una buena capacidad para clasificar las clases de fraude, sin embargo, hay un número considerable dentro de los falsos positivos, los cuáles al ser clasificados como posibles fraudes puede incurrir en costos operativos y en la reputación de la organización debido a las molestias por parte de los clientes.

Figure 18 Matriz de Confusión para Datos de Prueba – Modelo Regresión Logística



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Este modelo muestra un mayor número de falsos negativos (2893), lo que indica que muchas transacciones fraudulentas no fueron detectadas por el modelo. De la misma manera tiene un alto número de falsos positivos.

Figure 19 Sobreajuste modelo Regresión Logística

El modelo Regresión Logística NO parece estar sobreajustado.
Entrenamiento del modelo Regresión Logística completado. Tiempo transcurrido: 8 segundos.

Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

Este modelo no se encuentra sobreajustado, lo que indica que el modelo ha aprendido bastante bien las características del conjunto de datos de entrenamiento.

Tabla 14 Reporte de Clasificación – Modelo Regresión Logística

Reporte de clasificación (Test):				
	precision	recall	f1-score	support
0	0.99	0.94	0.96	362287
1	0.94	0.99	0.97	362287
accuracy			0.97	724574
macro avg	0.97	0.97	0.97	724574
weighted avg	0.97	0.97	0.97	724574


Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

En el reporte de clasificación muestra que el modelo es bastante preciso para clasificar no fraude, sin embargo, en la clasificación del fraude con 0.94 muestra

que hubo una incorrecta clasificación en estos casos. En Recall se puede ver que hay un 6% de falsos negativos en la clase 0 mientras que para la clase 1 se detecta correctamente el 99% de los fraudes. Existe un buen equilibrio entre recall y precisión para ambas clases, el modelo presenta una exactitud alta en todas las predicciones.

Figure 20 Curva Roc – Modelo de Regresión Logística



Elaboración: Autores

Fuente: Kaggle. Datos financieros sintéticos para la detección de fraudes

El resultado de la curva ROC indica que el modelo distingue bien las transacciones de fraude y no fraude, es decir, un modelo bueno. Este modelo muestra un desempeño inferior a los otros 2 modelos revisados ya tiene un número alto de falsos negativos y falsos positivos.

Los códigos utilizados para el desarrollo del modelo de detección de fraude en transacciones bancarias están publicados en un repositorio de GitHub (Alcivar & Condolo, 2024).

DISCUSIÓN DE LOS RESULTADOS Y PROPUESTA DE SOLUCIÓN

11.1. Rendimiento de los modelos

El modelo de regresión logística muestra un buen desempeño general, su recall de 99.20% y AUC-ROC de 99.23% muestra que el modelo es capaz de detectar la mayoría de fraudes y tiene una buena capacidad para identificar las transacciones fraudulentas y las reales.

Por otro lado, el modelo árbol de decisión tiene un recall perfecto del 100% y una precisión del 99.95% lo que indica que detecta la mayoría de los fraudes, tiene pocos falsos positivos 230 lo que indica que pocas transacciones fueron mal clasificadas.

Por último, el modelo random forest al igual que el árbol de decisión tiene un recall del 100% y en AUC-ROC de 100% lo que muestra la excelente capacidad de identificaciones de transacciones fraudulentas y reales. Este modelo tiene menos falsos positivos que el árbol de decisión y cero falsos negativos lo que muestra que detecta todos los fraudes del conjunto de datos.

11.2. Falsos Positivos y Negativos de los modelos

El modelo de regresión logística tiene 22,029 falsos positivos, es decir, transacciones reales clasificadas como fraude. Este valor puede afectar a los clientes en sus transacciones debido a que pueden afrontar inconvenientes en el retiro de su dinero. Por otro lado, también presenta 2,893 falsos negativos esto indica que estas transacciones no fueron detectadas por el modelo y si eran transacciones fraudulentas. Este valor incurre en pérdidas financieras significativas para las instituciones financieras.

El modelo árbol de decisión muestra cero falsos negativos, lo que es muy importante en la detección de fraudes en retiros de dinero. Este modelo también muestra un mínimo de falsos positivos, este dato si puede ser manejable operativamente.

Por último, el modelo random forest muestra que todas las transacciones fraudulentas son identificadas, esto en una prioridad en retiros de dinero. El modelo también muestra un valor más bajo de falsos positivos comparándolo con el modelo de árbol de decisión. Este bajo volumen de transacciones que pueden ser revisadas operativamente genera un impacto caso nulo en la experiencia del cliente.

11.3. Aplicabilidad en fraudes financieros

El modelo de regresión logística a pesar de tener un buen balance entre precisión y recall, tiene un alto número de falsos negativos lo que apunta a no ser la mejor opción en un escenario de riesgo como es el retiro de dinero, donde cada fraude no detectado incurre en pérdidas económicas en las instituciones financieras.

Por otro lado, el modelo de árbol de decisión puede ser ideal ya que no pasa desapercibido ningún fraude, sin embargo, el rendimiento perfecto puede indicar un sobreajuste lo que implicaría no tener un buen desempeño en futuros casos.

Por último, el modelo de random forest es el más robusto y menos propenso a sobreajuste debido a que maneja múltiples árboles, lo que lo hace más confiable en los datos reales.

11.4. Elección del mejor modelo

Dentro del mundo de detección de fraudes en transacciones de retiro de dinero el mejor modelo debe cumplir con ciertos requisitos que permitan la opción más adecuada para evitar pérdidas en las instituciones financieras.

Cada fraude no detectado implica un impacto financiero y reputacional en la institución, de la misma manera se debe tratar de que el modelo no minimice los falsos positivos ya que esto puede generar costos operativos adicionales y molestias en los clientes, así mismo el modelo debe mantenerse robusto frente a datos futuros ya que los patrones de fraude van evolucionando constantemente.

El modelo de regresión logística muestra un desempeño bueno, sin embargo, mantiene un número alto de falsos negativos. Por otro lado, el modelo de árbol de decisión tiene un número bajo de falsos positivos y un recall perfecto pero su tendencia a sobreajuste muestra riesgos en nuevos patrones de fraude. Por último, el modelo random forest tiene un recall perfecto, es el modelo con el número más bajo de falsos positivos y además es bastante robusto frente al sobreajuste.

Se elige el modelo Random Forest por su excelente balance entre precisión, recall y capacidad de generalización, es la opción más adecuada para detección de fraudes en transacciones de retiro de dinero.

11.5. Estrategia de implementación

La adopción del modelo Random Forest, permitirá mejorar los procesos relevantes del negocio rediseñando estrategias de alto impacto que serán dirigidas al cumplimiento de los objetivos de la organización.

Para la selección del modelo apropiado se utilizó una base de datos sintética externa de Kaggle, sin embargo, es necesario que el modelo se adapte al contexto nacional, para ello es fundamental la integración de nuevas variables que incrementen su capacidad predictiva a otros tipos de transacciones como transferencias, débitos automáticos, e incluso depósitos en los que se puede detectar irregularidad, abriendo el panorama a otras problemáticas como el lavado de activos, entre otros.

Interfaz para detección en tiempo real. - Integrar el modelo a un aplicativo que permita de manera sistemática y automatizada alertar en tiempo real posibles transacciones fraudulentas para tomar acción sobre ellas.

Unidad integrada de análisis de fraude y gestión de data. - Conformar un equipo de profesionales en las áreas de análisis de datos y tecnologías de la información, que trabajen en sinergia bajo un sistema que integre las operaciones clave guiando la implementación del modelo y su aplicación.

Autenticación reforzada. – Establecer un método adicional de autenticación en retiros de dinero sin tarjeta específicamente en cajeros automáticos, cuando el algoritmo clasifique una posible transacción fraudulenta, el sistema integrado de prevención de fraude solicitará un código adicional que será enviado al teléfono del titular, mismo que será registrado en el cajero, asegurando la legitimidad de la transacción, esta medida se integrara a los mecanismos y reglas actuales de prevención como por ejemplo montos máximos de retiros por día

Adaptación del modelo al contexto nacional. - Las formas de fraude evolucionan constantemente, esto implica identificar patrones emergentes y garantizar la incorporación de nuevas variables al entrenamiento del modelo. Información como historial crediticio, patrones de comportamiento, black list, y otros datos transaccionales deben ser evaluados. Este enfoque permite adaptar la herramienta a las cambiantes estrategias fraudulentas, manteniendo su eficacia y capacidad predictiva

Integración con el sistema de gestión de riesgos. -. Integrar con medidas proactivas para la prevención tales como:

- Umbrales de riesgo
- Script de reglas
- Puntuación de riesgo

El alcance de la gestión de riesgos debe incluir el aprendizaje constante de las nuevas formas de fraude que se aplican a nivel mundial.

Monitoreo y evaluación constante. – Revisión periódica del modelo con la adopción de nuevas variables y su efectividad.

Capacitación y Cultura Organizacional. - La prevención del fraude también requiere un cambio cultural dentro de las instituciones. Es importante capacitar a los empleados en la interpretación de resultados y en la identificación de riesgos, fomentando una cultura de responsabilidad y prevención.

11.6. Beneficios empresariales asociados a la implementación.

La implementación de un modelo de Machine Learning para detección de fraude no solo aborda los riesgos inherentes a la actividad financiera, sino que también impacta de manera directa otros procesos de negocio clave de la organización, generando un impacto significativo en la innovación empresarial y ofreciendo nuevas oportunidades para incrementar los beneficios organizacionales.

El beneficio más evidente es la reducción de pérdidas financieras, por su puesto esto da mayor seguridad a los clientes lo que se traduce en confianza hacia la entidad financiera y una relación de largo plazo más sólida.

La detección automatizada de transacciones sospechosas reduce el tiempo y los costos asociados a la identificación manual del fraude (Gómez-Rodríguez et al., 2022). Esto libera recursos que deben ser reasignados a otras iniciativas estratégicas haciendo la operación más eficiente.

Bajo el mismo concepto la implementación de cualquier modelo predictivo permite a las instituciones cumplir con normativas internacionales de prevención

del lavado de dinero y financiamiento al terrorismo, evitando sanciones legales y protegiendo su reputación.

La analítica de datos también se ve fortalecida con este tipo de sistemas. Al recopilar información sobre los comportamientos transaccionales del usuario, las instituciones financieras no solo mejoran su capacidad de detección, sino que también obtienen insights valiosos para la toma de decisiones estratégicas, esto servirá para comprender mejor a los clientes, ajustar los perfiles de riesgo y desarrollar nuevos productos financieros.

Todas estas oportunidades contribuyen a la creación de ventajas competitivas sostenibles para la organización al reducir pérdidas financieras, mejorando la rentabilidad (Zapata Yáñez, 2024).

11.7. Nuevas estrategias impulsadas por la detección de fraude

Aprovechando las mejoras derivadas del sistema de detección de fraude, las entidades financieras tendrán nuevas herramientas que les permitan implementar nuevas estrategias que incrementen sus beneficios.

Una de las más efectivas es la monetización de la tecnología, ofreciendo el sistema como un servicio (Fraud Detection as a Service) a otras entidades financieras que carecen de los recursos para desarrollar sus propias soluciones, como por ejemplo las cooperativas de ahorro y crédito.

Otra estrategia clave es la creación de programas de fidelización que resalten el compromiso de la entidad con la seguridad financiera. Estos programas incluirán beneficios exclusivos, como tasas de interés preferenciales o productos financieros personalizados, que refuercen la percepción de valor por parte de los usuarios permitiendo incrementar el portafolio de clientes.

La segmentación avanzada de clientes también juega un rol importante. Al utilizar los datos generados por los sistemas de detección, las instituciones tienen la posibilidad de identificar perfiles de riesgo para diseñar productos adaptados a las necesidades específicas de cada segmento. Esto no solo mejora la experiencia del cliente, sino que también reduce la morosidad y mejora la rentabilidad general.

Finalmente, la colaboración con startups y empresas tecnológicas ayudaran a potenciar las capacidades del sistema, permitiendo el desarrollo de soluciones innovadoras y generando sinergias que beneficien a ambas partes.

A través de estrategias bien definidas, las entidades financieras tienen la capacidad de transformar esta tecnología en una ventaja competitiva que impulse sus beneficios y refuerce su posición en el mercado.

11.8. Relación con la innovación empresarial.

La adopción de sistemas de detección de fraude está estrechamente vinculada con la innovación empresarial. En primer lugar, impulsa la digitalización y la automatización de procesos clave, mejorando la eficiencia operativa y reduciendo los errores humanos. Además, el uso de tecnologías avanzadas como la inteligencia artificial, el big data y los algoritmos predictivos posiciona a la entidad como un líder tecnológico en el sector financiero.

Un aspecto destacable es la creación de nuevos productos y servicios. La experiencia adquirida al gestionar datos y prevenir fraudes puede ser aprovechada para desarrollar soluciones de ciberseguridad dirigidas a clientes corporativos. Esto no solo diversifica las fuentes de ingresos de la entidad, sino que también refuerza su reputación como un socio confiable en un entorno empresarial cada vez más digitalizado.

CONCLUSIONES Y RECOMENDACIONES

De acuerdo con los resultados obtenidos, el modelo de Random Forest clasifica de mejor manera los casos de fraude relacionados con el retiro de dinero en instituciones financieras, obteniendo métricas sobresalientes en precisión, sensibilidad y especificidad. Sus métricas de Recall 100% y AUC-ROC del 100% garantizan que las transacciones son correctamente identificadas, así mismo el modelo demuestra su efectividad obteniendo menos falsos positivos minimizando el impacto operativo y el malestar en los clientes.

Los conocimientos generados a partir de la implementación del modelo permitirán una mayor adaptabilidad al contexto nacional. Las instituciones financieras podrán identificar tendencias emergentes y ajustar sus estrategias de manera proactiva, demostrando una cultura organizacional comprometida con la innovación y la mejora continua.

Un sistema de detección de fraude no solo mitiga los riesgos asociados a las transacciones bancarias, sino que también actúa como un catalizador para la innovación empresarial y el crecimiento sostenible

Se recomienda que dentro de los modelos de prevención de fraudes en el contexto de retiros de dinero que actualmente manejan en las organizaciones se sumen también las variables de investigación analizadas en este estudio debido a que mostraron ser cruciales en la detección de fraudes y pueden ayudar a disminuir costos operativos y mejorar la eficiencia de los modelos que ya manejan las organizaciones.

Así mismo, entidades financieras de pequeño tamaño que no tengan capacidad analítica para implementar un sistema robusto de detección de fraude pueden adoptar el modelo propuesto como base para implementación en sus organizaciones.

REFERENCIAS

- López-Rojas, E. (2016). *Conjuntos de datos financieros sintéticos para la detección de fraudes. [Conjunto de datos]. Kaggle. Recuperado de <https://www.kaggle.com/datasets/ealaxi/paysim1/data>*
- Asociación de Bancos Privados del Ecuador (ASOBANCA). (2023). *Boletín macroeconómico: Canales bancarios: ¿Qué prefieren los ecuatorianos?. Recuperado de <https://datalab.asobanca.org.ec/mapa-ec/internal-map.html>*
- Ali, A., Razak, S. A., Othman, S. H., Al-Dhaqm, A., Nasser, M., Elhassan, T., ... & Eisa, T. A. E. (2021). Financial Fraud Detection Based on Machine Learning: A Systematic Literature Review.
- Mansilla Montero, J. (2020). Detección de fraude bancario en tiempo real utilizando tecnologías de procesamiento distribuido.
- Carmona Mora, M., & Londoño Morales, L. M. (2021). Modelos de machine learning para la detección de fraude financiero.
- Kazeem, O. (2023). Fraud Detection using machine learning.
- Afriyie, J. K., Tawiah, K., Pels, W. A., Addai-Henne, S., Dwamena, H. A., Owiredue, E. O., Amening Ayeh, S., & Eshun, J. (2023). A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions.
- Oza, A. (2018). Fraud Detection using Machine Learning.
- Quintero Acuña, L. K. (2023). Aplicación de Machine Learning a un modelo tradicional de prevención y detección de fraude en entidad financiera proyectado a periodos trimestrales.
- Artola Moreno, A. (2023). Crimen financiero – detección de fraude en tarjetas de crédito aplicando aprendizaje automático.
- Pérez Tatamués, E. A. (2019). Algoritmo de random forest aplicado a la detección de fraude en el sistema bancario ecuatoriano. Escuela Politécnica Nacional, Quito. Recuperado de bibdigital.epn.edu.ec

- Moya, O., et al. (2023). Diseño de un modelo de prevención de fraudes en transacciones digitales con técnicas de machine learning. Universidad Internacional del Ecuador, Quito. Recuperado de repositorio.uide.edu.ec
- Santos, E., & Costa, F. (2021). Machine Learning for Credit Card Fraud Detection. *Journal of Financial Analysis and Decision Making*, 38(4), 245-258. Recuperado de <https://journal-financial-studies.com>
- Lee, J., & Wang, T. (2020). Deep Learning and Fraud Detection in E-commerce. *International Journal of AI in Business*, 12(2), 98-115. Recuperado de <https://ai-business-journal.org>
- Gupta, R., & Singh, K. (2022). Fraud Detection Using Blockchain and AI. *Journal of Blockchain Applications*, 8(1), 53-69. Recuperado de <https://blockchain-research.org>
- Müller, A., & Fischer, L. (2019). Fraud Detection in Online Banking Systems Using SVMs. *European Journal of Financial Technology*, 7(3), 145-160. Recuperado de <https://european-fintech-journal.org>
- Johnson, P., & Martinez, C. (2023). Adapting Fraud Models to Emerging Threats in Digital Banking. *Journal of Banking Innovation*, 10(5), 215-230. Recuperado de <https://banking-innovation.org>
- Chen, Y., & Zhang, H. (2021). Efficiency of Unsupervised Learning in Fraud Detection. *Journal of Machine Learning Applications*, 14(7), 322-340. Recuperado de <https://ml-applications-journal.org>
- DiveX, C. E. (23 de agosto de 2024). *officedivex.com*. Recuperado de <https://officedivex.com/tiempo-real-operaciones-criticas>
- Soto, D. (3 de Agosto de 2024). *tresastronautas.com*. Recuperado de https://www.tresastronautas.com/es/blog/enhancing-fraud-detection-with-machine-learning-algorithms?utm_source=chatgpt.com
- EA Lopez-Rojas, A. Elmir y S. Axelsson. (2016). *PaySim: conjunto de datos de transacciones financieras*. Recuperado de <https://www.kaggle.com/datasets/ealaxi/paysim1/data>
- Creswell, JW y Poth, CN (2018). *Investigación cualitativa y diseño de investigación: elección entre cinco enfoques*.

- Maxwell, JA (2013). *Diseño de investigación cualitativa: un enfoque interactivo* (3.^a ed.).
- Mentch, L. y Zhou, S. (2020). Aleatorización como regularización: una explicación de los grados de libertad para el éxito de los bosques aleatorios. *Journal of Machine Learning Research*, 21. Recuperado de <https://jmlr.org/papers/volume2/19-905/1-905.pdf>
- Mitchell, TM (1997). *Aprendizaje automático*. McGraw-H.
- Quinlan, JR (1986). Inducción de árboles de decisión. *Aprendizaje automático*, 1
- Hosmer, DW, Lemeshow, S. y Sturdivant, RX (2013). *Regresión logística aplicada* (3.^a ed.). Wiley. Recuperado de <https://doi.org/10.1002/9781118548387>
- Menard, S. (2002). *Análisis de regresión logística aplicada* (2da edición). Recuperado de <https://doi.org/10.413/9781412983433>
- Alcívar, S. y Condolo, J. (2024). *Modelo de detección de fraude en transacciones bancarias* [Repositorio en GitHub]. GitHub. <https://github.com/Condolo88/ModeloDeteccionFraude/blob/main/Modelode-teccionfraude.ipynb>

ANEXOS

ANEXO 1: MATRIZ DE REVISIÓN LITERARIA

	Artículo	Autor (es)	Año publicación	Tipo de datos	Metodología de análisis	Implicaciones gerenciales
1	Modelos de machine learning para la detección de fraude financiero	Maricela Carmona Mora Leidy Marcela Londoño Morales	2021	Base de datos de Kaggle. Numero de observaciones: 6362619 Variables numericas: 8 Variables categoricas: 3 Variable objetivo: "IsFraud"	Análisis descriptivo Regresión logística Random forest Naive Bayes Redes neuronales	Establecer modelos que detecten amenazas en tiempo real para reducir pérdidas económicas por fraude en el sector financiero
2	Fraud Detection using machine learning	Oladimeji Kazeem	2023	Base de datos de Kaggle. Numero de observaciones: 10000 Variables numericas: 8 Variables categoricas: 3 Variable objetivo: "IsFraud"	Preprocesamiento de datos. Análisis exploratorio de datos Logistic Regression Decision trees Random Forest Suport Vector Machines (SVM)	Explorar medidas proactivas para la prevención del fraude, como puntuación de riesgo dinámica y umbrales adaptativos. Analizar las consideraciones de escalabilidad y despliegue para implementar el sistema propuesto en instituciones financieras del mundo real.
3	A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions	Jonathan Kwaku Afriyie Kassim Tawiah Wilhemina Adoma Pels Sandra Addai-Henne Harriet Achiaa Dwamena Emmanuel Odame Owiredo Samuel Amening Ayeh John Eshun	2023	Base de datos de Kaggle. Numero de observaciones: 555719 Variables numericas: 10 Variables categoricas: 13 Variable objetivo: "IsFraud"	Preprocesamiento de datos. Logistic Regression Decision trees Random Forest	Determinar el modelo que detecte con mayor precisión los fraudes en transacciones con tarjetas de credito
4	Fraud Detection using Machine Learning	Aditya Oza	2018	Base de datos de Kaggle. Numero de observaciones: 6362620 Variables numericas: 8 Variables categoricas: 3 Variable objetivo: "IsFraud"	Preprocesamiento de datos. Análisis exploratorio de datos Logistic Regression Suport Vector Machines (SVM) Class weights based approach	Diseñar un sistema de detección de fraude preciso y eficiente que tenga pocos falsos positivos pero que detecte la actividad fraudulenta de manera efectiva

	Artículo	Autor (es)	Año publicación	Tipo de datos	Metodología de análisis	Implicaciones gerenciales
5	Aplicación de Machine Learning a un modelo tradicional de prevención y detección de fraude en entidad financiera proyectado a periodos trimestrales	Lady Katherine Quintero Acuña	2023	Base de datos de Banco. Numero de observaciones: 500 Variables numericas: 3 Variables categoricas: 15 Variable objetivo: "Fraud"	Analisis exploratorio de datos Limpieza y transformacion de datos Regresión logística Random Forest	Implementar un modelo de machine learning que complemente al modelo tradicional de prevención y detección de fraude en una entidad financiera proyectado a periodos trimestrales
6	Crimen financiero – detección de fraude en tarjetas de crédito aplicando aprendizaje automático.	Alvaro Artola Moreno	2023	Base de datos de Kaggle. Numero de observaciones: 284807 Variables numericas: 10 Variables categoricas: 13 Variable objetivo: "IsFraud"	Analisis exploratorio de datos Regresión logística El algoritmo KNN (k-nearest neighbours) SVM (Support Vector Machine) Árbol de decisión (Decision Tree) Bosque Aleatorio (Random Forest) XGBoost (Extreme Gradient Boosting)	Informar el desarrollo de los modelos predictivos que se implementarán en este proyecto para prevenir y detectar el fraude financiero.
7	Application of Machine Learning Models in Fraud Detection in Financial Transactions	Dávila-Morán RC Castillo-Sáenz RA Vargas-Murillo AR Dávila LV García-Huamantumba E García-Huamantumba C	2023	Base de datos de diferentes instituciones financieras Este contenía información detallada como perfiles demográficos, historial de compras y características bancarias de miles de clientes	Imputación múltiple por regresión para llenar valores perdidos transformación de variables mediante normalización z-score Regresión logística Random Forest Redes neuronales Naive Bayes	Demostrar la eficacia de los modelos de aprendizaje automático, especialmente los Random Forest y las Redes neuronales convolucionales, para una detección precisa del fraude en tiempo real
8	Credit Card Fraud Detection Using Machine Learning	Meera AlEmad	2022	Base de datos de Kaggle. Numero de observaciones: 284808 Variables numericas: 10 Variables categoricas: 13 Variable objetivo: "IsFraud"	Preprocesamiento de datos. Algorithm (KNN) Naive Bayes Logistic Regression Support Vector Machine	Encontrar el modelo más adecuado en la detección de fraude con tarjetas de crédito en términos de las técnicas de aprendizaje
9	Financial Fraud Detection Based on Machine Learning: A Systematic Literature Review	Abdulalem Ali Shukor Abd Razak Siti Hajar Othman Arafat Al-Dhaqm Maged Nasser Tusneem Elhassan Hashim Elshafie Abdu Saif Taiseer Abdalla Elfadil Eisa	2022	No especifica	Comparacion de los siguientes modelos: SVM HMM ANN Fuzzy Logic KNN Decisión Tree Genetic Algorithm Ensemble Logistic Regression Clustering Random Forest Naive Bayes	Siintetizar sistemáticamente la literatura existente sobre la detección de fraude basada en ML, comparando tipos de fraude y modelos aplicados

	Artículo	Autor (es)	Año publicación	Tipo de datos	Metodología de análisis	Implicaciones gerenciales
10	Revisión de literatura sobre las técnicas de Machine Learning en la detección de fraudes bancarios	Julio Alvarado Zabala Ivette Martillo Alchundia Geomar Guzman Seraquive	2021	No especifica	Redes Neuronales Random Forest Naive Bayes Maquinas vectoriales de soporte Modelos lineales generalizados	Evaluar la literatura existente con el objetivo de sintetizar una comparativa entre los diferentes modelos de ML aplicados a la detección de fraudes
11	Detección de fraude bancario en tiempo real utilizando tecnologías de procesamiento distribuido	Javier Mansilla Montero	2016	No especifica	Modelo estadístico: Gaussiana o la Poisson Modelo basado en la densidad relativa Modelos basados en la proximidad Redes neuronales	Diseñar e implementar un sistema capaz de detectar fraudes de tarjetas de crédito usando dos tecnologías punteras especializadas en procesamiento de datos en tiempo real.
12	Detecting Financial Fraud Using Data Mining Techniques: A Decade Review from 2004 to 2015	Mousa Albashrawi ¹	2016	No especifica	Detecting financial fraud financial fraud and data mining financial fraud detection, detecting financial fraud via data mining	Otorgar una revisión actualizada, integral y en profundidad que pueda ayudar a las empresas a seleccionar la técnica de minería de datos adecuada
13	Comparative Review of Credit Card Fraud Detectio using Machine Learning and Concept Drift Techniques	Oluwadare Samuel Adebayo Thompson Aderonke Favour-Bethy Owolafe Otasowie Orogun Adebola Okunola	2023	No especifica	Artificial Neural Network (ANN) Support Vector Machine (SVM) Naive Bayes Classifier (NB) k-Nearest Neighbour (kNN) Logistic Regression (LR) Decision Trees (DT)	Destacar la importancia de las técnicas de aprendizaje automático y los métodos para la detección de fraudes con tarjetas de crédito
14	Detección de Fraude en tarjetas de crédito mediante técnicas de IA	Cristian Lameiro Juan Manuel Medina Walter Sanchez	2020	Origen: Alemania, recolectado por el Profesor Dr. Hans Hofmannel de la Universidad de Hamburgo Numero de Observaciones: 1000 20 atributos	Arboles de decisión Métodos Bayesianos Algoritmos Basados en Instancias u Holgazanes Redes neuronales	Descubrir los clasificadores más adecuados para la predicción de fraude con tarjetas a partir de datos de transacciones

Elaboración: Autores

ANEXO 2: CÓDIGO DEL PROYECTO

Enlace al repositorio Github con el código del proyecto:

<https://github.com/Condolo88/ModeloDeteccionFraude/blob/main/Modelodeteccionfraude.ipynb>

