UNIDAD 1

Fundamentos de Analítica de Datos.

TEMA 2:

Metodología Datlas para analítica.

Descripción:

Hoy en día, el análisis de datos es una herramienta estratégica para las empresas que ayuda a transformar los datos en valor, lo que a su vez respalda las decisiones empresariales.
El contenido del módulo introduce conceptos básicos de análisis y minería de datos, estableciendo su aplicabilidad en diferentes contextos.
Se discutirán los tipos de métodos descriptivos, predictivos y prescriptivos, diferenciando sus características, objetivos y aplicaciones.
Además, se cubrirá el ciclo de vida de un proyecto de análisis de datos, comenzando desde la definición del problema, pasando por la implementación de la solución, y proporcionando al estudiante una visión clara de los procesos que guían la práctica analítica. Por último, se mostrarán aplicaciones en la industria, dirigidas a reconocer cómo se aplica el análisis a la innovación, la competitividad y la mejora continua.

Metodologías de Analítica de Datos.

PERIODO ACADÉMICO 2026-1S

TABLA DE CONTENIDO

Tema 2. Metodología Datlas para analítica. 2
2.1. Origen y fases de la metodología Datlas. 2
2.2. Descripción del proceso paso a paso de la metodología Datlas. 8
2.3. Aplicaciones de Datlas en proyectos de negocio. 12
2.4. Ventajas y limitaciones de Datlas frente a otros modelos. 19
Bibliografía 24

Tema 2. Metodología Datlas para analítica.

2.1. Origen y fases de la metodología Datlas.

La metodología Datlas surge de la necesidad de contar con un proceso estructurado para guiar proyectos de análisis de datos de principio a fin. A inicios de la década de 2020, el equipo de Datlas (una iniciativa de analytics) desarrolló este enfoque como respuesta al crecimiento exponencial de los datos y a la complejidad de extraer conocimiento útil de ellos.

Se buscaba formalizar los pasos de descubrimiento y obtención de conocimiento dentro de un marco estandarizado de Ciencia de Datos. En otras palabras, **la metodología Datlas fue concebida para ofrecer un mapa claro** (de ahí su nombre, que evoca un "atlas" de datos) que orientase a científicos y analistas de datos a través de cada etapa de un proyecto, asegurando rigurosidad sin perder la flexibilidad necesaria para adaptarse a distintos contextos.

Desde sus inicios, la metodología Datlas se diseñó con varios principios rectores.

Primero, pone énfasis en la claridad y la comunicación: un método bien definido facilita la comprensión común del proyecto entre todos los involucrados. Esto responde al reconocimiento de que un proyecto de datos exitoso no solo depende del análisis técnico, sino también de la alineación con los objetivos del negocio y la colaboración interdisciplinaria.

Segundo, promueve la accesibilidad y la precisión en el análisis. Es decir, la metodología procura ser asequible para los equipos (incluso aquellos sin gran experiencia en ciencia de datos) a la vez que asegura resultados confiables. Este equilibrio entre facilidad de aplicación y rigor analítico ha sido un factor clave en su adopción práctica.

Tercero, Datlas incorpora el principio de iteratividad controlada: aunque define fases secuenciales, permite retroalimentación y ajustes continuos. Si los resultados de cierta etapa no satisfacen los criterios esperados, el método contempla revisar pasos previos y refinar el enfoque hasta lograr los objetivos establecidos. Este carácter flexible pero trazable distingue a **Datlas como una metodología pragmática**, preparada para abordar la naturaleza experimental de la analítica de datos.

A lo largo de su evolución, la metodología Datlas ha incorporado mejoras para mantenerse alineada con las mejores prácticas hasta 2025.

Recientemente, en 2024, se reforzaron aspectos de gestión del proyecto de datos dentro del marco metodológico. En su versión actual, **Datlas no solo describe qué hacer en cada fase, sino también cómo gestionar el proceso de forma óptima**. Por ejemplo, se subraya la importancia de una asignación clara de roles y responsabilidades en el equipo desde el inicio, garantizando que haya responsables definidos para la obtención de datos, su preparación, el modelado, la validación y la presentación de resultados. Asimismo, se ha potenciado el criterio de trazabilidad y documentación: cada paso del proyecto debe quedar registrado para permitir reproducibilidad y seguimiento detallado de las decisiones tomadas. Esta documentación continua provee una línea de vida del proyecto, facilitando auditorías técnicas y aprendizajes para proyectos futuros. De igual forma, la metodología actualizada enfatiza la evaluación rigurosa de los resultados intermedios y finales, instaurando puntos de control formales donde se validan los modelos desarrollados antes de proceder o desplegar una solución.

Finalmente, refuerza la comunicación efectiva de hallazgos, de modo que los resultados del análisis se traduzcan en información comprensible y utilizable para la toma de decisiones estratégica. **Todos estos elementos, roles bien definidos, documentación exhaustiva, evaluación periódica y comunicación clara** caracterizan a la metodología Datlas contemporánea y aportan valor para estructurar proyectos de datos de manera integral y exitosa.

2.1.1. Estructura metodológica.

La metodología Datlas se organiza en una secuencia lógica de fases operativas, abarcando el ciclo completo de un proyecto de analítica de datos desde la definición de los objetivos hasta el despliegue y monitoreo de la solución. **Cada fase tiene propósitos bien definidos y entregables concretos**, lo que facilita el control de calidad y la trazabilidad del proyecto. En esencia, Datlas propone un conjunto de pasos estructurados para obtener, procesar, analizar y aprovechar los datos, de forma que se conviertan en información estratégica para la organización. Estas etapas, descritas en la sección siguiente, incluyen desde la planificación inicial del problema hasta la puesta en producción de los resultados, asegurando que ningún aspecto crítico quede sin atender.

Una característica importante de la estructura metodológica es su **naturaleza iterativa**. Si bien las fases se presentan de manera secuencial, el proceso admite retrocesos y refinamientos cuando es necesario. Esto significa que los hallazgos de fases posteriores pueden conducir a revaluar o ajustar trabajos previos. Por ejemplo, tras construir un modelo de datos, podría descubrirse que se requieren datos adicionales o redefinir alguna variable; la metodología Datlas contempla volver a fases anteriores (como recopilación de datos o incluso reformulación del objetivo) **para realizar las correcciones pertinentes**. Gracias a este enfoque iterativo, se evita avanzar con supuestos erróneos y se mejora gradualmente la calidad del análisis hasta cumplir con los objetivos planteados.

Otra pieza central de la estructura es la integración de actividades de documentación, evaluación y comunicación a lo largo del proceso. En cada fase, **se incentiva llevar un registro detallado de las acciones realizadas**, **las fuentes de datos utilizadas, las técnicas aplicadas y los resultados obtenidos**. Esta documentación continua asegura la trazabilidad de cada resultado hasta sus datos de origen y decisiones metodológicas, lo cual es fundamental para la confiabilidad del proyecto. Asimismo, tras las fases analíticas principales, se llevan a cabo evaluaciones formales en las que el equipo valida si los resultados alcanzados satisfacen los criterios de éxito definidos al inicio. Solo después de superar estas evaluaciones, el proyecto avanza hacia las etapas finales. Por último, la estructura **metodológica reserva una fase dedicada**

a la comunicación y aplicación práctica de los hallazgos, garantizando que el conocimiento descubierto no quede confinado al equipo técnico, sino que se transfiera efectivamente a los tomadores de decisiones en la organización. En conjunto, esta arquitectura por fases dota al proyecto de un marco de trabajo coherente, reproducible y orientado a la acción, donde cada etapa sienta las bases para la siguiente y todas en su conjunto conducen desde preguntas iniciales hasta resultados implementables.

2.1.2. Fases operativas.

A continuación, se describen en detalle las fases operativas de la metodología Datlas. Cada fase corresponde a un conjunto de actividades y resultados esperados que, en conjunto, permiten estructurar y llevar adelante un proyecto de analítica de datos de forma exitosa. Si bien se presentan numeradas para enfatizar el flujo lógico, es importante recordar que el proceso es flexible y puede iterar según las necesidades identificadas en el camino.

I. Entendimiento del negocio (definición de objetivos y alcance)

En esta fase se establece **qué** se quiere lograr y **por qué** es importante. Junto con las y los responsables del proceso, se delimitan el problema y los **KPI** de éxito, se precisan el **alcance**, los supuestos y los riesgos, y se asignan roles. El resultado es un **marco de entendimiento compartido** y un plan de trabajo que orientará todas las decisiones posteriores y servirá de referencia para evaluar el éxito del proyecto.

II. Adquisición y comprensión de datos

Con los objetivos claros, se **localizan y caracterizan** las fuentes (internas y externas), se levantan permisos de acceso y se elabora el **diccionario de datos**. Se realiza un **perfilado inicial** (distribuciones, faltantes, consistencia, sesgos potenciales) para valorar la pertinencia y **calidad** de la información respecto a las preguntas del proyecto. Esta fase concluye con un inventario priorizado y un **plan de limpieza/preparación**.

III. Preparación (curación) de datos

Se construye el **conjunto analizable** mediante limpieza, integración y estandarización de formatos y unidades; se tratan faltantes y atípicos, se

deduplican registros y se crean **variables derivadas**. Todo cambio queda en una **bitácora de transformaciones** para garantizar trazabilidad y reproducibilidad. El producto es un dataset curado y documentado, listo para análisis.

IV. Exploración y visualización (línea base)

Se realiza **análisis exploratorio** para comprender patrones, estacionalidades, segmentaciones simples y relaciones entre variables. Se construye una **línea base** de los KPI y se generan visualizaciones y tableros preliminares que permiten **validar supuestos** y refinar preguntas con las áreas usuarias antes de modelar.

V. Modelado y experimentación

Se define el **diseño de la solución analítica** (pronóstico, clasificación, puntuación de riesgo, etc.), así como métricas y esquema de validación. Se ejecuta un **plan de experimentos** con diferentes técnicas y ajustes de hiperparámetros, comparando alternativas. El resultado son **modelos candidatos** técnicamente sólidos y coherentes con el contexto del problema, con registro de configuraciones y resultados.

VI. Evaluación y comunicación

Se evalúan los modelos con métricas adecuadas al tipo de tarea (por ejemplo, MAE/RMSE en regresión; AUC, F1, **precisión** y **exhaustividad (recall)** en clasificación) y se contrasta su utilidad con los **KPI de negocio** y las **restricciones operativas**. Se preparan el **informe ejecutivo** y el relato que conecta problema–datos–método–hallazgos–implicaciones. Si los resultados no satisfacen los criterios, se **itera** sobre fases previas; si los cumple, se decide el despliegue.

VII. Implementación

Se operacionaliza la solución en el entorno objetivo (cloud, on-prem o híbrido) mediante pipelines reproducibles (IaC + CI/CD), empaquetado (contenedores) y orquestación (jobs/servicios). Se definen roles, accesos y SLAs; se integra con sistemas fuente/destino (ETL/ELT, APIs) y se habilitan prácticas de MLOps: versionado de datos/modelos, despliegues canary/A-B, monitoreo de desempeño y costo, y alertas por drift o caídas

de calidad. Se documentan dependencias y procedimientos de rollback, se capacita a usuarios clave y mesa de ayuda, y se establece el calendario de re-entrenamiento/actualización. Finalmente, se activa la observabilidad end-to-end (logs, métricas, trazas) y el tablero de KPIs operativos y de negocio para verificar valor en producción y facilitar iteraciones controladas.

VIII. Despliegue y monitoreo (mejora continua)

La solución se lleva a **operación** —dashboard, API o proceso por lotes— con manuales de uso, plan de adopción y controles de acceso. Se instrumenta el **monitoreo** técnico y de negocio, con alertas ante degradación o **deriva** de datos/modelo, y se agenda **recalibración/reentrenamiento** cuando corresponda. Se documentan las **lecciones aprendidas** para retroalimentar el ciclo y sostener el valor en el tiempo.

En conclusión, la metodología Datlas con sus fases bien definidas y sus principios de trazabilidad, documentación, evaluación y comunicación proporciona un marco integral para estructurar proyectos de analítica de datos en entornos universitarios y empresariales. Su origen en la práctica de ciencia de datos y **su evolución constante hasta 2025** la han dotado de solidez teórica y flexibilidad práctica. Gracias a este enfoque metodológico, los equipos de datos pueden abordar problemas complejos de manera ordenada y reproducible, asegurando que el valor latente en los datos se transforme en resultados accionables y medibles para las organizaciones. Cada fase de Datlas cumple una función específica en ese proceso de transformación, y juntas articulan una ruta clara desde la formulación de preguntas hasta la generación de conocimiento aplicado. De esta manera, la metodología Datlas se consolida como una herramienta fundamental en la formación de analistas de datos y en la ejecución exitosa de proyectos de ciencia de datos en el mundo real, contribuyendo a cerrar la brecha entre los datos y la toma de decisiones informada.

2.2. Descripción del proceso paso a paso de la metodología Datlas.

La metodología Datlas organiza el trabajo analítico en una secuencia de pasos claros que permiten pasar de una necesidad concreta a una solución en uso, con trazabilidad, control de calidad y comunicación efectiva.

A continuación, se describe el proceso paso a paso, en lenguaje operativo y con el nivel de detalle necesario para guiar proyectos reales de la asignatura.

Paso 1. Alineación de objetivos y alcance

El proceso inicia con la formulación precisa del problema a resolver y los objetivos medibles del proyecto. Se identifican actores, decisiones a soportar, restricciones y riesgos. Se define el alcance (qué incluye y qué no), se establecen KPI y se acuerda un cronograma de entregas parciales. El resultado es una declaración de objetivos que servirá de referencia para todas las fases posteriores y un plan de trabajo con responsables.

Paso 2. Roles, gobernanza y plan de comunicación

Para evitar fricciones operativas, se asignan roles y responsabilidades (patrocinador, referente de negocio, responsable de datos, responsable analítico, responsable de despliegue). Se acuerdan canales y ritmos de comunicación (reuniones de seguimiento, actas, tableros de control) y se establecen reglas de cambio de alcance. Este paso garantiza coordinación y acelera la resolución de bloqueos.

Paso 3. Requisitos de datos y estrategia de adquisición

Con el objetivo claro, se deriva una lista de preguntas analíticas y de variables necesarias. Se mapean fuentes internas y externas,

criterios de acceso, periodicidad y formato. El equipo define la estrategia de adquisición (extracciones programadas, acceso a APIs, uso de repositorios) y las consideraciones de privacidad y cumplimiento. El producto es un inventario de fuentes con responsables y autorizaciones.

Paso 4. Perfilado y diagnóstico de calidad de datos

Antes de transformar, se realiza un perfilado: conteos, distribuciones, valores únicos, tasas de faltantes, detección de inconsistencias y anomalías. Se documentan reglas de validación (rango, tipo, integridad referencial) y se identifican sesgos posibles por cobertura o medición. Este diagnóstico evita construir sobre datos defectuosos y alimenta el plan de limpieza.

Paso 5. Integración y curación (preparación)

Se limpian, integran y transforman los datos para conformar un conjunto analizable. Las actividades incluyen estandarización de formatos y unidades, tratamiento de faltantes y outliers, deduplicación, enriquecimiento y construcción de variables derivadas. Se redacta un diccionario de datos y se mantiene una bitácora de transformaciones que asegure reproducibilidad.

Paso 6. Exploración y línea base (descriptiva)

Con el conjunto curado, se desarrolla una exploración descriptiva orientada al objetivo: tendencias, estacionalidades, correlaciones, segmentaciones simples y construcción de líneas base para los KPI. Esta etapa permite validar supuestos, refinar preguntas y detectar oportunidades o riesgos que condicionarán el modelado posterior. Se generan visualizaciones y hallazgos preliminares que se socializan con el equipo de negocio.

Paso 7. Diseño de la solución analítica

Antes de entrenar modelos, se decide qué enfoque analítico responde mejor al problema (pronóstico, clasificación, puntuación de riesgo, segmentación, reglas de decisión, optimización). Se define el criterio de evaluación (métricas técnicas y de negocio),

el esquema de validación y el plan de experimentos. Este diseño evita iteraciones ciegas y alinea lo técnico con la utilidad esperada.

Paso 8. Modelado y experimentación controlada

Se implementan los experimentos definidos: selección de algoritmos, división de datos, ajuste de hiperparámetros y comparación de resultados. Se registran pruebas, configuraciones y métricas en un registro de experimentos para asegurar trazabilidad. El objetivo es obtener uno o varios modelos candidatos que cumplan con los requisitos técnicos y tengan sentido en el contexto del proceso.

Paso 9. Evaluación técnica y de negocio

Los candidatos se someten a evaluación rigurosa con datos de validación y, cuando es posible, con escenarios de negocio. Se cuantifica el desempeño con métricas acordadas y se analiza el impacto operativo (beneficio/costo, tiempos, riesgos, interpretabilidad, requisitos de adopción). Si no se alcanzan los umbrales, se itera sobre datos, variables o diseño. Si se cumplen, se pasa a preparar la entrega.

Paso 10. Comunicación de hallazgos y decisión

Se elabora un informe ejecutivo y una presentación orientada a la toma de decisiones. El relato conecta problema, datos, método y resultados con implicaciones operativas claras. Se explican limitaciones y supuestos, y se propone una recomendación concreta: desplegar, ajustar o posponer. Este paso busca alinear expectativas y garantizar que el conocimiento sea entendible y accionable.

Paso 11. Despliegue de la solución

La solución se lleva a operación según el caso: tablero, API, proceso por lotes, integración en un sistema existente. Se preparan manuales de uso, guías de soporte y un plan de adopción con responsables y fechas. El despliegue incluye pruebas de

aceptación, controles de acceso y, si aplica, empaquetado de código y dependencias para asegurar estabilidad.

Paso 12. Monitoreo, alerta y mejora continua

Una vez en uso, se instrumentan métricas de desempeño técnico y de negocio, y alertas ante degradación o cambios en los datos. Se calendariza reentrenamiento o recalibración, se registran incidencias y se documentan versiones. El objetivo es preservar el valor en el tiempo y sostener un ciclo de aprendizaje con retroalimentación hacia el equipo.

Paso 13. Cierre y lecciones aprendidas

Al concluir un hito o la iniciativa, se realiza un cierre formal: consolidación de entregables, evidencia de impacto en KPI, costos y beneficios, y un apartado de lecciones aprendidas. Este documento facilita la transferencia de conocimientos y la madurez metodológica del equipo para futuros proyectos.

Resultado esperado del proceso

Aplicado en su totalidad, el proceso Datlas entrega: una solución analítica funcional (tablero, API o modelo operativo), documentación técnica y ejecutiva, un plan de monitoreo con responsables y métricas, y evidencia del impacto en los KPI definidos al inicio. Más allá del producto técnico, el valor central reside en haber recorrido un camino verificable desde el problema hasta la decisión, con controles y aprendizajes que pueden reutilizarse en nuevas iniciativas de la organización.

2.3. Aplicaciones de Datlas en proyectos de negocio.

La metodología Datlas —también denominada "Laboratorio de Datos"— es un marco estructurado para proyectos de analítica que adapta principios académicos (como CRISP-DM) a la realidad empresarial.

Este enfoque se basa en fases clave (extracción, integración, clasificación, visualización, entrenamiento de modelos y reporte de hallazgos) para asegurar que los datos brutos se transformen en información útil y decisiones informadas. A continuación, se presentan casos reales documentados en los que esta metodología ha sido aplicada en organizaciones de Latinoamérica, mostrando el contexto, objetivos, pasos seguidos y resultados obtenidos en cada experiencia. Estos ejemplos abarcan sectores diversos –desde retail hasta medio ambiente y entretenimiento– y permiten reflexionar sobre los beneficios y aprendizajes logrados mediante la aplicación rigurosa de Datlas en entornos de negocio.

Sector Retail: Caso Sigma Alimentos (Optimización de análisis de mercado)

Contexto y objetivo: Sigma Alimentos, una multinacional de productos alimenticios (carnes frías, lácteos, etc.), enfrentaba el desafío de modernizar su proceso de inteligencia de mercados. La empresa buscaba automatizar y agilizar la ingesta y actualización de datos de su Índice de Calidad del Consumidor, un indicador clave obtenido de encuestas y ventas, el cual hasta entonces se gestionaba manualmente en múltiples hojas de cálculo. El objetivo era migrar de informes en Excel a dashboards interactivos que tradujeran el análisis descriptivo en acciones concretas para los gerentes de marca, permitiendo una toma de decisiones más rápida y basada en evidencia.

Aplicación de la metodología Datlas: Siguiendo las fases de Datlas, el equipo de ciencia de datos trabajó junto a expertos de negocio para definir con claridad el problema y las métricas de éxito (satisfacción y comportamiento del consumidor por categoría de producto).

Posteriormente, procedieron a integrar diversas fuentes de datos internas, homologándolas en una plataforma unificada. En este caso, se consolidaron más de 8 esquemas de datos que antes se manejaban por separado en Excel, incorporando históricos del índice de calidad del consumidor, ventas y otros indicadores relevantes. Tras la etapa de integración y limpieza, se aplicaron técnicas de minería de datos y análisis estadístico para extraer hallazgos clave, manteniendo la alineación con los objetivos iniciales. Finalmente, en la fase de visualización y reporte, se desarrolló un dashboard de "eficiencia comercial" altamente personalizado, con gráficos interactivos y KPIs críticos, entregando al equipo de inteligencia de mercado una herramienta para monitorear en tiempo real el desempeño de cada marca y detectar oportunidades de mejora. Durante todo este proceso, la metodología Datlas proporcionó una guía estructurada: desde la definición de prioridades de medición (qué datos recopilar y con qué frecuencia) hasta la comunicación de resultados de forma comprensible para los tomadores de decisión.

Resultados: La implementación de esta solución analítica produjo beneficios cuantificables para Sigma Alimentos. En primer lugar, se reportó un retorno sobre la inversión (ROI) cercano al doble (2x) en el primer año tras adoptar la nueva plataforma. Esto refleja que el proyecto generó valor económico significativo comparado con su costo, mediante eficiencias y mejores decisiones. Asimismo, los tiempos de respuesta del equipo de inteligencia de mercados hacia sus clientes internos (los gerentes de marca) se redujeron en aproximadamente un 25%, al contar ahora con información actualizada al instante. Un resultado adicional fue la escalabilidad de la solución: el dashboard no solo abarcó las categorías de producto iniciales, sino que integró 3 nuevas categorías en México y está siendo replicado en 2 unidades de negocio internacionales de la compañía, estableciendo un nuevo estándar corporativo para el análisis de mercados.

Reflexiones: Este caso demuestra cómo la aplicación rigurosa de una metodología de analítica de datos puede transformar un proceso empresarial tradicional. Al definir claramente el problema y centralizar los datos dispersos, Sigma logró convertir información antes fragmentada en insights accionables. La participación de las áreas usuarias en el diseño de indicadores garantizó que el dashboard se alineara con las

necesidades estratégicas reales, facilitando su adopción. En suma, el enfoque Datlas permitió mejorar la eficiencia operativa y la calidad de las decisiones en el área de marketing de Sigma Alimentos, sentando las bases para una cultura organizacional más orientada al dato.

Sector Ambiental/Gubernamental: Caso ProNatura México (Monitoreo de reforestación con analítica)

Contexto y objetivo: ProNatura México –organización civil dedicada a la conservación ambiental– lidera proyectos de reforestación riparia (en ríos y humedales) con apoyo de patrocinadores internacionales. En uno de sus programas en Armería, Colima, la institución buscaba demostrar con datos el impacto de las inversiones realizadas por la Unión Europea y otros financiadores, así como optimizar el monitoreo de cientos de parcelas reforestadas dispersas geográficamente. El reto consistía en pasar de reportes manuales y puntuales a un sistema integrado que permitiera supervisar en tiempo real la evolución de los sitios reforestados, identificando riesgos (sequías, inundaciones) y evaluando la eficacia de las acciones de conservación sobre el terreno.

Aplicación de la metodología Datlas: Para abordar este desafío, ProNatura colaboró con especialistas en datos aplicando las fases del laboratorio de datos. En la etapa inicial, se definieron los objetivos junto con los ecólogos y gestores del proyecto: por un lado, cuantificar la supervivencia de las áreas reforestadas y, por otro, asociar resultados ambientales con el dinero aportado por los patrocinadores, para evidenciar rendimiento social de la inversión. Luego se procedió a recopilar y priorizar datos relevantes: se levantaron datos primarios en campo (ej. número de árboles sobrevivientes, hectáreas reforestadas, ocurrencias de eventos climáticos extremos en cada parcela) y se integraron con fuentes secundarias (índices socioeconómicos locales, datos meteorológicos históricos, etc.). Mediante herramientas de integración de Datlas, estas diversas capas de información fueron consolidadas en una base georreferenciada común. A continuación, en la fase de análisis, se calcularon indicadores clave de desempeño ambiental para cada sitio (por ejemplo, porcentaje de cobertura vegetal recuperada, tasa de pérdida de cultivos evitada) y se compararon contra las metas esperadas. Este análisis incluyó técnicas de visualización geoespacial para destacar en el mapa las zonas más vulnerables o

exitosas. Finalmente, se diseñó un dashboard de monitoreo ambiental –el primero de su tipo para el programa– donde los gestores pueden visualizar en gráficos y mapas la evolución de más de 100 parcelas reforestadas en tiempo real. El dashboard presenta alertas tempranas (p. ej., si una parcela muestra indicadores de estrés hídrico) y enlaza cada resultado con las inversiones realizadas, facilitando la generación de informes automáticos para los patrocinadores.

Resultados: La implementación estructurada de analítica de datos en ProNatura produjo beneficios tangibles tanto operativos como estratégicos. En términos financieros, se estimó un retorno sobre la inversión del orden de 2x en el primer año de uso del nuevo sistema, lo que sugiere que el valor de las mejoras (por ejemplo, en ahorros o eficacia) duplicó el costo del proyecto. Más notable aún, la gestión proactiva basada en datos permitió evitar la mayoría de las pérdidas que típicamente afectaban a estas reforestaciones. Se reporta que el 80% de las parcelas monitoreadas lograron evitar pérdidas de cultivos por altas temperaturas, y el 60% evitaron pérdidas por inundaciones, gracias a las intervenciones oportunas guiadas por el sistema. En otras palabras, la gran mayoría de los terrenos reforestados sobrevivieron a condiciones climáticas adversas que históricamente causaban estragos. Consecuentemente, el valor económico de las pérdidas se redujo a apenas un ~20% de la inversión inicial, el nivel más bajo en la historia del proyecto. Este indicador refleja que las estrategias de mitigación apoyadas en el dashboard (como instalar barreras, realizar riegos preventivos o reforzar ciertas zonas) fueron altamente efectivas, protegiendo el capital invertido en la restauración ambiental.

Reflexiones: El caso de ProNatura México ilustra cómo una metodología de analítica estructurada puede potenciar proyectos en el sector socioambiental y público. En primer lugar, la transparencia de datos brindada por el dashboard fortaleció la rendición de cuentas: los patrocinadores internacionales pudieron visualizar en tiempo real el impacto de cada dólar invertido, incrementando su confianza en el programa. Además, la capacidad de monitoreo continuo permitió al equipo técnico aprender de los datos y ajustar sus acciones (por ejemplo, focalizando recursos en las parcelas de mayor riesgo) en un ciclo de mejora continua. Un aprendizaje importante fue que la fase de

clasificación y diseño de indicadores resultó crucial para traducir objetivos sociales amplios (conservar biodiversidad, reducir vulnerabilidad climática) en métricas concretas y medibles. En síntesis, mediante Datlas se logró vincular los datos operativos con la toma de decisiones estratégicas en un contexto no lucrativo, maximizando los beneficios ambientales y asegurando que cada intervención estuviera respaldada por evidencia.

Sector Entretenimiento: Caso Cinépolis (Analítica predictiva de taquilla cinematográfica)

Contexto y objetivo: En la industria del cine, predecir el éxito de una película en taquilla es un problema crucial que históricamente dependía de experiencia e intuición. Cinépolis, una de las cadenas de cines más grandes de América Latina, decidió impulsar sus decisiones de marketing con análisis de datos avanzados para anticipar la asistencia del público a los estrenos. El objetivo era aprovechar la abundancia de datos disponibles (ventas anticipadas, tendencias en redes sociales, históricos de géneros exitosos, etc.) para orientar las estrategias de promoción película por película, optimizando la ocupación de las salas y la rentabilidad de cada lanzamiento. En particular, para el estreno de una película nacional, la empresa buscaba identificar con precisión dónde y cómo enfocar su campaña publicitaria digital para maximizar la audiencia, en lugar de depender únicamente de distribuciones de marketing uniformes o corazonadas locales.

Aplicación de la metodología Datlas: Cinépolis colaboró con el equipo de Datlas para aplicar una solución de analítica predictiva mediante dashboards geoespaciales. Como primer paso, se definieron las metas analíticas: por ejemplo, pronosticar el número de asistentes por ciudad y función, y estimar el impacto de distintos niveles de publicidad en redes. Con esos objetivos, se procedió a integrar múltiples fuentes de datos relevantes para el estreno en cuestión. Usando la herramienta EDA & Forecasting de Datlas, se conectaron datos de preventa de boletos segmentados por zona geográfica, historiales de comportamiento de audiencias para películas similares, datos demográficos locales y actividad en línea (clics en anuncios, búsquedas en internet, menciones en redes sociales). Esta integración permitió visualizar en un tablero único la demanda anticipada en diferentes plazas del país. A través de mapas

de calor y gráficos de series temporales, el equipo de análisis detectó patrones regionales: por ejemplo, identificó que en ciertas ciudades medianas (como Querétaro y Puebla) la intención de compra era inusualmente alta para ese estreno, en comparación con otros mercados. Siguiendo la metodología Datlas, se emplearon técnicas de forecasting (modelos de predicción basados en tendencias históricas ajustadas con los datos en tiempo real de preventa) para proyectar distintos escenarios de asistencia. Luego, en la etapa de interpretación y recomendación, el dashboard permitió simular el efecto de redirigir presupuesto publicitario adicional hacia las zonas de mayor interés identificado. En estrecha comunicación con el equipo comercial de Cinépolis, se tomó la decisión de ajustar la estrategia de marketing digital en tiempo real, invirtiendo más en anuncios específicos para las regiones con alta probabilidad de asistencia y reduciendo gasto en zonas de menor interés relativo.

Resultados: La aplicación de la analítica basada en Datlas tuvo un impacto inmediato y medible en el desempeño de este estreno cinematográfico. Al focalizar la campaña según las sugerencias del modelo, Cinépolis logró un aumento del 28% en la asistencia a las salas respecto a la proyección inicial que se tenía antes de usar el análisis de datos. En otras palabras, gracias a la identificación oportuna de plazas con mayor demanda latente y al redireccionamiento de la publicidad hacia esas ciudades, se superó en casi una tercera parte la expectativa de público, llenando muchas butacas que de otro modo habrían quedado vacías. Este incremento significativo se tradujo en ingresos adicionales importantes para la cadena y evidenció el potencial de los datos para influir positivamente en decisiones de marketing. Además del aumento de público, el proyecto dejó capacidades instaladas: la empresa cuenta ahora con un sistema replicable para futuros estrenos, donde los gerentes pueden monitorear indicadores clave como la tasa de preventa por día y región, el engagement en redes sociales y el ritmo de venta post-estreno, todo centralizado en un dashboard interactivo. Esto ha llevado a una nueva forma de trabajo más ágil y proactiva en el departamento de análisis de mercado de Cinépolis, que complementa la creatividad del marketing tradicional con la rigurosidad del pronóstico científico.

Reflexiones: El caso Cinépolis resalta el valor de la metodología Datlas en un entorno de negocio altamente dinámico y competitivo como el del entretenimiento. Un aprendizaje fundamental es que disponer de plataformas de datos en tiempo real habilita a las empresas a responder con rapidez a las tendencias del mercado. La fase de visualización geoespacial, combinada con modelos predictivos, fue clave para descubrir oportunidades que no eran evidentes a simple vista (por ejemplo, un interés inusualmente alto en ciertas ciudades). Esto enfatiza que no solo importa reunir datos, sino presentarlos de forma comprensible para que los equipos ejecutivos puedan actuar de inmediato. También se evidenció la importancia de iterar: tras el éxito inicial, la empresa puede refinar continuamente sus modelos con nuevos datos de cada estreno, mejorando así sus predicciones en el largo plazo. En suma, la experiencia demostró que una cultura de decisiones basadas en datos —apoyada por metodologías estructuradas— puede aumentar la eficacia de las estrategias comerciales incluso en sectores creativos, al reducir la incertidumbre y alinear las acciones tácticas (como la publicidad) con el comportamiento real del público.

Conclusiones generales

Los anteriores casos de estudio evidencian cómo la metodología Datlas se adapta a distintos contextos empresariales y institucionales, aportando valor en cada uno de ellos. Un hilo común es que el enfoque estructurado desde la definición clara del problema y las métricas, pasando por la integración rigurosa de datos de diversas fuentes, hasta el despliegue de herramientas de visualización y seguimiento– permite convertir datos en decisiones efectivas. En sectores tradicionales como el retail alimenticio (Sigma), el uso de Datlas agilizó procesos y mejoró la eficiencia interna, mientras que en proyectos sociales y ambientales (ProNatura) proporcionó transparencia y optimización de recursos, y en industrias creativas (Cinépolis) habilitó una reacción ágil basada en evidencia ante cambios del mercado. En todos los casos, los equipos obtuvieron lecciones valiosas: la necesidad de colaboración interdisciplinaria (entre expertos de negocio y científicos de datos), la importancia de establecer indicadores adecuados que vinculen los objetivos estratégicos con los análisis, y el beneficio de iterar continuamente a medida que se obtienen nuevos hallazgos.

2.4. Ventajas y limitaciones de Datlas frente a otros modelos.

La metodología DATLAS es un modelo reciente de análisis de datos que se compara con metodologías clásicas como CRISP-DM, SEMMA y KDD.

Cada una de estas metodologías provee un marco estructurado con diferentes enfoques y fortalezas. A continuación, se analizan las ventajas y limitaciones de Datlas en relación con dichos modelos, considerando aspectos como estructura, flexibilidad, nivel de detalle, aplicabilidad práctica, documentación, validación, comunicación y contexto de uso.

Fortalezas de la metodología Datlas en comparación con CRISP-DM, SEMMA y KDD

Estructura y enfoque: Datlas consta de cinco fases principales (definición del problema, análisis de datos, preparación de datos, modelado y interpretación de resultados). Esta estructura es similar en número de etapas a la de CRISP-DM (que tiene seis fases: comprensión del negocio, comprensión de los datos, preparación de datos, modelado, evaluación y despliegue) y a la de KDD (proceso iterativo de cinco etapas desde la selección y transformación de datos hasta la extracción de conocimiento). A diferencia de SEMMA –un proceso lineal orientado a herramientas SAS con cinco pasos técnicos (muestreo, exploración, modificación, modelado y evaluación)– Datlas integra desde el inicio la comprensión del problema en colaboración con los usuarios finales, parecido a la fase de entendimiento del negocio de CRISP-DM. Esta colaboración temprana con expertos del dominio asegura que los objetivos del proyecto estén alineados con las necesidades reales antes de profundizar en el análisis técnico. En su fase final, Datlas enfatiza la interpretación y comunicación efectiva de los resultados a los interesados, lo que refleja una fortaleza importante: un foco explícito en la comunicación de hallazgos y en la adopción de los resultados por parte del usuario final. Si bien CRISP-DM también contempla la

evaluación y el despliegue (incluyendo la entrega de resultados al cliente), Datlas destaca por subrayar la importancia de la comunicación de una manera más directa, lo cual la beneficia especialmente en contextos donde la transferencia de conocimiento es clave (por ejemplo, proyectos educativos o consultorías empresariales orientadas a la toma de decisiones).

Flexibilidad y adaptabilidad: Una ventaja reconocida de CRISP-DM es su carácter iterativo y flexible, adaptable a distintos sectores y tecnologías. Datlas comparte esa orientación adaptable; de hecho, ha sido diseñada con un enfoque práctico y ajustable a proyectos de analítica de datos y aprendizaje automático modernosds. Al igual que CRISP-DM, el modelo Datlas permite retroalimentación entre fases: por ejemplo, si los resultados del modelado no satisfacen los objetivos, se reconsideran etapas previas (redefinir el problema o recopilar datos adicionales) antes de continuar. Esta iteratividad está alineada con KDD, que también es un proceso cíclico donde es posible regresar a etapas anteriores según sea necesario. En comparación, SEMMA tiende a ser más secuencial y centrada en las tareas técnicas, ofreciendo menos guía sobre cómo iterar con el contexto de negocio en mente. Por lo tanto, Datlas presenta la ventaja de combinar la estructura lógica de un proceso definido con la flexibilidad necesaria para adaptarse a cambios o nuevos hallazgos durante el proyecto, algo fundamental en proyectos de ciencia de datos dinámicos.

Orientación práctica y comunicación: Datlas se enfoca en la analítica de datos y el aprendizaje automático como núcleo de su metodología. Esto implica que incorpora herramientas modernas de minería de datos y técnicas de machine learning de forma natural en sus fases. Su énfasis en trabajar con usuarios finales y comunicar resultados de forma efectiva supone una fortaleza en términos de alineación con objetivos de negocio y usabilidad de los hallazgos. En proyectos donde la implementación de soluciones debe ser comprendida y aceptada por equipos no técnicos, este foco comunicativo de Datlas es especialmente ventajoso. Por ejemplo, al final del proceso Datlas, los resultados no solo se evalúan técnicamente, sino que se interpretan en lenguaje de

negocio para los tomadores de decisión, facilitando la traducción de los modelos en acciones concretas. CRISP-DM igualmente destaca por su fuerte orientación al entendimiento del negocio y la integración de requisitos con soluciones analíticas, pero Datlas refuerza este aspecto incluyendo la colaboración con el usuario desde el inicio hasta el final. En contraste, metodologías más antiguas como KDD originalmente se centraron en el descubrimiento de patrones en los datos, dejando implícita la necesidad de traducir ese conocimiento para su aplicación práctica. SEMMA, por su parte, asume que la comprensión del problema y la utilización de los resultados ocurren fuera de sus etapas formales, lo que puede dificultar la conexión entre el análisis técnico y la toma de decisiones. Así, una fortaleza de Datlas frente a estos modelos clásicos es su enfoque integral que va desde la definición del problema con el cliente hasta la comunicación de resultados, asegurando que el ciclo analítico esté conectado con el contexto de uso en todo momento

Limitaciones de Datlas frente a los modelos clásicos

Alcance y nivel de detalle: Una de las limitaciones de Datlas es que, al ser un marco emergente, no cuenta con la profundidad de documentación ni con el nivel de desglose de tareas que sí tiene CRISP-DM. La guía de CRISP-DM proporciona descripciones detalladas de cada fase, posibles actividades, salidas intermedias y consejos prácticos, fruto de su desarrollo colaborativo en la industria desde los años 90. En contraste, Datlas se describe a alto nivel en cinco fases, pero carece de guías oficiales extensas; su definición proviene principalmente de fuentes puntuales (por ejemplo, trabajos académicos de 2021 o materiales de la empresa Datlas) más que de un estándar ampliamente consensuado. Esto puede llevar a interpretaciones diversas de cómo implementar exactamente cada paso de Datlas en la práctica. Por ejemplo, mientras CRISP-DM define claramente qué preguntas responder en Comprensión del negocio o qué entregables obtener en Evaluación, Datlas enuncia "interpretación de resultados" sin detallar procedimientos de validación exhaustivos o protocolos de deployment. De hecho, no incluye explícitamente una fase de

despliegue o mantenimiento del modelo en producción, aspecto cubierto en CRISP-DM (fase de Despliegue). Esta ausencia puede ser una desventaja en proyectos donde, tras el análisis, se requiere implementar la solución en sistemas operativos o integrarla a procesos de negocio continuos. KDD y SEMMA también presentan limitaciones en alcance.

Adopción y aplicabilidad universal: Otra limitación de Datlas es su escasa adopción comprobada en comparación con los modelos tradicionales. CRISP-DM es referenciada como la metodología más recomendada y utilizada gracias a su equilibrio entre perspectivas de negocio y técnicas, respaldada por décadas de uso en numerosos sectores. De hecho, CRISP-DM ha servido de base para múltiples variantes y estándares posteriores, lo que demuestra su aplicabilidad generalizada. Por su parte, Datlas no ha alcanzado ese nivel de reconocimiento ni de comunidad de práctica: su uso parece restringido a ciertos entornos (por ejemplo, iniciativas de la empresa Datlas o casos académicos aislados). Esto implica que no existe un amplio conjunto de experiencias documentadas, estudios de caso o herramientas específicas alineadas con Datlas que los profesionales puedan consultar. En entornos empresariales muy consolidados, esta falta de historial puede generar reticencia a adoptar Datlas en lugar de metodologías probadas.

Enfoque específico vs. generalidad: Si bien Datlas destaca su énfasis en analítica de datos y aprendizaje automático, esta especialización podría ser una limitación en ciertos escenarios. CRISP-DM fue concebido deliberadamente como un proceso genérico para todo tipo de proyectos de minería de datos, lo que le permite ajustarse tanto a proyectos descriptivos sencillos como a iniciativas complejas de big data. Datlas, al provenir de un entorno específico (una iniciativa privada con foco en dashboards, análisis geoespaciales y soluciones de negocio rápidas), podría no abarcar con igual eficacia proyectos que se desvíen de ese enfoque. Por ejemplo, en proyectos de desarrollo de productos de datos a gran escala (que involucren consideraciones de arquitectura de software, ingeniería de datos masivos, etc.), Datlas no provee lineamientos explícitos, mientras que CRISP-DM puede

ampliarse con fases adicionales o combinarse con metodologías de ingeniería de software para cubrir esas necesidades. En resumen, la menor generalidad de Datlas puede ser una desventaja si se busca una metodología que sirva como marco universal; los modelos tradicionales, con todas sus variaciones, han demostrado ser maleables para distintos tipos de proyectos, mientras que Datlas aún debe probar esa versatilidad.

Contextos de aplicación: ¿Cuándo conviene usar Datlas?

Considerando las fortalezas y debilidades anteriores, es posible delinear escenarios donde la adopción de Datlas resulta más ventajosa, y otros donde puede ser menos adecuada en comparación con CRISP-DM, SEMMA o KDD. Datlas puede ser más ventajosa en proyectos de alcance limitado o mediano donde se valore una rápida comprensión del problema y entrega de insights accionables. Por ejemplo, en contextos de consultoría de datos para startups o pequeñas empresas, donde el objetivo principal es obtener análisis claros en poco tiempo y comunicarlos efectivamente a clientes o áreas de negocio, Datlas provee un marco ágil centrado en ese fin. Su enfoque en la comunicación y colaboración con el usuario la hace apropiada en sectores como la educación (de donde surgió originalmente su formulación) o en proyectos corporativos donde el dashboarding y la interpretación de resultados inmediatos son prioridad. Asimismo, equipos que ya están familiarizados con CRISP-DM podrían encontrar en Datlas una versión simplificada y actualizada que incorpora prácticas modernas (integración de datos de múltiples fuentes, visualización centrada en el usuario, etc.), siendo útil para fines didácticos o para prototipos rápidos de análisis.

En síntesis, Datlas destaca por su enfoque contemporáneo en la colaboración con el usuario y la comunicación efectiva de resultados, aportando un marco estructurado pero flexible para proyectos de ciencia de datos orientados a obtener valor práctico de forma ágil. Frente a los modelos clásicos, ofrece ventajas en accesibilidad, rapidez y énfasis comunicacional, pero a costa de una menor consolidación y detalle metodológico. Su uso es

prometedor en escenarios controlados o educativos, mientras que para proyectos de gran envergadura o con requerimientos formales robustos, los enfoques tradicionales (especialmente CRISP-DM) continúan siendo la opción más sólida y respaldada por la experiencia. Cada organización deberá valorar estas diferencias para decidir si Datlas puede complementar o sustituir a las metodologías clásicas en su práctica de analítica de datos, considerando el equilibrio entre la innovación en la metodología y la seguridad de seguir un estándar probado.

Bibliografía

Álvarez, D. (20 de noviembre de 2024). Actualizamos nuestra metodología de analítica de datos: ¡Descúbrela! – Columna de Opinión Datlas. Blog Datlas. https://blogdatlas.wordpress.com/2024/11/20/actualizamos-nuestra-metodologia-de-analitica-de-datos-descubrela-columna-de-opinion-datlas/

Camm, J., Cochran, J., & Fry, M. (2024). Business Analytics: Descriptive, Predictive, Prescriptive 5th. Cengage Learning.

Cote, C. (19 de octubre de 2021). 4 types of data analytics to improve decision-making. Harvard Business School Online. https://online.hbs.edu/blog/post/types-of-data-analysis

Datlas. (16 de febrero de 2020). Blog Datlas. ¿Qué es el pensamiento analítico y por qué será clave para todos los trabajos del futuro? – Columna de Investigación de Datlas.. https://blogdatlas.wordpress.com/2025/09/06/que-es-el-pensamiento-analitico-y-por-que-sera-clave-para-todos-los-trabajos-del-futuro-columna-de-investigacion-de-datlas/

Datlas. (2025). Analítica Avanzada. Datlas. https://www.datlas.mx/analitica_avanzada/

IBM (o Autor: Stryker, C.). (2 de Mayo de 2024). What is prescriptive analytics? IBM Think. https://www.ibm.com/think/topics/prescriptive-analytics

Machorro, P. (23 de julio de 2025). ¿Se puede predecir el éxito en taquilla? Dashboards y analítica para lograrlo – Columna de Investigación Datlas. Blog Datlas. https://blogdatlas.wordpress.com/2025/07/23/se-puede-predecir-el-exito-en-taquilla-dashboards-y-analitica-para-lograrlo-columna-de-investigacion-datlas/

Marr, B. (2022). Data Strategy: How to Profit from a World of Big Data, Analytics and AI 2nd. Kogan Page.

Saltz, J., & Krasteva, I. (2022). Current approaches for executing big data science projects—A systematic literature review. PeerJ Computer Science, 8, e862. https://doi.org/https://doi.org/10.7717/peerj-cs.862

Sharda, R. D. (2021). Analytics, Data Science, & Artificial Intelligence: Systems for Decision Support. Pearson.