



ASIGNATURA METODOLOGÍAS DE ANALÍTICA DE DATOS

Actividad Autónoma 3

Nombre de la actividad: KDD aplicado y comparación metodológica

Unidad 2: Enfoques clásicos de la analítica

Tema 1: Knowledge Discovery in Databases (KDD)



FACULTAD DE
Ingeniería

Nombre: Lenin López

Fecha: 12/05/2026

Carrera: Ciencia de Datos e IA

Periodo académico: 2026-1S

Semestre: 4to.

Contenido

1. Explique con sus propias palabras qué es KDD y describa el propósito de cada una de sus cinco fases (selección, preprocesamiento, transformación, minería, interpretación). Indique además por qué este flujo es necesario en proyectos de analítica.

KDD (Knowledge Discovery in Databases) es el proceso sistemático para extraer conocimiento útil y comprensible a partir de grandes volúmenes de datos. Sus cinco fases y propósitos son:

- **Selección:** elegir y reunir las fuentes y subconjuntos de datos relevantes para el problema (objetivo: disponer de la muestra correcta).
- **Preprocesamiento:** limpiar, estandarizar e imputar datos faltantes (objetivo: mejorar la calidad y consistencia de los datos).
- **Transformación:** generar variables, normalizar, codificar y reducir dimensionalidad cuando convenga (objetivo: adaptar los datos al método de minería).
- **Minería:** aplicar algoritmos (clustering, clasificación, regresión, reglas de asociación) para descubrir patrones (objetivo: extraer modelos o patrones cuantificables).
- **Interpretación/evaluación:** validar resultados, medir desempeño y traducir hallazgos a decisiones (objetivo: entregar conocimiento accionable).



Este flujo es necesario porque cada fase prepara el insumo para la siguiente; saltarse etapas provoca modelos pobres, fugas de información o conclusiones no replicables.

2. Clasifique cada actividad en la fase de KDD que corresponda y justifique en 2-3 líneas:



- a. Crear una bitácora de calidad, detectar duplicados y estandarizar formatos de fecha.

Preprocesamiento. Ya que son tareas de limpieza y control de calidad necesarias antes de análisis.

- b. Generar variables de recencia, frecuencia y valor (RFM) y aplicar una reducción de dimensionalidad (PCA).

Transformación. Creación de nuevas variables y reducción de dimensionalidad para preparar modelos.

- c. Entrenar y comparar árboles de decisión, regresión logística y gradient boosting con validación cruzada.

Minería. Aplicación y comparación de algoritmos predictivos para seleccionar el mejor modelo.

- d. Definir la ventana temporal, las fuentes autorizadas y los criterios de inclusión/exclusión de registros.

Selección. Determinación del conjunto de datos y límites temporales del estudio.

- e. Elaborar un dashboard de hallazgos, explicar errores y proponer umbrales operativos.

Interpretación. Comunicar resultados y convertir métricas en decisiones.

- f. Imputar faltantes con reglas de negocio y KNN-imputer y documentar supuestos.

Preprocesamiento. Imputación de valores faltantes y documentación de supuestos son tareas de limpieza y reproducibilidad.

3. Mencione e investigue seis técnicas comunes en un proyecto de KDD y asigne cada una a su fase y a una herramienta posible. Describa en una línea el objetivo y un entregable típico.

Pistas: muestreo estratificado; reglas de validación; one-hot encoding; scaling; PCA; selección por information gain; clustering

kmeans; reglas de asociación; matriz de confusión/ROC; informe de interpretación.

TECNICA	FASE	HERRAMIENTA	OBJETIVO	ENTREGABLE
Muestreo estratificado	Selección	scikit-learn (StratifiedKFold)	Preservar la distribución de clases	conjunto de entrenamiento/validación estratificado
Reglas de validación	Preprocesamiento	scripts pandas / Great Expectations	detectar y corregir inconsistencias	bitácora de calidad
One-hot encoding / scaling	Transformación	pandas / scikit-learn (OneHotEncoder, StandardScaler)	convertir variables categóricas y escalar números	matriz de diseño lista para modelado
PCA (reducción dimensional)	Transformación	scikit-learn (PCA)	reducir ruido y correlación entre variables	componentes principales y gráfica de varianza explicada
K-means (clustering)	Minería	scikit-learn (KMeans)	encontrar segmentos naturales	componentes principales y gráfica de varianza explicada.
Matriz de confusión / ROC	Interpretación	scikit-learn (confusion_matrix, roc_auc_score)	evaluar rendimiento predictivo	tabla de métricas y curvas ROC

4. Ordene cronológicamente y asigne la fase de KDD a cada elemento. Justifique en 1 frase.
 - a. Definir la ventana “t-6 a t-1 meses” y listar tablas/variables autorizadas.
 - b. Quitar outliers por IQR y normalizar montos.
 - c. Construir variables de “canasta” y lags semanales.
 - d. Comparar modelos y seleccionar el mejor por ROC-AUC y F1.
 - e. Presentar un mapa de segmentos y reglas de acción para marketing.
 - f. Unir ventas internas con clima y calendario de promociones.

Orden	Ítem	Fase de KDD	Justificación
1	a	Selección	Se define el marco temporal y el subconjunto de datos (tablas/variables) necesarios para el objetivo del proyecto.
2	f	Preprocesamiento (Integración)	Se consolidan fuentes de datos heterogéneas (internas y externas) para enriquecer el contexto del análisis.
3	b	Limpieza / Transformación	Se mejora la calidad del dato eliminando ruido (outliers) ajustando escalas para asegurar la estabilidad del modelo.
4	c	Transformación (Ingeniería de variables)	Se crean nuevas dimensiones de análisis, como comportamientos de compra y tendencias temporales, para capturar patrones complejos.
5	d	Minería de Datos (Data Mining)	Se ejecutan algoritmos y se evalúa su rendimiento mediante métricas para encontrar el modelo predictivo más preciso.
6	e	Interpretación / Evaluación	Se traducen los hallazgos técnicos en conocimiento accionable y visualizaciones para la toma de decisiones de negocio.

Realice el siguiente ejercicio:

Problema: La ANT desea entender y anticipar la emisión de licencias de conducir por provincia, categoría y priorizar oficinas.


Objetivo: Aplicar KDD sobre el archivo "ant_datos_licencias_2022_mayo_hoja.csv" de la página de Datos Abiertos del Ecuador para:

- **Limpieza y documentación de calidad de datos agregados:** El estudiante limpiará el archivo agregado (provincia×categoría×mes), estandarizará encabezados y tipos, imputará vacíos coherentemente y documentará la calidad del dato (tamaño, % de faltantes, consistencia de totales frente a suma de categorías, y hallazgos relevantes).
- **Indicadores descriptivos por provincia, categoría y mes (cuando aplique):** El estudiante construirá indicadores de volumen y mezcla: totales por provincia, distribución por clase/categoría y, si la hoja lo permite, totales por mes. Se incluirán visualizaciones como barras comparativas y mapas de calor (absoluto y en proporciones) para sustentar los hallazgos.
- **Modelo de priorización provincial con variables de mezcla:** El estudiante desarrollará un modelo sencillo a nivel provincia (p. ej., clasificación Top vs. no-Top por cuartil o share profesional proxy) utilizando como insumos las proporciones por categoría (prop_*). Se reportarán métricas (Accuracy, Precision, Recall, F1 y, cuando corresponda, ROC-AUC) para justificar el uso del modelo como herramienta de priorización táctica.
- **Traducción de resultados a decisiones operativas:** Con base en los indicadores y el modelo, el estudiante propondrá acciones de focalización: priorización de provincias de mayor carga, refuerzo por categorías con lift alto (especialización relativa), y lineamientos operativos (p. ej., dimensionamiento de recursos y focos de campaña). Se señalarán supuestos y límites derivados de trabajar con datos agregados.

Indicador Clave de Desempeño KPI

- a. Lift/variación de demanda por provincia y categoría;
- b. Accuracy/F1 del modelo y uso para focalización operativa.

Suba el archivo "ant-datos-licencias-2022-mayo.xlsx" con la flecha indicada en la imagen.



FASE 0 — Preparación

```
[2]
✓ 0 s
import sys, numpy as np, pandas as pd, matplotlib.pyplot as plt
from pathlib import Path
np.random.seed(42)
pd.set_option("display.max_columns", 200)

def std_name(c):
    return (str(c).strip().replace("\n", " ").replace("\r", " ")
            .lower().replace(" ", "_").replace("-", "_")
            .replace("á", "a").replace("é", "e").replace("í", "i")
            .replace("ó", "o").replace("ú", "u").replace("ñ", "n"))

def normaliza_txt(x):
    s = str(x).strip().upper()
    for a,b in (("Á", "A"), ("É", "E"), ("Í", "I"), ("Ó", "O"), ("Ú", "U"), ("Ü", "U"), ("Ñ", "N")): s = s.replace(a,b)
    return s

ON_WEB = (sys.platform == "emscripten") # JupyterLite/Pyodide
print("Entorno:", "Web (sin pip)" if ON_WEB else sys.platform)
```

... Entorno: linux

FASE 1 — Selección y normalización (CSV)

... FASE 1 OK → filas: 504 | columnas: 11
Columnas: ['unidad', 'a', 'a1', 'b', 'c', 'c1', 'd', 'e', 'f', 'g', 'total_general']

	unidad	a	a1	b	c	c1	d	e	f	g	total_general
2	AZUAY	99	0	993	460	0	32	315	27	30	1956
3	Enero	20	0	133	86	0	10	25	3	13	290
4	Duplicado o Reimpresión de Licencia	6	0	75	22	0	8	21	1	1	134
5	Emisión de Licencia por Primera Vez	1	0	41	63	0	0	1	0	12	118
6	Renovación de Licencia	13	0	17	1	0	2	3	2	0	38
7	Febrero	20	0	202	185	0	4	35	5	11	462
8	Duplicado o Reimpresión de Licencia	7	0	83	31	0	3	16	3	1	144
9	Emisión de Licencia por Primera Vez	2	0	72	149	0	0	10	0	10	243
10	Renovación de Licencia	11	0	47	5	0	1	9	2	0	75
11	Marzo	25	0	239	56	0	8	55	6	1	390
12	Duplicado o Reimpresión de Licencia	5	0	117	34	0	2	34	0	0	192
13	Emisión de Licencia por Primera Vez	5	0	60	19	0	0	4	1	1	90

FASE 2 — Extraer provincias (24)



Provincias detectadas: 25
Listado: ['AZUAY', 'BOLIVAR', 'CANAR', 'CARCHI', 'CHIMBORAZO', 'COTOPAXI', 'EL ORO', 'ESMERALDAS', 'GALAPAGOS', 'GUAYAS', 'IM

Faltantes (según catálogo): ['SANTA ELENA', 'SANTO DOMINGO DE LOS TSACHILAS']

	unidad	a	a1	b	c	c1	d	e	f	g	total_general
0	AZUAY	99	0	993	460	0	32	315	27	30	1956
1	BOLIVAR	173	0	1317	666	0	175	669	2	43	3045
2	CARCHI	25	0	332	129	0	48	196	0	2	732
3	CAÑAR	137	2	1756	340	0	115	468	6	14	2838
4	CHIMBORAZO	60	0	976	439	3	121	362	8	16	1985
5	COTOPAXI	99	1	428	206	1	39	205	5	14	998
6	EL ORO	493	0	1869	606	1	120	478	13	26	3606
7	ESMERALDAS	1078	20	3601	819	1	362	1563	32	70	7546
8	GALÁPAGOS	127	0	168	67	0	12	54	0	2	430
9	GUAYAS	1265	13	18756	1496	31	636	4041	75	318	26631
10	IMBABURA	66	0	586	180	0	38	154	13	2	1039
11	LOJA	52	0	458	182	0	42	213	6	33	986
12	LOS RÍOS	1146	14	5958	922	3	427	1942	44	69	10525
13	MANABÍ	3607	171	14749	2202	15	1046	4487	89	180	26546
14	MORONA SANTIAGO	168	0	857	431	0	131	433	4	29	2053

	unidad	a	a1	b	c	c1	d	e	f	g	total_general
10	IMBABURA	66	0	586	180	0	38	154	13	2	1039
11	LOJA	52	0	458	182	0	42	213	6	33	986
12	LOS RÍOS	1146	14	5958	922	3	427	1942	44	69	10525
13	MANABÍ	3607	171	14749	2202	15	1046	4487	89	180	26546
14	MORONA SANTIAGO	168	0	857	431	0	131	433	4	29	2053
15	NAPO	437	0	1149	539	1	157	490	0	78	2851
16	ORELLANA	925	0	1433	838	2	260	1280	11	151	4900
17	PASTAZA	189	0	1437	614	0	172	511	7	58	2988
18	PICHINCHA	467	0	5199	686	21	253	1396	100	17	8139
19	SANTA ELENA	271	0	1871	277	3	105	457	11	17	3012
20	SANTO DOMINGO DE LOS TSÁCHILAS	342	0	1530	450	2	258	1239	5	41	3867
21	SUCUMBÍOS	89	0	132	104	0	17	102	7	5	456
22	TUNGURAHUA	22	0	287	81	2	23	80	20	2	517
23	Total general	11348	221	65958	12833	86	4616	21216	487	1235	118000
24	ZAMORA CHINCHIPE	11	0	116	99	0	27	81	2	18	354

Forma final df_prov: (25, 11)

FASE 3 — Transformación

Chequeo rápido:

- Provincias en df_prov: 25
- Filas en prov_long (debería ser 24 × nº de clases): 225

	unidad	clase	emisiones
0	AZUAY	a	99
1	BOLIVAR	a	173
2	CARCHI	a	25
3	CAÑAR	a	137
4	CHIMBORAZO	a	60
5	COTOPAXI	a	99
6	EL ORO	a	493
7	ESMERALDAS	a	1078
8	GALÁPAGOS	a	127
9	GUAYAS	a	1265
10	IMBABURA	a	66
11	LOJA	a	52

Resumen df_prov2 (debe haber 24 provincias): (25, 22)

	unidad	_total	a	a1	b	c	c1	d	e	f	g	prop_a	prop_a1	prop_b	prop_c	prop_c1
0	Total general	118000	11348	221	65958	12833	86	4616	21216	487	1235	0.096169	0.001873	0.558966	0.108754	0.000729
1	GUAYAS	26631	1265	13	18756	1496	31	636	4041	75	318	0.047501	0.000488	0.704292	0.056175	0.001164
2	MANABÍ	26546	3607	171	14749	2202	15	1046	4487	89	180	0.135877	0.006442	0.555602	0.082950	0.000565
3	LOS RÍOS	10525	1146	14	5958	922	3	427	1942	44	69	0.108884	0.001330	0.566081	0.087601	0.000285
4	PICHINCHA	8139	467	0	5199	686	21	253	1396	100	17	0.057378	0.000000	0.638776	0.084286	0.002580
5	ESMERALDAS	7546	1078	20	3601	819	1	362	1563	32	70	0.142857	0.002650	0.477206	0.108534	0.000133
6	ORELLANA	4900	925	0	1433	838	2	260	1280	11	151	0.188776	0.000000	0.292449	0.171020	0.000408
7	SANTO DOMINGO DE LOS TSÁCHILAS	3867	342	0	1530	450	2	258	1239	5	41	0.088441	0.000000	0.395656	0.116369	0.000517
8	EL ORO	3606	493	0	1869	606	1	120	478	13	26	0.136717	0.000000	0.518303	0.168053	0.000277
9	BOLIVAR	3045	173	0	1317	666	0	175	669	2	43	0.056814	0.000000	0.432512	0.218719	0.000000
10	SANTA ELENA	3012	271	0	1871	277	3	105	457	11	17	0.089973	0.000000	0.621182	0.091965	0.000996
11	PASTAZA	2988	189	0	1437	614	0	172	511	7	58	0.063253	0.000000	0.480924	0.205489	0.000000



Provincias en df_prov2: 25
Suma de proporciones por provincia (esperado ≈ 1.0):

```
0
0 1.0
1 1.0
2 1.0
3 1.0
4 1.0
5 1.0
6 1.0
7 1.0
8 1.0
9 1.0
```

FASE 4 — Clasificación Top vs. no-Top (autosuficiente)

```
... == Test ==
Accuracy: 0.750 | Precision: 0.500 | Recall: 0.500 | F1: 0.500
ROC-AUC: 0.750
Matriz de confusión:
[[5 1]
 [1 1]]
Reporte:
```

	precision	recall	f1-score	support
0	0.833	0.833	0.833	6
1	0.500	0.500	0.500	2
accuracy			0.750	8
macro avg	0.667	0.667	0.667	8
weighted avg	0.750	0.750	0.750	8

```
== CV estratificada ==
```

	accuracy	precision	recall	f1
mean	0.840	0.700	0.600	0.600
std	0.089	0.447	0.418	0.365

Importancia de variables (prop_*):


```
0
prop_a1 0.227
prop_c 0.188
prop_a 0.127
prop_d 0.110
prop_b 0.109
prop_c1 0.085
prop_e 0.055
prop_g 0.052
prop_f 0.048
```




Top potencial (primeras 15 filas):

	unidad	_total	prob_top	pred_top_rank	prop_a	prop_a1	prop_b	prop_c	prop_c1	prop_d	prop_e	prop_f	prop_g
2	MANABÍ	26546	0.888333	1	0.135877	0.006442	0.555602	0.082950	0.000565	0.039403	0.169027	0.003353	0.006781
0	Total general	118000	0.848333	1	0.096169	0.001873	0.558966	0.108754	0.000729	0.039119	0.179797	0.004127	0.010466
3	LOS RÍOS	10525	0.841667	1	0.108884	0.001330	0.566081	0.087601	0.000285	0.040570	0.184513	0.004181	0.006556
5	ESMERALDAS	7546	0.821667	1	0.142857	0.002650	0.477206	0.108534	0.000133	0.047972	0.207130	0.004241	0.009276
6	ORELLANA	4900	0.661667	1	0.188776	0.000000	0.292449	0.171020	0.000408	0.053061	0.261224	0.002245	0.030816
13	CAÑAR	2838	0.280000	1	0.048273	0.000705	0.618746	0.119803	0.000000	0.040521	0.164905	0.002114	0.004933
4	PICHINCHA	8139	0.221667	1	0.057378	0.000000	0.638776	0.084286	0.002580	0.031085	0.171520	0.012287	0.002089
21	TUNGURAHUA	517	0.220000	0	0.042553	0.000000	0.555126	0.156673	0.003868	0.044487	0.154739	0.038685	0.003868
1	GUAYAS	26631	0.208333	0	0.047501	0.000488	0.704292	0.056175	0.001164	0.023882	0.151740	0.002816	0.011941
18	COTOPAXI	998	0.188333	0	0.099198	0.001002	0.428858	0.206413	0.001002	0.039078	0.205411	0.005010	0.014028
7	SANTO DOMINGO DE LOS TSÁCHILAS	3867	0.153333	0	0.088441	0.000000	0.395656	0.116369	0.000517	0.066718	0.320403	0.001293	0.010603
12	NAPO	2851	0.146667	0	0.153280	0.000000	0.403016	0.189056	0.000351	0.055068	0.171870	0.000000	0.027359
10	SANTA ELENA	3012	0.146667	0	0.089973	0.000000	0.621182	0.091965	0.000996	0.034861	0.151726	0.003652	0.005644
8	EL ORO	3606	0.121667	0	0.136717	0.000000	0.518303	0.168053	0.000277	0.033278	0.132557	0.003605	0.007210
19	LOJA	986	0.113333	0	0.052738	0.000000	0.464503	0.184584	0.000000	0.042596	0.216024	0.006085	0.033469


FASE 5 — Assess: gráficos + KPI + export





KPI (a) – Top 15 provincia×clase por Lift ponderado (prioridad operativa):

	unidad	clase	lift	var_pp	lift_pond
0	Total general	a	1.00	0.000	118000.000000
1	Total general	a1	1.00	0.000	118000.000000
2	Total general	b	1.00	0.000	118000.000000
3	Total general	c	1.00	0.000	118000.000000
4	Total general	c1	1.00	0.000	118000.000000
5	Total general	d	1.00	0.000	118000.000000
6	Total general	e	1.00	0.000	118000.000000
7	Total general	f	1.00	0.000	118000.000000
8	Total general	g	1.00	0.000	118000.000000
9	MANABÍ	a1	3.44	0.005	91303.167421
10	GUAYAS	c1	1.60	0.000	42534.883721
11	MANABÍ	a	1.41	0.040	37506.697215
12	GUAYAS	b	1.26	0.145	33554.807605
13	GUAYAS	g	1.14	0.001	30383.805668
14	PICHINCHA	c1	3.54	0.002	28813.953488



... KPI (b) – Métricas del modelo (clasificación Top vs. no-Top)
Accuracy: 0.750 | Precision: 0.500 | Recall: 0.500 | F1: 0.500 | ROC-AUC: 0.750
Matriz de confusión:

```
[[5 1]
 [1 1]]
```

Reporte:


	precision	recall	f1-score	support
0	0.833	0.833	0.833	6
1	0.500	0.500	0.500	2
accuracy			0.750	8
macro avg	0.667	0.667	0.667	8
weighted avg	0.750	0.750	0.750	8

CV estratificada (media±std):

	accuracy	precision	recall	f1
mean	0.840	0.700	0.600	0.600
std	0.089	0.447	0.418	0.365

Focalización operativa – Top 12 provincias por prob_top:

	unidad	_total	prob_top	prop_a	prop_a1	prop_b	prop_c	prop_c1	prop_d	prop_e	prop_f	prop_g
0	MANABI	26546	0.888333	0.135877	0.006442	0.555602	0.082950	0.000565	0.039403	0.169027	0.003353	0.006781
1	Total general	118000	0.848333	0.096169	0.001873	0.558966	0.108754	0.000729	0.039119	0.179797	0.004127	0.010466
2	LOS RÍOS	10525	0.841667	0.108884	0.001330	0.566081	0.087601	0.000285	0.040570	0.184513	0.004181	0.006556
3	ESMERALDAS	7546	0.821667	0.142857	0.002650	0.477206	0.108534	0.000133	0.047972	0.207130	0.004241	0.009276
4	ORELLANA	4900	0.661667	0.188776	0.000000	0.292449	0.171020	0.000408	0.053061	0.261224	0.002245	0.030816
5	CAÑAR	2838	0.280000	0.048273	0.000705	0.618746	0.119803	0.000000	0.040521	0.164905	0.002114	0.004933
6	PICHINCHA	8139	0.221667	0.057378	0.000000	0.638776	0.084286	0.002580	0.031085	0.171520	0.012287	0.002089
7	TUNGURAHUA	517	0.220000	0.042553	0.000000	0.555126	0.156673	0.003868	0.044487	0.154739	0.038685	0.003868
8	GUAYAS	26631	0.208333	0.047501	0.000488	0.704292	0.056175	0.001164	0.023882	0.151740	0.002816	0.011941
9	COTOPAXI	998	0.188333	0.099198	0.001002	0.428858	0.206413	0.001002	0.039078	0.205411	0.005010	0.014028
10	SANTO DOMINGO DE LOS TSÁCHILAS	3867	0.153333	0.088441	0.000000	0.395656	0.116369	0.000517	0.066718	0.320403	0.001293	0.010603
11	NAPO	2851	0.146667	0.153280	0.000000	0.403016	0.189056	0.000351	0.055068	0.171870	0.000000	0.027359



Responder:

Explique en al menos 3 líneas el funcionamiento y la utilidad de cada fase del trabajo realizado.

1) Limpieza y documentación

Detección automática de la fila de encabezado, estandarización de nombres de columna, conversión numérica segura (eliminar separadores de miles y convertir coma decimal), reemplazo de símbolos - por NA, llenado de clases NaN con 0 y verificación/ajuste de total_general para que coincida con la suma de categorías.

2) Indicadores descriptivos y visualizaciones

Agregación a nivel provincial (suma por provincia de cada categoría y total_general), totales por provincia, proporción por categoría (prop_*), y clasificación is_top (provincias en cuartil superior por total_general).

Visualizaciones

Barra horizontal con Top 15 provincias por total_general.

Heatmap de proporciones por categoría para las principales provincias.

Tabla con las primeras 30 provincias y sus totales.

3) Modelo de priorización provincial (enfoque y resultados)

Target (definición): provincia is_top = 1 si total_general $\geq$ cuartil 75 (Top 25%); 0 en caso contrario.

Features: proporciones por categoría (cada c/total_general), p. ej. a_prop, b_prop, etc.

Algoritmo: regresión logística con validación cruzada estratificada (n_splits=4).

Métricas reportadas (validación cruzada):

Accuracy (media CV): 0.75

Precision (media CV): 0.0

Recall (media CV): 0.0

F1 (media CV): 0.0

4) Decisiones operativas

Usa el ranking por total_general y complementar con lift por categoría (prop_*) para definir focos (por ejemplo, priorizar provincias con alto share en categorías profesionales si la prioridad es servicios profesionales).

- Se afirma que Manabí y Pichincha deben tener la misma prioridad operativa que Guayas. En desacuerdo, ya que el lift ponderado muestra oportunidades mayores en Guayas para categorías específicas; la priorización debe ser escalonada (Guayas primero y luego Manabí/Pichincha según mezcla), ¿está de acuerdo con lo anterior o los datos reflejan otras conclusiones?

No estoy de acuerdo ya que la prioridad debería ser Manabi, luego Guayas y finalmente Pichincha,

KPI (a) – Top 15 provincia×clase por Lift ponderado (prioridad operativa):

	unidad	clase	lift	var_pp	lift_pond
0	Total general	a	1.00	0.000	118000.000000
1	Total general	a1	1.00	0.000	118000.000000
2	Total general	b	1.00	0.000	118000.000000
3	Total general	c	1.00	0.000	118000.000000
4	Total general	c1	1.00	0.000	118000.000000
5	Total general	d	1.00	0.000	118000.000000
6	Total general	e	1.00	0.000	118000.000000
7	Total general	f	1.00	0.000	118000.000000
8	Total general	g	1.00	0.000	118000.000000
9	MANABÍ	a1	3.44	0.005	91303.167421
10	GUAYAS	c1	1.60	0.000	42534.883721
11	MANABÍ	a	1.41	0.040	37506.697215
12	GUAYAS	b	1.26	0.145	33554.807605
13	GUAYAS	g	1.14	0.001	30383.805668
14	PICHINCHA	c1	3.54	0.002	28813.953488