



Coordinación de
Educación Abierta y a Distancia
VICERRECTORADO ACADÉMICO



METODOLOGÍAS DE ANALÍTICA DE DATOS

Actividad Autónoma 4

Nombre de la actividad: SEMMA aplicado y comparación metodológica

Unidad 2: Enfoques clásicos de la analítica

Tema 2: SEMMA (Sample, Explore, Modify, Model, Assess)



FACULTAD DE
Ingeniería

Nombres:

Fecha:

Carrera:

Periodo académico:

Semestre:



Objetivo de la actividad: Aplicar con precisión la metodología SEMMA para transformar datos en modelos evaluados, justificando cada fase (Sample, Explore, Modify, Model, Assess).

Recursos o temas que debe haber estudiado antes de hacer la actividad:

Conceptos básicos de analítica de datos

- Principios de la metodología SEMMA
- Etapas del proceso: Sample, Explore, Modify, Model y Assess.
- Aplicaciones de SEMMA en proyectos

Limitaciones y vigencia de SEMMA en la industria actual.

Formato de entrega: PDF

Instrucciones:

- Redacte claramente las respuestas solicitadas
- Siga los pasos de la actividad autónoma en secuencia estricta
- Incluya una bibliografía con al menos 5 referencias académicas en APA 7.
- Nombrar el archivo de la siguiente manera:
Apellido_Nombre_Grupo_X.

Contenido

1. Explique con sus propias palabras ¿qué es SEMMA y describa el propósito de cada una de sus cinco fases (Sample, Explore, Modify, Model, Assess)?

2. Clasifique cada actividad en la fase de SEMMA que corresponda y justifique en 2-3 líneas:

a. Definir la ventana temporal, la unidad de análisis, las fuentes autorizadas y los criterios de inclusión/exclusión, dejando semilla y tamaños de las particiones.

Fase: _____

b. Perfilar datos (duplicados, faltantes, atípicos, coherencia de totales, reglas de negocio) y explorar distribuciones y correlaciones con tablas y gráficos.

Fase: _____



- c. Imputar faltantes con reglas de negocio y KNN-imputer, estandarizar formatos de fecha y codificar categóricas (one-hot/ordinal), encapsulando todo en un pipeline.

Fase: _____

- d. Generar variables de recencia-frecuencia-valor (RFM), proporciones por categoría (prop_*) y aplicar una reducción de dimensionalidad (p. ej., PCA) si procede.

Fase: _____

- e. Entrenar y comparar modelos (p. ej., regresión logística, árboles, gradient boosting) con validación apropiada (k-fold/estratificada o walk-forward) y métricas (Accuracy, Precision, Recall, F1, ROC-AUC).

Fase: _____

- f. Elaborar un dashboard de hallazgos, analizar errores y sesgos, definir umbrales/reglas operativas y estimar impacto en KPI (p. ej., lift y variación por provincia×categoría), dejando un plan de monitoreo (deriva y recalibración).

Fase: _____

3. Dibuje el mapa mental con el nodo central "SEMMA". Cree cinco ramas: Sample, Explore, Modify, Model y Assess. En cada rama, añada subnodos con: decisiones clave, técnicas/herramientas, riesgos típicos y entregables esperados.
4. Con base en un dataset del Portal de Datos Abiertos de datos abiertos una fuente pública y segura del Ecuador, cargue esa información en JupyterLab, y explique cómo aplicaría cada fase de SEMMA (Sample, Explore, Modify, Model, Assess) al problema analítico que defina a partir de esos datos, indicando el KPI principal y la meta de desempeño.
5. Investigue y compare al menos tres herramientas de análisis de datos (open-source y/o comerciales) que permitan aplicar SEMMA total o parcialmente (Sample, Explore, Modify, Model, Assess). Describa para cada una: tipo y licenciamiento, alcance por fase SEMMA, requisitos técnicos, costos aproximados en Ecuador, ventajas/desventajas y casos de uso; cierre con una recomendación justificada para el problema definido en la actividad 4 para su uso.



Bibliografía:

- SAS Institute Inc. (s. f.). SEMMA: Sample, Explore, Modify, Model, Assess. <https://www.sas.com>
- Shmueli, G., Bruce, P. C., Gedeck, P., Patel, N. R., & Lin, X. (2020). Data Mining for Business Analytics: Concepts, Techniques, and Applications in Python. Wiley.
- Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. CRC Press.
- Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3.ª ed.). OTexts. <https://otexts.com/fpp3/>
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (PAKDD).
- Pyle, D. (1999). Data Preparation for Data Mining. Morgan Kaufmann.
- Han, J., Pei, J., & Kamber, M. (2012). Data Mining: Concepts and Techniques (3.ª ed.). Morgan Kaufmann.
- Provost, F., & Fawcett, T. (2013). Data Science for Business. O'Reilly Media.

Rúbrica de evaluación

Componente de aprendizaje:	Autónomo	X	Contacto con el Docente	
Nombre de la Unidad:	Unidad 2: Enfoques clásicos de la analítica.			
Resultado(s) de aprendizaje:	- Describir los procesos clásicos de descubrimiento de conocimiento en bases de datos (KDD, SEMMA, CRISP-DM) en contextos académicos y profesionales. - Aplicar las metodologías KDD y SEMMA para planificar y ejecutar proyectos de analítica de datos en distintos escenarios de uso.			
Nombre de la Actividad:	SEMMA aplicado y comparación metodológica.			

Criterios de Evaluación	Escala de Valoración						
	Excelente (10 - 9,1)	Bueno (9 - 8,1)	Satisfactorio (8 - 7)	Necesita mejorar (6,9 - 0,1)	No entrega (0)	Puntaje	Comentarios (SIGEA)
1. Explicación de conceptos de análisis de datos	Define el concepto con claridad y clasifica la mayoría de los casos con justificación adecuada	Define el concepto con claridad y clasifica la mayoría de los casos con justificación adecuada	Explica parcialmente el concepto y clasifica algunos casos con justificación limitada.	Definición es incompleta o confusas, sin justificación adecuada en la clasificación.	No entrega		
2. Identifica el tipo de analítica descriptiva, predictiva o prescriptiva	Identifica con exactitud el tipo de analítica descriptiva, predictiva o prescriptiva y sustenta con métricas y evidencia	Identifica el tipo de analítica descriptiva, predictiva o prescriptiva y clasifica la mayoría de los casos con justificación adecuada.	Explica parcialmente el concepto y clasifica algunos casos con justificación limitada.	No identifica y con justificaciones incompletas o confusas	No entrega		
3. Identifica los ciclos de vida de un proyecto de analítica de datos	Identifica con exactitud al menos seis de las fases del ciclo de vida de un proyecto de analítica de datos	Identifica con exactitud al menos cuatro de las fases del ciclo de vida de un proyecto de analítica de datos.	Identifica con exactitud al menos dos de las fases del ciclo de vida de un proyecto de analítica de datos	Identifica con exactitud a una de seis de las fases del ciclo de vida de un proyecto de analítica de datos	No entrega		
4. Identifica las actividades y el orden a las que pertenecen dentro del ciclo de vida de un proyecto de analítica de datos.	Ordena correctamente y justifica adecuadamente las siete actividades	Ordena correctamente y justifica adecuadamente al menos cinco actividades	Ordena correctamente y justifica adecuadamente al menos tres actividades.	Ordena correctamente y justifica adecuadamente al menos una actividad.	No entrega		
5. Innovación en soluciones (Eje: Innovación / Autonomía)	Sigue las instrucciones y resuelve correctamente el problema planteado y entrega resultados realistas y ajustados a la problemática	Sigue las instrucciones y resuelve correctamente el problema, dando resultados que no se encuentran alineados al problema	Resuelve el problema pero los resultados obtenidos son inexactos y sin coherencia	No propone mejoras	No entrega		

Puntaje total

Los criterios 4 y 5 están alineados a los ejes de formación del Modelo Educativo UNACH "Introspección y Prospectiva" y responden principalmente a dos de los siguientes ejes:

1. Ambiente;
2. Autonomía y adaptabilidad;
3. Comunicación;
4. Desarrollo humano;
5. Ética y valores;
6. Emprendimiento;
7. Inter y multidisciplinariedad;
8. Innovación;
9. Inclusión e interculturalidad;
10. Investigación;
11. Impacto social;
12. Tecnologías.